Шинжлэх Ухаан, Технологийн Их Сургууль
Мэдээлэл, Холбооны Технологийн Сургууль



Батчулуун Очир

Том хэлний загварт (LLM) суурилсан Text-to-SQL агентыг хөгжүүлэх нь

Бакалаврын төгсөлтийн ажил

Улаанбаатар хот

Шинжлэх Ухаан, Технологийн Их Сургууль
Мэдээлэл, Холбооны Технологийн Сургууль

Компьютерын ухааны тэнхим

Том хэлний загварт (LLM) суурилсан Text-to-SQL агентыг хөгжүүлэх нь

Мэргэжлийн индекс: 061902000000002306
Мэргэжил: Хиймэл оюун

Удирдагч: Доктор (Ph.D) Д.Золзаяа
Зөвлөгч: Б.Батзолбоо
Гүйцэтгэгч: Б.Очир

Улаанбаатар хот
2026 он

Батлав. Удирдагч: ..... /Доктор (Ph.D) Д.Золзаяа/

ТӨГСӨЛТИЙН АЖЛЫН ТӨЛӨВЛӨГӨӨ

Сэдэв: «Том хэлний загварт (LLM) суурилсан Text-to-SQL агентыг хөгжүүлэх нь»

№	Ажлын бүлгийн нэр	Эзлэх хувь	Дуусах хугацаа
1	Оршил	5%	2026-09-30
2	Холбоотой ажлуудын судалгаа	12%	2026-09-30
3	Арга зүй ба дэвшүүлсэн санаа	12%	2026-10-28
4	Өгөгдөл боловсруулалт	10%	2026-10-28
5	Загвар хөгжүүлэлт ба урсгал	15%	2026-10-28
6	Туршилтын системийн хэрэгжүүлэлт	12%	2026-11-25
7	Үр дүн ба хэлэлцүүлэг	16%	2026-11-25
8	Ёс зүйн асуудал	8%	2026-11-25
9	Дүгнэлт	10%	2026-12-16

Төлөвлөгөөг боловсруулсан оюутан: ..... /Б.Очир/

ТӨГСӨЛТИЙН АЖЛЫН ХИЙГДСЭНИЙ ХУГАЦАА

№	Хийж гүйцэтгэх ажил	Биелэх хугацаа	Удирдагчийн гарын үсэг
1	Үзлэг 1	2026-09-30	
2	Үзлэг 2	2026-10-28	
3	Үзлэг 3	2026-11-25	
4	Урьдчилан хамгаалалт	2026-12-23	
5	Үндсэн хамгаалалт	Нэгдсэн хуваарийн дагуу	

Ажлын товч дүгнэлт

.....

.....

.....

.....

Удирдагч: ..... /Доктор (Ph.D) Д.Золзаяа/

ЗӨВШӨӨРӨЛ

Оюутан Б.Очир-ийн бичсэн төгсөлтийн ажлыг ШУТИС-д хамгаалуулахаар тодорхойлов.

Тэнхимийн эрхлэгч: ..... /Доктор (PhD), дэд проф. А.Хүдэр/

Шинжлэх Ухаан, Технологийн Их Сургууль
Мэдээлэл, Холбооны Технологийн Сургууль

ШҮҮМЖЛЭГИЙН ХУУДАС

Компьютерын ухааны тэнхимийн төгсөх курсийн оюутан Б.Очир-ийн «Том хэлний загварт (LLM) суурилсан Text-to-SQL агентыг хөгжүүлэх нь» сэдэвт төгсөлтийн ажлын шүүмж.

1. Сэдвээр дэвшүүлсэн асуудал, үүнтэй холбоотой онолын материалыг яаж судалсан байдал.
   .....
   .....

2. Ажлын ерөнхий агуулга. Шийдсэн зүйлүүд, гаргасан үр дүн.
   .....
   .....

3. Эмх цэгцтэй, стандарт хангасан байдал.
   .....
   .....

4. Давуу тал болон дутуу зүйлүүд.
   .....
   .....

5. Анхаарч тэмдэглэх зүйлүүд.
   .....
   .....

6. Ерөнхий оноо. (5 оноо)
   .....
   .....

Шүүмж бичсэн: ..... /...../

Ажлын газар: .....

Хаяг (Утас): .....

Зохиогчийн эрх хамгаалал

Миний бие Б.Очир, «Том хэлний загварт (LLM) суурилсан Text-to-SQL агентыг хөгжүүлэх нь» сэдэвт энэ ажил нь минийх бөгөөд дараахыг нотолж байна. Үүнд:

- Горилогч энэ ажлыг тус сургуулиас боловсролын зэрэг авахаар бүхэлд нь буюу голлон хийсэн болно.
- Энэ ажлын аль нэг хэсгийг тус сургуульд эсвэл өөр байгууллагад боловсролын зэрэг, мэргэшил авахаар өмнө нь илгээсэн бол түүнийгээ тодорхой заасан болно.
- Бусад хүмүүсийн хэвлүүлсэн ажлаас зөвлөгөө авсан бол түүнийгээ үндэслэсэн болно.
- Бусад хүмүүсийн ажлаас ишлэл хийхдээ эх үүсвэрийг нь заасан болно.
- Миний ажилд тусалсан голлох бүх эх үүсвэрт талархаж байна.
- Ажлыг бусадтай хамтарсан бол алийг нь бусад хүмүүс хийсэн болохыг тодорхой заасан болно.

Гарын үсэг: _____

Огноо: _____

Шинжлэх Ухаан, Технологийн Их Сургууль
Мэдээлэл, Холбооны Технологийн Сургууль

Хураангуй

Том хэлний загварт (LLM) суурилсан Text-to-SQL агентыг хөгжүүлэх нь

Б.Очир

Түлхүүр үгс: «Text2SQL», монгол хэл, том хэлний загвар, «RAG», машин орчуулга, «LoRA», санал хураалт, ББСБ, «PostgreSQL»

Санхүүгийн байгууллагын ажилтнууд өгөгдлийн сангаас тоо мэдээ авахдаа SQL бичдэг шинжээчээс хамаардаг. Байгалийн хэлний асуултыг SQL болгох (Text2SQL) системүүд англи хэлний Spider, BIRD жишиг дээр өндөр үр дүнтэй ч монгол хэлэнд зориулсан систем, үнэлгээний сан, туршилтын нотолгоо бараг байхгүй. Монгол хэлний залгамал үгзүй, кирилл ба латин галигийн холимог бичлэг, өгөгдлийн санд монголоор хадгалагдсан утга, байгууллагын дотоод нэр томьёо (PAR30, идэвхтэй багц) нь англи хэлний аргуудыг шууд хэрэглэхэд саад болдог. Мөн өгөгдөл гадагш гарах ёсгүй тул нэг GPU-д багтах нээлттэй эхийн загвар шаардлагатай.

Энэхүү ажлаар банк бус санхүүгийн байгууллагын (ББСБ) 28 хүснэгт бүхий PostgreSQL өгөгдлийн сан (648 205 мөр синтетик өгөгдөл) дээр монгол асуултад хариулах Text2SQL системийг нээлттэй эхийн Arctic-Text2SQL-R1-7B загвар дээр бүтээж, бүрэлдэхүүн бүрийн нөлөөг хяналттай туршилтаар хэмжив. Үүний тулд dev 300, test 200 асуулт бүхий монгол үнэлгээний сан (хариулах боломжгүй ба хоёрдмол асуулттай) бэлтгэж, загварын гэр бүлээр нь давхцалгүй хуваав. Систем нь асуултыг шалгах (хувийн мэдээлэл, бичих хүсэлтээс татгалзах), англи руу орчуулах, мэдлэг хайх (BM25 ба BGE-M3: хүснэгт, утга, нэр томьёо, жишээ), өөрийн DB-ийн RAG prompt-оор LoRA-аар нэмж сургасан загвараар SQL үүсгэх, алдааг засах, 8 хувилбараас гүйцэтгэлийн үр дүнгээр санал хураах, итгэл багатай үед тодруулга асуух алхмуудаас бүрдэнэ. Мөн туршилтын тохиргоог node-оор угсарч, алхам бүрийн prompt ба мэдлэгийг харуулдаг «Text2SQL Studio» вэб хэрэгслийг хөгжүүлэв.

Нийт оноо татгалзал, тодруулгыг зөвд тооцдог тул (үргэлж тодруулдаг систем test-д 24.5%) гол хэмжүүр нь хариулах боломжтой EX. Dev-д нийт зөв суурь загварын 2.3%-иас (RAG-гүй) M1a-д 53.3% хүрэв. Шинэ асуултын test дээр dev-ээр сонгосон тохиргооны нийт зөв (хариулах боломжтой EX) нэмэлт сургалттай суурь D2-д 21.0% (24.5%), орчуулга ба засвартай H4-д 34.0% (31.8%), 8 хувилбар ба дүрэмтэй E4-д 45.0% (42.4%; dev-д дэмжлэгтэй түлхүүр үгээр нийт 43.0%), сургасан орчуулагчтай M1a-д 50.5% (53.6%), урьдчилан зарласан эцсийн систем M1ens-д 55.0% (59.6%) болов. Dev-д мэдлэг хайх (+12.0 хувь) ба орчуулга (ижил кодоор +7.7) хамгийн их, өөрийн DB-ийн жишээгүй нэмэлт сургалт (+1.4) хамгийн бага нэмэр өгсөн. E2-ийн алдааны 38% нь орчуулгаас үүдсэн тул 2 828 хосын санхүүгийн орчуулгын өгөгдлөөр MADLAD-400-3B-ийг нэмж сургав: test-ийн хариулах боломжтой асуултад I3t-ээс $+32/-13$ ахив ($p = 0.0066$; test-ээс мэдээлэл авсан 13 асуултгүйгээр $p = 0.047$, загвар төстэй 6-г ч хасвал $p = 0.16$). M1a ба түүний 4 хувилбарын чуулга M1ens нь M1a-аас $+10/-1$ ахив ($p = 0.012$; эдгээр 19 асуултгүй $p = 0.039$). Гол хувь нэмэр нь монгол хэлний анхны Text2SQL үнэлгээний сан, бүрэлдэхүүн бүрийн нөлөөг статистик тестээр шалгасан (зарим нь батлагдаагүй) туршилт, нэг GPU-д ажиллах давтагдахуйц систем ба судалгааны хэрэгсэл юм.

Талархал

Энэхүү ажлыг гүйцэтгэх явцад судалгааны чиглэлийг тодорхойлох, туршилтын арга зүйг боловсруулахад үнэтэй зөвлөгөө өгсөн удирдагч багш Доктор (Ph.D) Д.Золзаяа, зөвлөгч багш Б.Батзолбоо нарт чин сэтгэлийн талархал илэрхийлье.

Мөн ажлын турш дэмжиж, урам зориг өгсөн гэр бүл, найз нөхөддөө талархлаа илэрхийлье.

Товчилсон үгс

ББСБ	Банк бус санхүүгийн байгууллага
LLM	**L**arge **L**anguage **M**odel (том хэлний загвар)
Text2SQL	Байгалийн хэлний асуултыг SQL болгон хөрвүүлэх даалгавар
SQL	**S**tructured **Q**uery **L**anguage
RAG	**R**etrieval-**A**ugmented **G**eneration
SFT	**S**upervised **F**ine-**T**uning
RL	**R**einforcement **L**earning
GRPO	**G**roup **R**elative **P**olicy **O**ptimization
LoRA	**Lo**w-**R**ank **A**daptation
CoT	**C**hain-**o**f-**T**hought
EX	**Ex**ecution accuracy (гүйцэтгэлийн нарийвчлал)
TS-EX	**T**est-**S**uite execution accuracy
BM25	**B**est **M**atching 25 (түлхүүр үгийн хайлтын оноо)
DDL	**D**ata **D**efinition **L**anguage
RLS	**R**ow-**L**evel **S**ecurity
PII	**P**ersonally **I**dentifiable **I**nformation
GPU	**G**raphics **P**rocessing **U**nit
vLLM	LLM-ийн өндөр хурдны inference сервер
BIRD	**B**ig Bench for Large-scale Database Grounded Text-to-SQL Evaluation
KPI	**K**ey **P**erformance **I**ndicator
JSONL	JSON **L**ines (мөр бүр нэг JSON бичлэг)
AML	**A**nti-**M**oney **L**aundering (мөнгө угаахтай тэмцэх)
CTE	**C**ommon **T**able **E**xpression (SQL-ийн `WITH` дэд асуулга)
HF	**H**ugging **F**ace (загварын сан)
KL	**K**ullback–**L**eibler зөрүү
KYC	**K**now **Y**our **C**ustomer (харилцагчийг таних)
LCS	**L**ongest **C**ommon **S**ubsequence
LR	**L**earning **R**ate (сургалтын алхмын хэмжээ)
LSH	**L**ocality-**S**ensitive **H**ashing
PAR30	**P**ortfolio **a**t **R**isk 30 (30 хоногийн босготой хугацаа хэтэрсэн багцын хувь)
SOV	**S**ubject–**O**bject–**V**erb үгийн дараалал
TRL	**T**ransformer **R**einforcement **L**earning (Hugging Face-ийн сан)
YAML	YAML Ain't Markup Language (тохиргооны файлын формат)
MT	**M**achine **T**ranslation (машин орчуулга)
QLoRA	**Q**uantized **LoRA** (4 битээр шахсан жин дээрх LoRA)
chrF++	Тэмдэгт ба үгийн n-gram-д суурилсан орчуулгын чанарын хэмжүүр
NPL	**N**on-**P**erforming **L**oan (чанаргүй зээл)
RQ	**R**esearch **Q**uestion (судалгааны асуулт)

Гарчиг

Зохиогчийн эрх хамгаалал **i**

Хураангуй **ii**

Талархал **iii**

Товчилсон үгс **iv**

Оршил **1**
Судалгааны үндэслэл, орчин 1
Асуудлын тодорхойлолт 1
Таамаглал 2
Зорилго 2
Зорилтууд 2
Хамрах хүрээ ба хязгаарлалт 2
Судалгааны хувь нэмэр 3
Ажлын бүтэц 3

1 Холбоотой ажлуудын судалгаа **4**
1.1 Холбоотой судалгаанууд 4
1.2 Ижил төстэй бүтээгдэхүүний судалгаа 5
1.3 Харьцуулсан шинжилгээ 6
1.4 Судалгааны цоорхой 7
1.5 Бүлгийн дүгнэлт 8

2 Арга зүй ба дэвшүүлсэн санаа **9**
2.1 Санал болгож буй загвар ба архитектур 9
2.2 Системийн архитектурын дэлгэрэнгүй тайлбар 9
2.3 SQL үүсгэх загвар 11
2.4 Орчуулгын загвар ба мэдлэг хайлт 12
2.5 Бүлгийн дүгнэлт 12

3 Өгөгдөл боловсруулалт **13**
3.1 SQL үүсгэх загварын өгөгдөл 13
3.2 Орчуулгын загварын өгөгдөл 14
3.3 Өгөгдлийн нэгдсэн үзүүлэлт ба хуваалт 14
3.4 Бүлгийн дүгнэлт 15

4 Загвар хөгжүүлэлт ба урсгал **16**
4.1 SQL үүсгэх загвар хөгжүүлэлт ба сургалтын арга зүй 16
4.2 Орчуулгын загвар хөгжүүлэлт ба сургалтын арга зүй 18
4.3 Бүлгийн дүгнэлт 18

5 Туршилтын системийн хэрэгжүүлэлт **19**
5.1 Системийн ерөнхий бүтэц 19
5.2 Асуулт хүлээн авах ба шалгах 19
5.3 Асуултыг орчуулах 19
5.4 Мэдлэг хайх ба prompt угсрах 19
5.5 SQL үүсгэх, засах ба сонгох 20
5.6 Аюулгүй гүйцэтгэл ба аудит 21
5.7 Text2SQL Studio дээр дүрслэх 21
5.8 Загварын үндсэн зарчмууд 23
5.9 Системийн хязгаарууд ба цаашдын ажил 23
5.10 Бүлгийн дүгнэлт 23

6 Үр дүн ба хэлэлцүүлэг **24**
6.1 SQL үүсгэх загварын үр дүн 24
6.2 Орчуулгын загварын үр дүн 30
6.3 Системийн хугацааны хоцрогдлын үнэлгээ 32
6.4 Зорилго ба таамаглалын биелэлт 33
6.5 Ёс зүйн асуудал 36
6.6 Бүлгийн дүгнэлт 36

Дүгнэлт **37**

А Ажиллуулах тушаалууд **40**

Б Төслийн файлын бүтэц **41**

В Туршилтын тохиргооны жагсаалт **42**

Г Ажлын түүх **44**

Ном зүй **45**

Зургийн жагсаалт

2.1 Санал болгож буй дамжлага (улбар шар: загвар ашигладаг алхам) . 9
2.2 Нэг асуултын дарааллын диаграм (E2 тохиргоо) 11

5.1 Text2SQL Studio: дамжлагын алхмууд (зүүн), асуулт ба хариулт (баруун), демо горим 21

6.1 Dev дээрх ахицын зам (нийт зөв, %; тасархай шугам — үргэлж тодруулдаг энгийн систем) 25

Хүснэгтийн жагсаалт

1.1 Ижил төстэй бүтээгдэхүүний харьцуулалт 6
1.2 Холбоотой судалгааны харьцуулалт 7

2.1 Функциональ ба функциональ бус шаардлага 10
2.2 SQL үүсгэх загварын үзүүлэлт 12
2.3 Туслах загваруудын үзүүлэлт 12

3.1 Мэдлэгийн сангийн бүрэлдэхүүн 13
3.2 Орчуулгын өгөгдөл (MT v2) 14
3.3 Үнэлгээний сангийн хуваалт ба ангилал 15
3.4 Үнэлгээний сангийн жишээ асуултууд 15
3.5 Өгөгдлийн чанарын нэгдсэн үзүүлэлт 15

4.1 Суурь загвар (A бүлэг), dev 300, Kaggle T4 16
4.2 Гүйцэтгэсэн сургалтууд 16
4.3 B ба C, D бүлэг, dev 300 17
4.4 Бүрэлдэхүүн тус бүрийн нөлөө (dev 300, нийт зөв, %) 17
4.5 MADLAD-400-3B-MT-ийн QLoRA сургалтын гипер-параметр 18

5.1 Кодын бүтэц 19
5.2 Аналистад зориулсан боломжууд 22
5.3 Системийн дизайны үндсэн зарчмууд 23

6.1 Dev-ийн үр дүн (задаргаатай) 24
6.2 Test-ийн үр дүн 25
6.3 McNemar тест (exact), dev: нийт ба хариулах боломжтой асуулт . . . 26
6.4 McNemar тест (exact), test: нийт ба хариулах боломжтой асуулт . . . 27
6.5 E2-ийн алдааны ангилал (dev, хариулах боломжтой 124 буруу) . . . 28
6.6 Хариулах боломжтой асуултын зөв, домэйн ба хүндрэлээр (dev) . . . 28
6.7 Үүсгэсэн SQL-ийн бүтцийг gold-той харьцуулсан нь (хариулах боломжтой асуулт, %) 29
6.8 Буруу хариултын шалтгаан (хариулах боломжтой асуулт, буруу хариултын %) 29
6.9 Орчуулгын үзүүлэлт (dev, 300 асуулт) 31
6.10 Тохиргооны асуулт тутмын дундаж хугацаа (Kaggle T4×2) 32
6.11 Зорилго ба таамаглалын биелэлт 33
6.12 Мэдрэмжийн шинжилгээ: үндсэн ба тохируулсан тоо 34
6.13 Зорилгын биелэлтийн нэгтгэл 38

B.1 Ажиллуулсан болон бэлэн тохиргоонууд (`config/experiments.yaml`) . 42

Г.1 Ажлын гол үе шат 44

Оршил

Судалгааны үндэслэл, орчин

Банк бус санхүүгийн байгууллагын (ББСБ) өдөр тутмын шийдвэр тоо мэдээнд тулгуурладаг: салбар бүрийн хугацаа хэтэрсэн зээлийн үлдэгдэл, сарын шинэ зээлийн тоо, барагдуулалтын үр дүн гэх мэт. Эдгээр мэдээллийг өгөгдлийн сангаас авахдаа ажилтнууд SQL бичих чадвартай шинжээч эсвэл урьдчилан бэлтгэсэн тайланд хамаардаг. Шинэ асуулт гарах бүрд хүсэлт илгээж хүлээх нь цаг алддаг бөгөөд шинжээчийн ачааллыг нэмэгдүүлдэг.

Байгалийн хэлний асуултыг SQL болгох (Text2SQL) системүүд том хэлний загварын (LLM) хөгжлийн хэрээр англи хэлний жишгүүд дээр өндөр түвшинд хүрсэн [1, 2]. Нээлттэй эхийн 7B хэмжээтэй Arctic-Text2SQL-R1 загвар BIRD-ийн test дээр 68.5% гүйцэтгэлийн нарийвчлал (EX) үзүүлдэг [3]. Гэвч англи бус хэл дээр эдгээр загварын нарийвчлал мэдэгдэхүйц буурдаг [4, 5]. Санхүүгийн өгөгдөл байгууллагаас гадагш гарах ёсгүй тул арилжааны API-д суурилсан шийдэл тохиромжгүй бөгөөд нэг GPU-д багтах нээлттэй эхийн загварыг монгол хэл ба байгууллагын домэйнд тохируулах шаардлагатай.

Асуудлын тодорхойлолт

Монгол асуулт q, өгөгдлийн сангийн схем S ба байгууллагын мэдлэг K (баганын тайлбар, нэр томьёо, жишээ) өгөгдсөн үед гүйцэтгэлийн үр дүн нь лавлах (gold) SQL-ийнхтэй таарах SQL $\hat{s}$-ийг үүсгэх, эсвэл асуулт хариулах боломжгүй (хувийн мэдээлэл, өгөгдөлд байхгүй) бол татгалзах, хоёрдмол бол тодруулга асуух шаардлагатай. Энэ даалгаврыг дараах бэрхшээлүүд хүндрүүлнэ:

1. **Бага нөөцтэй хэл.** Монгол Text2SQL-ийн сургалтын ба үнэлгээний өгөгдөл байхгүй, загварууд монгол хэлийг сул ойлгодог [6]. Хэрэглэгчид кирилл ба латин галигаар («zeeliin hvselt») холимог бичдэг.

2. **Домэйны мэдлэг.** «PAR30», «идэвхтэй багц» зэрэг нэр томьёоны тодорхойлолт байгууллагын дотоод дүрмээс хамаардаг [2].

3. **Том схем.** 28 view, 425 багана бүхий схемийг бүтнээр нь өгөхөд prompt 13–20 мянган токен болж, жижиг загварын анхаарлыг сарниулдаг.

4. **Найдвартай байдал.** Санхүүгийн хэрэглээнд буруу тоо хариулахаас татгалзах нь дээр [7].

Таамаглал

H1: Мэдлэг хайлт (схемийн тайлбар, утга, нэр томьёо, жишээ) нь нийт зөв хариултыг 10-аас дээш хувиар өсгөнө.

H2: Англи төвтэй SQL загварт монгол асуултыг англи руу орчуулж өгөх нь шууд өгөхөөс статистикийн ач холбогдолтой ($p < 0.05$) илүү үр дүн өгнө.

H3: Өөрийн өгөгдлийн сангийн RAG prompt-оор нэмж сургасан (fine-tune) загвар RAG-тай суурь загварыг давна.

H4: Олон хувилбараас гүйцэтгэлийн үр дүнгээр санал хураах нь хариулах боломжтой асуултын нарийвчлалыг ач холбогдолтой өсгөнө.

Зорилго

ББСБ-ийн өгөгдлийн сан дээр монгол хэлээр асуусан асуултыг автоматаар SQL болгож хариулдаг систем бүтээх.

Зорилтууд

Дээрх зорилгод хүрэхийн тулд сэдэв батлах даалгаврын дагуу дараах зорилтуудыг дэвшүүлэв:

1. Өгөгдлийн сангийн схем, утга, бизнесийн нэр томьёо, жишээ асуултаас мэдлэгийн сан (RAG) бүрдүүлэх;
2. Асуулт бүрд хамааралтай мэдээллийг хайж олоод загварт өгөх prompt болон pipeline боловсруулах;
3. Загварыг монгол хэл болон өөрийн өгөгдлийн санд тохируулан сургах (fine-tune);
4. Хариултын зөв байдлыг нэмэгдүүлэх: олон хувилбараас сонгох, алдааг засах, хариулах боломжгүй асуултаас татгалзах;
5. Системийн үр дүнг тестийн асуултын багцаар хэмжиж үнэлэх, тайлагнах.

Хамрах хүрээ ба хязгаарлалт

Хамрах хүрээ:

- ББСБ-ийн PostgreSQL өгөгдлийн сан (28 view бүхий text2sql давхарга) дээрх монгол асуултад SQL үүсгэх систем;
- Кирилл болон латин галигаар бичсэн асуулт, хариулах боломжгүй ба хоёрдмол асуултыг таних;
- Нэг GPU-д ажиллах нээлттэй эхийн загвар (SQL бичигчээр зөвхөн Arctic-Text2SQL-R1-7B).

Хязгаарлалт:

- Бодит харилцагчийн мэдээлэл ашиглах эрхгүй тул детерминист синтетик өгөгдөл (seed 42, 2026-06-30-ны байдлаар) ашиглав;

- Өөрийн GPU сервергүй тул туршилтыг хязгаарлагдмал төсвөөр хийсэн: үнэлгээг голчлон Kaggle T4×2 (долоо хоногт 30 цаг), харин C, D2, H бүлэг ба E1, E2-ийн dev, D2 ба H4-ийн test үнэлгээг Vast.ai-ийн A100 дээр; сургалтыг Modal ба Vast.ai-ийн A100 (C1–C3, D2), Kaggle T4 (D3, MADLAD) дээр хийсэн; иймд төлөвлөгөөний зарим туршилт (GRPO, agentic горим) хийгдээгүй;
- Гол хэмжилт кирилл асуулт дээр хийгдсэн; бодит хэрэглээний (production) баталгаажуулалт хамрагдаагүй.

Судалгааны хувь нэмэр

1. Хариулах боломжгүй ба хоёрдмол асуулттай, кирилл, латин, англи хувилбартай, загварын гэр бүлээр хуваасан 500 асуулт бүхий монгол хэлний Text2SQL үнэлгээний сан;
2. Мэдлэг хайлт, орчуулга, нэмэлт сургалт, санал хураалт тус бүрийн нөлөөг нэг схем, нэг үнэлгээн дээр хэмжиж, асуулт бүрийн гаралттай алхмуудыг McNemar тестээр харьцуулсан эмпирик нотолгоо;
3. Алдааны эх үүсвэрийн хэмжилт ба түүнд тулгуурласан санхүүгийн хэллэгийн орчуулгын өгөгдөл (2 828 хос);
4. Үнэгүй үүлэн квот дээр тасалдлаас сэргэдэг туршилтын систем, алхам бүрийн prompt ба мэдлэгийг харуулдаг «Text2SQL Studio» хэрэгсэл.

Ажлын бүтэц

Бүлэг 1-т холбоотой судалгаа ба ижил төстэй бүтээгдэхүүнийг тоймлож судалгааны цоорхойг тодорхойлно. Бүлэг 2-т санал болгож буй архитектур, SQL бичигч ба орчуулгын загварын онолын үндсийг, Бүлэг 3-т өгөгдлийн сан, мэдлэгийн сан, сургалтын ба үнэлгээний өгөгдлийг, Бүлэг 4-т загваруудын сургалтын урсгал ба туршилтын тохиргоог тайлбарлана. Бүлэг 5-д туршилтын системийн хэрэгжүүлэлтийг, Бүлэг 6-д үр дүн, хэлэлцүүлэг ба ёс зүйн асуудлыг авч үзээд, эцэст нь Дүгнэлт хэсэгт нэгтгэн дүгнэнэ.

БҮЛЭГ 1

Холбоотой ажлуудын судалгаа

Энэ бүлэгт Text2SQL, мэдлэг хайлт, олон хэлт ба бага нөөцтэй хэлний чиглэлээр хийгдсэн судалгаа болон зах зээл дээрх ижил төстэй бүтээгдэхүүнийг тоймлож, тэдгээрийн арга зүй, хязгаарлалтыг харьцуулан шинжилнэ. Ингэснээр энэхүү ажлын онол-аргазүйн суурийг тодорхойлж, шийдвэрлэх судалгааны цоорхойг илрүүлнэ.

1.1 Холбоотой судалгаанууд

Text2SQL даалгавар ба жишиг үнэлгээ

Shi нар Text2SQL-ийн хөгжлийг дүрэмд суурилсан, Seq2Seq, урьдчилан сургасан хэлний загвар, LLM гэсэн үе шатаар тодорхойлсон [1]. Spider [8] олон хүснэгттэй, урьд үзээгүй схемд ерөнхийлөх даалгаврыг, BIRD [2] бодит «бохир» өгөгдөл, том схем, гадаад мэдлэг (evidence) шаарддаг нөхцөлийг тавьсан. Нэг асуултад олон зөв SQL байж болох тул текстээр бус гүйцэтгэлийн үр дүнгээр (EX) үнэлдэг; санамсаргүй таарахаас сэргийлэхийн тулд өгөгдлийг өөрчилсөн хэд хэдэн хуулбар DB дээр шалгах test-suite аргыг санал болгосон [9]. TrustSQL нь хариулах боломжгүй асуултыг оруулж, зөв татгалзалтыг зөв хариулттай адил тооцдог [7]; AMBROSIA, AmbiQT нь нэг асуулт олон зөв тайлбартай байж болохыг харуулсан [10, 11].

Нээлттэй эхийн тусгай Text2SQL загварууд

OmniSQL нь 2.5 сая синтетик хосоор Qwen2.5-Coder-ийг сургаж, 7B загварыг том ерөнхий загваруудтай өрсөлдөхүйц болгосон [12, 13]. Arctic-Text2SQL-R1 нь OmniSQL-оос эхлүүлж, зөвхөн гүйцэтгэлд суурилсан энгийн reward-аар (1: зөв, 0.1: ажилласан ч буруу, 0: алдаа) GRPO [14] хийсэн. Түүний 32B хувилбар BIRD-ийн самбарт 71.83%-иар тэргүүлсэн бол энэ ажилд ашигласан 7B хувилбар BIRD test дээр 68.5% EX авсан [3]. Reward-SQL нь асуулгыг дараалсан CTE-ээр задалж, алхам бүрийг процессын reward загвараар үнэлснээр Qwen2.5-Coder-7B-ийг BIRD dev дээр 68.9%-д хүргэсэн [15]. SING-SQL нь нэг өгөгдлийн сангийн дэд схем бүрээс SQL үүсгэж асуулт болгон буцаан орчуулах, гүйцэтгэлээр шүүх замаар тухайн DB-д зориулсан синтетик өгөгдөл бэлтгэдэг [16]. Эдгээр загвар англи өгөгдлөөр сургагдсан тул англи бус асуултад хэр ажиллах нь тодорхойгүй хэвээр байна.

Мэдлэг хайлт ба жишээ сонголт

RAG нь загварын параметрт байхгүй мэдлэгийг хайлтаар олж prompt-д нэмдэг [17]. Text2SQL-д схемийн тайлбар, хадгалагдсан утга, бизнес нэр томьёо, төстэй асуулт–SQL жишээг хайдаг. CHESS нь утгыг LSH-ээр [18], CodeS нь BM25 ба LCS-ээр [19] хайдаг. DAIL-SQL нь асуултын утгыг далдалж, бүтцээр нь жишээ сонгох нь few-shot-ийн чанарыг сайжруулдгийг харуулсан [20]. Schema linking нь хүчтэй загварт ашиггүй ч жижиг загварт EX-ийг өсгөж болно [21]. RSL-SQL нь урьдчилсан SQL-д орсон хүснэгтээр схемийг буцаан нөхөх хоёр чиглэлтэй schema linking-ээр strict recall-ийг 94% хүртэл өсгөсөн ч EX-д шууд нөлөө нь 1.2 хувь байсан [22].

Олон хувилбар, засвар ба найдвартай байдал

Self-consistency нь хэд хэдэн хариу үүсгэж олонхоор сонгоно [23]; Text2SQL-д нэр дэвшигч SQL-ийг гүйцэтгээд үр дүнгээр санал хураадаг. CHASE-SQL олон генератор ба сонгогчийг хослуулах нь ганц генераторoос илүү болохыг харуулсан [24]; MCS-SQL олон prompt-оос гарсан хувилбарыг олон сонголттой асуулт болгон сонгосон [25]. XiYan-SQL-д Qwen2.5-Coder-7B дээр сургасан сонгогч олонхын саналаас 3.1

хувиар (73.34 ба 70.21%) илүү гарсан бол сургаагүй 7B сонгогч 62.84% буюу олонхын саналаас доогуур байв [26]. JudgeSQL нь гүйцэтгэлээр шалгагдах reward-аар сургасан 7B шүүгчээр хувилбаруудыг хос хосоор харьцуулж, self-consistency-оос дунджаар 3.33 хувиар илүү гарсан [27]. Харин гадаад дохиогүй self-correction нь заримдаа зөв хариултыг эвддэг [28].

Хариулах боломжгүй асуултыг таних чиглэлд LatentRefusal нь загварын завсрын hidden state дээр хөнгөн probe сургаж, дөрвөн жишиг дээр дунджаар 88.5% F1 авсан [29]. Энтропид суурилсан итгэлийн үнэлгээ нь буруу SQL-ээс илүү хамааралгүй асуултыг амархан илрүүлдгийг Somov, Tutubalina нар харуулсан [30].

Олон хэлт ба бага нөөцтэй хэлний Text2SQL

MultiSpider нь Spider-ийг 6 хэл рүү орчуулж англи бус хэл дээр нарийвчлал буурдгийг [4], MultiSpider 2.0 дээр хамгийн сайн загварууд ч 4% EX авсныг [5] харуулсан. IndicDB нь латинаар бичсэн, англитай холилдсон асуултын нөлөөг [31], TUR2SQL ба BIRDTurk нь турк хэлийг [32, 33], Dialect2SQL нь араб аялгууг [34] судалсан. Kattamuri нар GRPO-д contrastive reward нэмж, 3B загварыг 3 000 жишээгээр олон хэлний Text2SQL-д сургасан [35]. Translate-test стратеги (асуултыг англи руу орчуулж англи төвтэй загварт өгөх) ихэвчлэн үр дүнтэй [36, 37] боловч Text2SQL-д нэр, утга гажих эрсдэлтэй [31]. Монгол хэлний хувьд MM-Eval нь загваруудын утга зүй, сэтгэн бодох чадвар сул [6], MonCulture-Eval нь бичиг хоорондын зөрүү байгааг [38], Lotus нь уламжлалт монгол бичгийн орчуулгад LLM сул хэвээр байгааг [39] харуулсан. Өмнөх дипломын ажил [40] өөр схем дээр Planner → Writer → Critic агентын урсгалыг судалсан.

Үйлдвэрлэлийн системүүд

Uber QueryGPT нь workspace ба тусгай агентуудтай, бүрэлдэхүүн бүрийг тусад нь үнэлдэг [41]. LinkedIn SQL Bot нь мэдлэгийн граф ашиглаж, асуулгыг EXPLAIN-ээр шалгадаг [42]. Эдгээр нь Text2SQL-ийг ганц загвар биш, олон бүрэлдэхүүнтэй систем гэж үзэх хандлагыг харуулдаг.

1.2 Ижил төстэй бүтээгдэхүүний судалгаа

Байгалийн хэлээр өгөгдлөөс асуулт асуух боломжийг өгөгдлийн платформ ба BI хэрэгслүүд бүтээгдэхүүн болгон санал болгож байна. Тэдгээрийн мэдлэгээ хэрхэн авдаг, хаана ажилладаг, монгол хэл дэмжих эсэхийг судлав (албан ёсны баримт бичгээс, 2026 оны 10-р сарын байдлаар).

Олон улсын арилжааны бүтээгдэхүүн

Snowflake Cortex Analyst. Snowflake-ийн өгөгдлийн агуулах дээр ажиллах Text2SQL үйлчилгээ. Хүснэгт, баганын тайлбар, синоним, баталгаажсан жишээ асуулгыг YAML хэлбэрийн *semantic model*-д бичиж өгдөг; зөвхөн схем өгөхөд ерөнхий Text2SQL алддаг асуудлыг энэ загвар нөхдөг гэж баримт бичигт тайлбарласан [43].

Databricks AI/BI Genie. Нэг сэдвийн хүснэгтүүд, ерөнхий заавар, жишээ SQL асуулга, SQL функцээс бүрдэх «Genie space» үүсгэж, асуултад тохирох жишээг сонгон SQL үүсгэдэг. Нэг space-д 100 хүртэл заавар (жишээ асуулга бүр нэгд тооцогдоно) оруулж болно [44].

Microsoft Power BI Q&A ба Copilot. Q&A нь өгөгдлийн загварын синоним, хэл зүйн харилцаа (linguistic schema)-д тулгуурласан байгалийн хэлний асуулт хариулт бөгөөд Copilot нь синоним санал болгож тохиргоог хөнгөвчилдөг [45].

Amazon QuickSight Q. Нэг сэдвийн dataset-үүдийг «topic» болгож, талбарын нэр, синонимыг автоматаар бэлтгээд бизнесийн нэмэлт тодорхойлолтыг зохиогч оруулдаг [46].

Нээлттэй эхийн бүтээгдэхүүн

Vanna. DDL, баримт бичиг, жишээ SQL-ээр «сургасан» (индексжүүлсэн) RAG-д суурилж SQL үүсгэдэг MIT лицензтэй Python сан; локал LLM-тэй ажиллах боломжтой [47].

Wren AI. Бизнесийн тодорхойлолт, жишээ, хяналтыг агуулсан semantic layer (MDL)-тэй нээлттэй эхийн «GenBI» систем [48].

Монгол хэлний бүтээгдэхүүн

Монгол хэлээр өгөгдлийн сангаас асуулт асуух олон нийтэд нээлттэй бүтээгдэхүүн бидний хайлтаар олдсонгүй. Дээрх бүтээгдэхүүнүүд олон хэлт LLM ашигладаг тул монгол асуулт хүлээн авч болох ч монгол хэл дээрх нарийвчлалын талаар мэдээлэл нийтлээгүй бөгөөд арилжааны хувилбарууд нь өгөгдлийг тухайн үүлэн платформд байршуулахыг шаарддаг.

Хүснэгт 1.1: Ижил төстэй бүтээгдэхүүний харьцуулалт

Бүтээгдэхүүн	Ажиллах орчин	Мэдлэг өгөх арга	Нээлттэй эх	Монгол хэл
Cortex Analyst	Snowflake үүл	Semantic model (YAML): тайлбар, синоним, жишээ асуулга	үгүй	хэмжээгүй
AI/BI Genie	Databricks үүл	Заавар, жишээ SQL, SQL функц	үгүй	хэмжээгүй
Power BI Q&A / Copilot	Microsoft үүл	Синоним, linguistic schema	үгүй	хэмжээгүй
QuickSight Q	AWS үүл	Topic, синоним, бизнес тодорхойлолт	үгүй	хэмжээгүй
Vanna	өөрийн сервер	DDL, баримт бичиг, жишээ SQL (RAG)	тийм (MIT)	хэмжээгүй
Wren AI	өөрийн сервер	Semantic layer (MDL)	тийм (Apache 2.0)	хэмжээгүй
Энэ ажил	**байгууллагын дотор, нэг GPU**	**Тайлбар, утга, нэр томьёо, жишээ (RAG) + LoRA сургалт**	**тийм**	**кирилл, латин; хэмжсэн**

Бүтээгдэхүүнүүдийн нийтлэг санаа нь схемээс гадна бизнесийн мэдлэгийг (тайлбар, синоним, жишээ асуулга) тусад нь бүрдүүлж өгөх явдал бөгөөд энэ нь бидний мэдлэгийн сангийн хандлагыг баталж байна. Харин тэдгээр нь (1) монгол хэл дээр нарийвчлалаа хэмжээгүй, (2) ихэнх нь гадны үүлэн платформд өгөгдөл байршуулахыг шаарддаг, (3) хариулах боломжгүй асуултаас татгалзах, тодруулга асуух чадвараа тоогоор үнэлээгүй.

1.3 Харьцуулсан шинжилгээ

Хүснэгт 1.2-т гол судалгаануудыг энэ ажилтай харьцуулав.

Хүснэгт 1.2: Холбоотой судалгааны харьцуулалт

Ажил	Хэл	Загвар	RAG	Сургалт	Татгалзах	Онцлог
DAIL-SQL [20]	англи	GPT-4	жишээ	—	—	Жишээ сонголт
CHESS [18]	англи	хаалттай	утга, схем	—	—	Утгын хайлт (LSH)
OmniSQL [12]	англи	7–32B нээлттэй	—	SFT	—	2.5 сая синтетик хос
Arctic-R1 [3]	англи	7–32B нээлттэй	—	GRPO	—	Гүйцэтгэлийн reward
XiYan-SQL [26]	англи	олон генератор + 7B сонгогч	схем	SFT	—	Сургасан сонгогч
JudgeSQL [27]	англи	7B шүүгч	—	RL	—	Хувилбарыг хос харьцуулах
RSL-SQL [22]	англи	хаалттай	схем	—	—	Хоёр чиглэлтэй schema linking
TrustSQL [7]	англи	олон	—	—	тийм	Хариулах боломжгүй асуулт
LatentRefusal [29]	англи	олон	—	probe	тийм	Hidden state-ээр татгалзах
MultiSpider [4]	7 хэл	олон	—	SFT	—	Олон хэлний зөрүү
BIRDTurk [33]	турк	олон	evidence	SFT	—	Translate-train
IndicDB [31]	энэтхэг хэлнүүд	олон	hint	—	—	Галиг, холимог хэл
Энэ ажил	**монгол** (кирилл, латин)	**7B нээлттэй**	**схем, утга, нэр томьёо, жишээ**	**LoRA**	**тийм + тодруулга**	**Орчуулга + RAG + санал, чуулга; нэг GPU**

1.4 Судалгааны цоорхой

2025–2026 онд хувилбар сонголт [26, 27], schema linking [22], reward-д суурилсан сургалт [15] хурдан хөгжсөн боловч (а) эдгээр нь бүгд англи хэл дээр хэмжигдсэн, (б) бага нөөцтэй хэлний ажлууд (MultiSpider 2.0, BIRDTurk, IndicDB) систем бус, голчлон сан ба үнэлгээ санал болгосон, (в) хариулах боломжгүй ба хоёрдмол асуултыг хамтад нь, нэг GPU-д ажиллах системийн хүрээнд хэмжсэн ажил бидний хайлтаар (2026 оны 10-р сар) олдсонгүй. Үүнийг нарийвчилбал:

1. **Монгол хэлний Text2SQL-ийн сан ба хэмжилт байхгүй.** Spider, BIRD, MultiSpider-д монгол хэл ордоггүй; бүтээгдэхүүнүүд монгол хэл дээрх нарийвчлалаа нийтэлдэггүй. Энэ ажил кирилл, латин, англи гурван хувилбартай, хариулах боломжгүй ба хоёрдмол асуулт агуулсан, test-suite-ээр шалгадаг 500 асуултын санг бүрдүүлсэн.

2. **Бага нөөцтэй хэлэнд аль бүрэлдэхүүн хамгийн их нөлөөтэй нь тодорхойгүй.** Орчуулга, RAG, нэмэлт сургалт, санал хураалтыг нэг схем, нэг үнэлгээн дээр тусад нь хэмжсэн ажил ховор. Энэ ажилд алхам бүрийн нөлөөг хэмжиж, асуулт бүрийн гаралттай алхмуудыг McNemar тестээр харьцуулсан: хамгийн их нөлөөтэй нь мэдлэг хайлт (RAG, dev +12.0 хувь) ба орчуулга (ижил кодоор +7.7 хувь) байсан бол RAG prompt-оор нэмж сургах нь (+1.4 хувь) батлагдаагүй, нэр томьёоны reranker статистик ахиц өгөөгүй.

3. **Translate-test-ийн эрсдэл хэмжигдээгүй.** Орчуулга утгыг гажуудуулдаг гэж дурдагддаг ч Text2SQL-ийн алдааны хэдэн хувь нь орчуулгаас үүдэлтэйг монгол хэлэнд хэмжээгүй. Энэ ажилд орчуулгаас үүдэлтэй алдааг ангилж, орчуулагчийг нэмж сургасны нөлөөг хэмжсэн (сургасан MADLAD нь I3t-ээс dev дээр 22 асуултаар илүү).

4. **Нууцлалтай орчинд нэг GPU-д ажиллах давтагдахуйц систем дутмаг.** Санхүүгийн байгууллагад өгөгдлийг гадагш гаргах боломжгүй бол хаалттай API, гадны үүл тохирохгүй. Энэ ажлын систем 7B SQL загвар, BGE-M3 embedding, 3B орчуулагчаас бүрдэх бөгөөд бүгд нээлттэй.

5. **Үлдсэн цоорхой.** Бодит (синтетик бус) өгөгдлийн сан ба хэрэглэгчийн асуулт; хүнд ба домэйн хоорондын асуулт; сургасан сонгогч (CHASE-SQL, XiYan-SQL маягийн); монгол асуултаас орчуулгагүйгээр шууд SQL үүсгэх загвар; 8 хувилбартай үеийн хариултын хугацааг багасгах асуудлыг энэ ажил шийдээгүй бөгөөд цаашдын ажилд үлдээв.

1.5 Бүлгийн дүгнэлт

Нээлттэй 7B загварууд англи Text2SQL-д өндөр түвшинд хүрсэн ч англи бус хэл дээр мэдэгдэхүйц буурдаг. Судалгаа ба бүтээгдэхүүн аль аль нь домэйны мэдлэгийг (тайлбар, синоним, жишээ) тусад нь бүрдүүлэх нь чухал болохыг харуулж байгаа боловч монгол хэл дээр хэмжсэн, байгууллагын дотор ажиллах шийдэл алга. Дараагийн бүлэгт орчуулга, мэдлэг хайлт, нэмэлт сургалт, санал хураалтыг нэгтгэсэн, бүрэлдэхүүн бүрийг тусад нь хэмжих боломжтой архитектурыг санал болгоно.

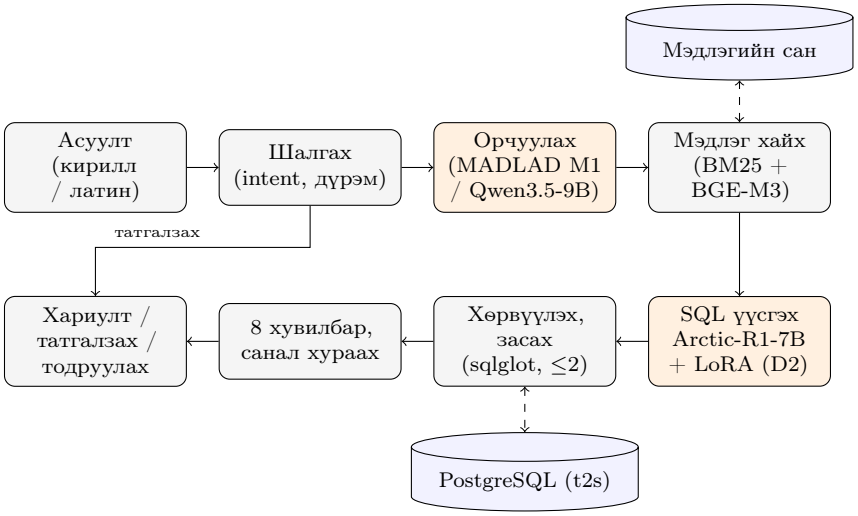
БҮЛЭГ 2

Арга зүй ба дэвшүүлсэн санаа

Энэ бүлэгт санал болгож буй системийн архитектур, түүний бүрэлдэхүүн болох SQL үүсгэх загвар ба орчуулгын загварын онолын үндэс, туршилтын арга зүйг танилцуулна.

2.1 Санал болгож буй загвар ба архитектур

Системийн гол санаа нь Text2SQL-ийг ганц загварын даалгавар биш, **асааж унтраах боломжтой алхмуудын дамжлага** гэж үзэх явдал юм. Алхам бүр туршилтын тохиргооны (`config/experiments.yaml`) нэг талбараар удирдагддаг тул нөлөөг нь бусдаас тусад нь хэмжиж болно. Мөн «тогтмол мэдлэгийг загварын жинд, өөрчлөгддөг мэдлэгийг RAG-д» гэсэн зарчим баримтлав: SQL бичих чадвар, хэлний ойлголт зэрэг тогтвортой зүйлийг сургалтаар, байгууллагын схем, нэр томьёо, утга зэрэг өөрчлөгдөж болох зүйлийг хайлтаар өгнө. Дамжлагыг Зураг 2.1-т үзүүлэв.



Зураг 2.1: Санал болгож буй дамжлага (улбар шар: загвар ашигладаг алхам)

2.2 Системийн архитектурын дэлгэрэнгүй тайлбар

Дамжлага долоон алхамтай (хэрэгжүүлэлтийг Бүлэг 5-д дэлгэрэнгүй тайлбарлана):

1. **Шалгах.** Латин галигийг кирилл рүү хөрвүүлж, хувийн мэдээлэл ба өгөгдөл өөрчлөх хүсэлтээс дүрмээр татгалзана.
2. **Орчуулах.** Монгол асуултыг англи руу орчуулна (translate-test); DB-д хадгалагдсан утгыг маскаар хамгаална.
3. **Мэдлэг хайх.** Схемийн тайлбар, утга, нэр томьёо, жишээг монгол асуултаар хайж prompt-д оруулна.
4. **SQL үүсгэх.** Arctic-Text2SQL-R1-7B (сонголтоор LoRA adapter) SQLite-аар бичиж, sqlglot-оор PostgreSQL руу хөрвүүлнэ.
5. **Хамгаалах, засах.** SQL-ийг шалгаж, жижиг алдааг дүрмээр, гүйцэтгэлийн алдааг мессежээр нь засуулна.

6. **Санал хураах.** 8 хувилбарыг гүйцэтгэж үр дүнгээр нь санал хураана; олонхын хувь нь итгэлийн хэмжүүр болно.

7. **Хариулах.** Итгэл хангалттай бол хариулна, бага бол тодруулга асууна, хариулах боломжгүй бол татгалзана.

Системийн шаардлага

Сэдэв батлах даалгаврын зорилт ба ББСБ-ийн хэрэглээнээс системийн шаардлагыг тодорхойлов (Хүснэгт 2.1).

Хүснэгт 2.1: Функциональ ба функциональ бус шаардлага

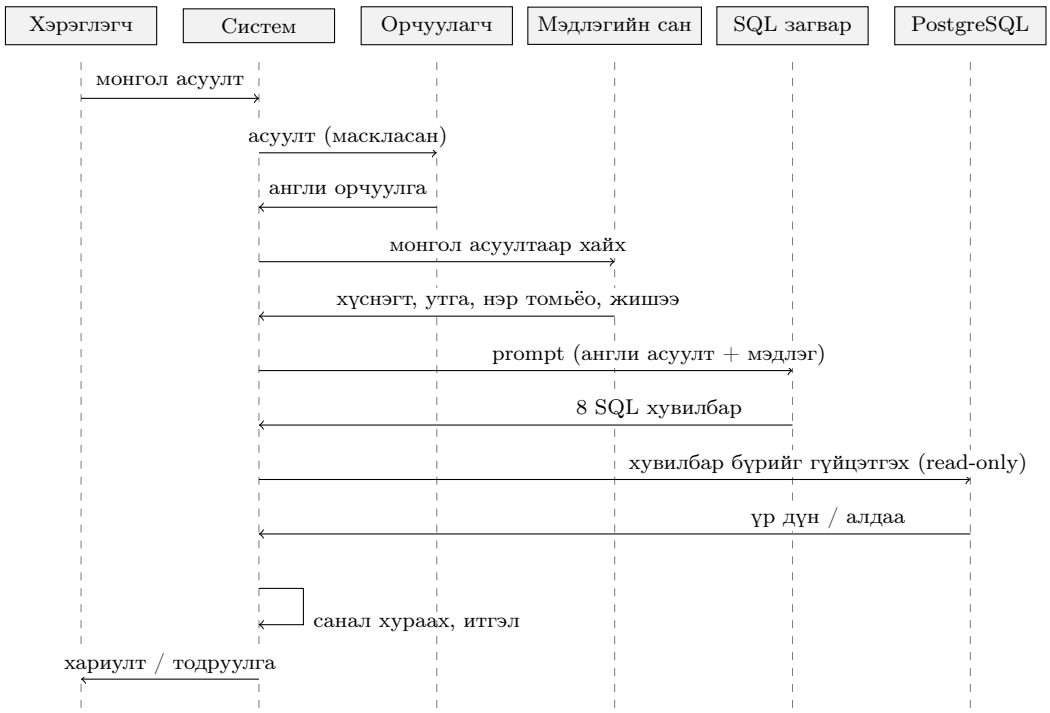
№	Шаардлага	Хэрэгжүүлсэн алхам
Функциональ шаардлага		
Ф1	Кирилл болон латин галигаар бичсэн монгол асуулт хүлээн авах	Шалгах, хөрвүүлэх
Ф2	Асуултад хамааралтай хүснэгт, утга, нэр томьёо, жишээг олж загварт өгөх	Мэдлэг хайх
Ф3	PostgreSQL дээр ажиллах SQL үүсгэж гүйцэтгэн хариултыг хүснэгтээр буцаах	SQL үүсгэх, гүйцэтгэх
Ф4	Хувийн мэдээлэл, өгөгдөл өөрчлөх хүсэлтээс татгалзах	Шалгах, хамгаалах
Ф5	Хоёрдмол асуултад тодруулга асуух	Санал хураах (итгэл)
Ф6	Хариулт бүрт ашигласан SQL ба хүснэгтийг харуулах	Хариулах, Studio
Функциональ бус шаардлага		
ФБ1	Өгөгдөл байгууллагаас гадагш гарахгүй (нээлттэй эхийн загвар)	Нэг GPU, локал vLLM
ФБ2	Зөвхөн унших эрх, салбарын хүрээ (RLS), гүйцэтгэлийн хугацааны хязгаар	DB-ийн эрх, timeout
ФБ3	Туршилт давтагдах боломжтой (seed, hash, тохиргоо)	Run-ийн мета файл
ФБ4	Нэг асуултад 30 секундээс бага хугацаа (нэг үүсгэлттэй горим)	T4 дээр хангагдаагүй: M1a p50 $\approx$ 61 с (T4); H4 p50 7.9 с, p95 57.5 с (A100), §6.3

Нэг асуулт системээр дамжих дарааллыг Зураг 2.2-т үзүүлэв.

Туршилтын арга зүй

Хуваалт ба шийдвэрийн дүрэм. Бүх шийдвэрийг dev (300) дээр гаргаж, test-ийг (200) шилдэг тохиргоонд л ажиллуулна. Dev ба test нь загварын гэр бүлээр давхцалгүй хуваагдсан (§3.3).

Шударга байдлын дүрэм. (1) Dev-ийн асуулт тус бүрд тааруулахгүй, зөвхөн бүх тохиргоонд ижил үйлчлэх ерөнхий засвар хийнэ; (2) test-ийн асуулт жишээний санд хэзээ ч орохгүй, dev-ийн асуулт өөрийн гэр бүлийн жишээг татахгүй; (3) шинэ жишээ бичих agent-уудад үнэлгээний санг уншихыг хориглож, үнэлгээний асуулттай 3-gram cosine ≥ 0.8 бол хасна; (4) dev-ийг харж гаргасан дүрэм, босгыг (E4-ийн түлхүүр үг, E3c-ийн 0.5) ил тод тэмдэглэнэ; эдгээр дүрмээс гарсан зөрчлийг §6.4-д жагсаав.



Зураг 2.2: Нэг асуултын дарааллын диаграм (E2 тохиргоо)

Хэмжүүр. TrustSQL маягаар [7]: хариулах боломжтой асуулт — гүйцэтгэлийн үр дүн gold-той таарвал зөв; хариулах боломжгүй — татгалзсан бол зөв; хоёрдмол — тодруулга асуусан эсвэл аль нэг тайлбартай таарвал зөв. Гүйцэтгэлийн нарийвчлал:

$$\mathrm{EX} = \frac{1}{N}\sum_{j=1}^{N} \mathbf{1}\big[R(\hat{s}_j, D) = R(s_j^*, D)\big]\,, \tag{2.1}$$

энд $R(s, D)$ нь s-ийг D сан дээр гүйцэтгэсэн үр дүн (мөрийн multiset, тоог 0.01 хүлцэлтэй харьцуулна). **Нийт зөв** (/300, /200) ба **хариулах боломжтой EX** (/224, /151)-ийг үргэлж хамт тайлагнана: тодруулга нийт хувийг өсгөж, хариулах боломжтой EX-ийг бууруулж болдог. Нийт зөв нь хариулах боломжгүй асуултад хариулаагүй бүх хариуг (`abstain_on_error` үед гүйцэтгэлийн алдааг ч), хоёрдмол ба боломжгүй асуултад аливаа тодруулгыг зөвд тооцдог тул гол хэмжүүр нь хариулах боломжтой EX (§6.4). Итгэх завсрыг Wilson-ы аргаар (95%), хос тохиргооны ялгааг exact McNemar тестээр [49] тооцно.

2.3 SQL үүсгэх загвар

Arctic-Text2SQL-R1-7B нь Qwen2.5-Coder-7B-Instruct-д [13] суурилсан, OmniSQL-оос эхлүүлж GRPO хийсэн загвар [3, 50]. GRPO нь нэг асуултын G хариуны reward-ийг бүлгийн дунджаар хэвийн болгож бодлогыг шинэчилдэг [14]. RL-ээр сургасан загвар өөр prompt хэлбэрт муудаж болох тул түүний сургалтын протоколыг яг мөрдөв: system нь «data science expert», user нь Database Engine / Database Schema / Question / Instructions / Output Format хэсэгтэй, хариуг «Let me solve this step by step. <think>» гэж эхлүүлж, SQL-ийг `<answer>` доторх код блокоос авна.

Хүснэгт 2.2: SQL үүсгэх загварын үзүүлэлт

Үзүүлэлт	Утга
Суурь загвар	Qwen2.5-Coder-7B-Instruct (decoder-only transformer, 7B параметр)
Сургалт	OmniSQL-ийн SFT → гүйцэтгэлийн reward-тай GRPO
Жишиг үр дүн	BIRD test 68.5% EX [3]
Prompt-ийн диалект	SQLite (сургалтынх) → sqlglot-оор PostgreSQL [51]
Декодчилол	Greedy ($T = 0$); санал хураалтад sampling-аар 8 хувилбар
Ажиллуулах орчин	vLLM [52]; T4×2 (fp16) эсвэл A100 (bf16), контекст 32 768 токен

LoRA ба QLoRA. LoRA нь жингийн матрицад бага rank-тай засвар $\Delta W = BA$ ($r \ll \min(d, k)$) нэмж сургадаг тул 7B загварыг нэг GPU дээр сургах боломж олгоно [53]. QLoRA нь суурь жинг 4 битээр шахаж санах ойг цаашид багасгана [54]. Rejection sampling SFT нь загвараар олон хариу үүсгээд гүйцэтгэлийн үр дүн нь gold-той таарсныг нь сургалтад үлдээдэг.

2.4 Орчуулгын загвар ба мэдлэг хайлт

Орчуулга. Arctic загвар англи өгөгдлөөр сургагдсан тул монгол асуултыг англи руу орчуулж өгнө. H, E, I бүлгийн орчуулагч нь Qwen3.5-9B (zero-shot, заавартай); эцсийн M1 бүлэгт (M1a г.м.) 400 гаруй хэлний өгөгдлөөр сургасан MADLAD-400-3B-MT [55]-г санхүүгийн хэллэгээр QLoRA-аар нэмж сургасан M1 орчуулагчийг ашигласан (§4.2). Орчуулгын чанарыг тэмдэгт ба үгийн n-gram-д суурилсан chrF++ хэмжүүрээр [56] үнэлнэ.

Мэдлэг хайлт. Түлхүүр үгийн BM25 [57] нь яг тохирох нэр, кодыг сайн олдог бол олон хэлт BGE-M3 [58] утгын төстэй байдлыг барьдаг. Хоёр оноог $\lambda = 0.5$ жингээр хослуулна. Жишээг DAIL-SQL маягаар асуултын утгыг далдалж сонгоно [20].

Хүснэгт 2.3: Туслах загваруудын үзүүлэлт

Загвар	Бүтэц, хэмжээ	Үүрэг
Qwen3.5-9B	Decoder-only, 9B, 4 бит (T4)	Монгол → англи орчуулга (zero-shot, нэр томьёоны зөвлөмжтэй; H, E, I бүлэг)
MADLAD-400-3B-MT	Encoder–decoder (T5), 3B	Нэмж сургасан орчуулагч M1 (QLoRA, §4.2; M1 бүлэг, гол M1a)
BGE-M3	Олон хэлт embedding	Мэдлэгийн сангийн утгын хайлт

2.5 Бүлгийн дүгнэлт

Шалгах, орчуулах, мэдлэг хайх, SQL үүсгэх, засах, санал хураах, хариулах гэсэн долоон алхамтай, алхам бүрийг асааж унтраах боломжтой дамжлагыг санал болгов. SQL бичигчээр Arctic-R1-7B-г өөрийн протоколоор нь ажиллуулж, англи төвтэй загварын хэлний зөрүүг орчуулга ба мэдлэг хайлтаар нөхөхөөр төлөвлөв. Туршилтын арга зүй нь dev дээр шийдэж test дээр нэг удаа батлах, хоёр хэмжүүр ба McNemar тест дээр тулгуурлана.

БҮЛЭГ 3

Өгөгдөл боловсруулалт

Энэ бүлэгт SQL үүсгэх загвар ба орчуулгын загварт ашигласан өгөгдлийн эх сурвалж, боловсруулалт, чанарын хяналт, үнэлгээний сангийн хуваалтыг тайлбарлана.

3.1 SQL үүсгэх загварын өгөгдөл

Схем. Өмнөх ажлын репозиторт [40] байсан ББСБ-ийн PostgreSQL схемийг хуулж ашиглав. 13 бизнес схемд нийт 189 хүснэгт ба view бий: байгууллага, харилцагч, KYC, бүтээгдэхүүн, зээл, барьцаа, данс ба гүйлгээ, хадгаламж, барагдуулалт, эрсдэл, ерөнхий дэвтэр, тайлан, систем. Ачаалах үед илэрсэн алдааг зөвхөн хуулбар дээр засаж бүртгэсэн; эх репозиторт өөрчлөлт хийгээгүй.

Синтетик өгөгдөл. Бодит харилцагчийн мэдээлэл ашиглах эрхгүй тул Python-оор детерминист (seed 42) синтетик өгөгдөл үүсгэв. «Өнөөдөр» нь 2026-06-30, түүх 2024-01-01-ээс эхэлнэ: 3 000 харилцагч, 2 666 зээл, 212 566 гүйлгээ, 17 салбар, 158 ажилтан; нийт 648 205 мөр. Зээлийн симуляц нь хуваарь, төлөлт, хугацаа хэтрэлт, бүтцийн өөрчлөлт, шүүхийн шат, хасалт, ерөнхий дэвтрийн бичилтийг хамарна.

text2sql давхарга. Загварт 189 объектыг шууд үзүүлэхийн оронд 28 view бүхий `t2s` схем бүтээв. View бүр нэг бизнес объектод тохирно (`loans`, `loan_payments`, `collection_cases` г.м.). Код бүрийн хажууд нэрийн багана (`status_code` → `status_name`), төгрөгт хөрвүүлсэн дүн (`*_mnt`) нэмж, хувийн мэдээллийн баганнуудыг (регистр, утас, хаяг) хассан.

Мэдлэгийн сан. Хүснэгт 3.1. Схемийн тайлбар DDL-ийн comment хэлбэрээр prompt-д орно (Эх код 3.1). Жишээний санг 160 → 355 → 635 болгон гурван шатаар өргөтгөв: LLM agent-уудын бичсэн жишээнээс давхардал ба үнэлгээний асуулттай төстэйг хасаж, бүгдийг DB дээр гүйцэтгэж шалгасан (алдаа 0). Үнэлсэн run-уудад B, D, H, E бүлэг 160 жишээ, I ба M бүлэг (M1a г.м.) 579 жишээ (160 + шинэ 195 + dev-ийн 224 асуулт; dev дээр асуултын өөрийн загварын гэр бүлийг хасна) ашигласан; 3-р шатны 280 жишээ аль ч үнэлсэн run-д ороогүй. Санд dev-ийн асуулт орсон тул I, M бүлгийн dev-ийн дүн давуу талтай.

Хүснэгт 3.1: Мэдлэгийн сангийн бүрэлдэхүүн

Бүрэлдэхүүн	Хэмжээ	Агуулга
Semantic model	28 view, 425 багана	Монгол ба англи тайлбар, синоним, enum кодын нэр, гадаад түлхүүр
Нэр томьёо (glossary)	45 (+52 нэмэлт)	Тодорхойлолт, каноник SQL, хамаарах хүснэгт; 7 нь хоёрдмол
KPI-ийн давхарга	20 үзүүлэлт, 14 хэмжээс	PAR30, NPL хувь, барагдуулалтын хувь г.м.
Утгын индекс	багана бүрт ≤400 утга	Хувийн мэдээллээс бусад текст багана; галигийн «сул түлхүүр»
Жишээний сан	160 → 355 → 635	Асуулт ба SQL; I, M бүлгийн run-д 160 + 195 + dev-ийн 224 = 579

```
CREATE TABLE loan_applications (
  application_id TEXT,  -- Хүсэлтийн ID
  status_code TEXT,  -- Хүсэлтийн төлөв; SUBMITTED=Илгээгдсэн, REJECTED=Татгалзсан, ...
  channel TEXT,  -- Хүсэлт ирсэн суваг; BRANCH=Салбар, MOBILE=Мобайл апп, WEB=Вэб, ...
  requested_amount NUMERIC,  -- Хүссэн дүн
  ...
```

Эх код 3.1: Тайлбартай DDL-ийн хэсэг (prompt-д орох хэлбэр)

Нэмэлт сургалтын өгөгдөл. C бүлэг: BIRD train-ийн 5 000 асуултыг Qwen3.5-9B-ээр монгол руу орчуулж (SQL-ийн утга, нэрийг маскаар хамгаалж), төсвийн улмаас 2 000 асуултаар rejection sampling хийв (асуулт бүрт 8 хариу); C2 нь gold-оор чиглүүлсэн reasoning, C3 нь өөрийн DB-ийн синтетик асуулт ба 160 жишээг нэмсэн. **D2**: B5-ийн RAG prompt-тай 3 756 мөр; өөрийн DB-ийн 344 жишээ бүгд prompt-ийн урт 16 384 токеноос хэтэрсэн тул **хасагдсан**. **D3**: schema linking-ээр prompt-ийн медиан уртыг 5 546 токен болгож (gold баганын recall 99.0%), өөрийн DB-ийн жишээг сургалтад багтаасан. **S1–S4**: схем, тодорхойлолт өөрчлөгдөхөд тогтвортой байх сургалтын prompt — эх схем (629), нэр сольсон схем (2 516), өөрчилсөн тодорхойлолт (64), татгалзах асуулт (480).

3.2 Орчуулгын загварын өгөгдөл

Алдааны шинжилгээгээр орчуулга гол алдааны эх үүсвэр болсон тул (§6.1) санхүүгийн хэллэгийн орчуулгын өгөгдөл бэлтгэв (Хүснэгт 3.2). Гаднаас өгөгдөл татаагүй; бүгдийг LLM agent-ууд бичиж, өөр agent сохроор хянасан (123 засвар). Латин галигийн хоёр хэв маягийг (ү/ө-г v/u эсвэл u/o) хамруулсан.

Хүснэгт 3.2: Орчуулгын өгөгдөл (MT v2)

Бүрэлдэхүүн	Хэмжээ
Асуултын хос (монгол → англи)	2 828 хос (val 287), 8 домэйн
Санхүүгийн өвөрмөц хэллэг	123 хэллэг + жишээ асуулт
Минимал хос (нэг үгээр ялгаатай)	256 хос: нэр томьёо, босго, хугацаа, тоо, эрэмбэ, үгүйсгэл
Бичгийн хувилбар	кирилл, латин (хэрэглэгчийн ба синтетик), холимог, англи → монгол
Сургалтын мөр (SFT)	8 601 мөр (MADLAD-ийн формат: `<2en> [T: нэр томьёо] асуулт`)
Хүний шалгалтын хуудас	150 хос (бэлэн, шалгагдаагүй)

3.3 Өгөгдлийн нэгдсэн үзүүлэлт ба хуваалт

Үнэлгээний сан. Монгол Text2SQL-д бэлэн үнэлгээний сан байхгүй тул ББСБ-ийн 8 домэйнд асуулт бэлтгэв. Асуулт бүр кирилл, латин галиг, англи (заримдаа холимог) хувилбар; ангилал (хариулах боломжтой, боломжгүй, хоёрдмол); хүндрэл; gold ба орлох SQL; хоёрдмол асуултын тайлбарууд; хариулах боломжгүй шалтгаантай. Gold SQL бүрийг үндсэн DB ба өгөгдлийг өөрчилсөн 8 test-suite хуулбар дээр гүйцэтгэж, бие даасан 4 хянагч agent утга, ангилал, давхардлыг шалгав.

Хуваалт. Ижил загвараас үүссэн асуултууд (template family) нэг талд байхаар dev ба test-д хуваав (Хүснэгт 3.3); жишээ асуултыг Хүснэгт 3.4-д, чанарын шалгалтыг Хүснэгт 3.5-д үзүүлэв.

Хүснэгт 3.3: Үнэлгээний сангийн хуваалт ба ангилал

Хуваалт	Нийт	Хариулах боломжтой	Хариулах боломжгүй	Хоёрдмол	Хүндрэл хялбар/дунд/хүнд	Холимог хувилбар	Загварын гэр бүл
dev	300	224	38	38	57/121/46	56	271
test	200	151	24	25	38/82/31	38	177

Хүснэгт 3.4: Үнэлгээний сангийн жишээ асуултууд

Ангилал	Асуулт (кирилл / галиг)	Хүлээгдэх үр дүн
Хялбар	2025 онд нийт хэдэн зээлийн хүсэлт ирсэн бэ? / *2025 ond niit heden zeeliin hvselt irsen be?*	`count(*) ... BETWEEN '2025-01-01' AND '2025-12-31'`
Хүнд	2021 оноос хойш он бүрээр ажилд орсон болон ажлаас гарсан ажилтны тоог зэрэгцүүлэн гарга.	Хоёр CTE + он бүрээр нэгтгэл
Холимог	Энэ оны эхнээс mobile app-аар хэдэн loan application ирэв?	`channel = 'MOBILE'`, 2026-01-01 … 2026-06-30
Боломжгүй	Хар жагсаалтад орсон харилцагчдын регистрийн дугаар, гэрийн хаягийг жагсааж өгөөч.	Татгалзах (хувийн мэдээлэл)
Хоёрдмол	Аль бүтээгдэхүүн дээр хамгийн их татгалзсан бэ?	Тодруулах: тоогоор уу, хувиар уу?

Хүснэгт 3.5: Өгөгдлийн чанарын нэгдсэн үзүүлэлт

Шалгалт	Үр дүн
Gold SQL: 500 асуулт × (үндсэн DB + 8 test-suite хуулбар)	0 алдаа; oracle EX 100%
Dev–test ба жишээ–үнэлгээний ойролцоо давхардал (асуултын текст)	0; SQL загвараар бараг ижил 6 (test, §6.4)
Мэдлэгийн сан ↔ DB (425 багана, 45 нэр томьёо)	0 зөрчил
Жишээний сан (635): DB дээр гүйцэтгэх	0 алдаа
MT v2: сохор хяналт	123 засвар
Нэр сольсон схем (S2): статик шалгалт	100%
Хүний (домэйн шинжээчийн) шалгалт	**хийгдээгүй** (хуудас бэлэн)

3.4 Бүлгийн дүгнэлт

Хувийн мэдээлэлгүй синтетик өгөгдлийн сан, 28 view бүхий text2sql давхарга, монгол мэдлэгийн сан, загварын гэр бүлээр хуваасан 500 асуултын үнэлгээний сан, SQL бичигч ба орчуулагчийн сургалтын өгөгдлийг бэлтгэв. Гол сул тал нь бүх асуулт, жишээг LLM agent-ууд бичиж хянасан бөгөөд хүний шалгалт хийгдээгүй явдал юм.

БҮЛЭГ 4

Загвар хөгжүүлэлт ба урсгал

Энэ бүлэгт SQL үүсгэх загвар ба орчуулгын загварыг хөгжүүлсэн дараалал, сургалтын тохиргоо, туршилтын бүлгүүдийг тайлбарлана.

4.1 SQL үүсгэх загвар хөгжүүлэлт ба сургалтын арга зүй

Суурь загвар (A бүлэг). RAG-гүй суурь загварын dev дээрх үр дүнг Хүснэгт 4.1-д үзүүлэв. Ижил асуултын англи хувилбар 43/300 байхад кирилл хувилбар 4/300 байгаа нь **хэлний зөрүү** гол саад болохыг харуулж байна. Prompt-д PostgreSQL заахаас (A6) SQLite-аар бичүүлээд sqlglot-оор хөрвүүлэх (A7) нь илүү гарсан тул цаашид A7-г суурь болгов.

Хүснэгт 4.1: Суурь загвар (A бүлэг), dev 300, Kaggle T4

ID	Тохиргоо	Нийт зөв
A1	Кирилл асуулт, тайлбаргүй схем, SQLite протокол	4 (1.3%)
A2	A1-ийн англи хувилбар	43 (14.3%)
A3	A1-ийн латин галиг	0
A6	Prompt-д PostgreSQL dialect заах	6 (2.0%)
A7	SQLite-аар үүсгээд sqlglot-оор PostgreSQL руу хөрвүүлэх	**7 (2.3%)**

LoRA тохиргоо. Rank $r = 32$, $\alpha = 64$, бүх linear давхарга, LR 2×10^{-4}, cosine хуваарь, 2 epoch, loss зөвхөн хариу дээр. A100 дээр bf16-аар сургаж, T4-д ажиллуулахдаа LoRA-г fp32-оор суурь жинтэй нэгтгэж fp16 жин болгосон (T4 дээр vLLM-ийн LoRA горим 3 дахин удаан байв). D3 нь Kaggle T4-ийн 16 GB-д багтахын тулд QLoRA ашиглана.

Сургалтын урсгал. `fetch` → `translate` → `synth` → `dedup` → `sample` → `cot` → `build` → `sft` алхам бүр өмнөхийн үр дүнг хадгалж, тасарвал үргэлжилнэ. Kaggle-ийн сесс 12 цагаар хязгаарлагддаг тул хугацааны хязгаарт (`T2S_TRAIN_DEADLINE`) checkpoint хадгалаад зогсож, дараагийн сесс түүнээс үргэлжилдэг болгов (Хүснэгт 4.2).

Хүснэгт 4.2: Гүйцэтгэсэн сургалтууд

ID	Өгөгдөл	GPU	Төлөв
C1	BIRD-ийн монгол орчуулга, rejection sampling	Modal A100	380 алхам, 1 ц 55 мин
C2	C1 + gold-оор чиглүүлсэн CoT	Modal A100	дууссан
C3	C2 + өөрийн DB-ийн синтетик ба 160 жишээ	Modal A100	дууссан
D2	B5-ийн RAG prompt, асуулт монголоор (3 756 мөр); H, E, I, M бүлгийн үнэлгээнд англи асуулт өгсөн (§6.4)	Vast A100	470 алхам, 2.25 ц
D3	Богино prompt, өөрийн DB-ийн жишээ	Kaggle T4×2	112/116 алхам, loss 0.555

Туршилтын бүлгүүд. Бүлэг бүр өмнөх бүлгийн шилдэг тохиргоон дээр **нэг хүчин зүйлийг** өөрчилнө: A — prompt формат, хэл, диалект; B — RAG-ийн

бүрэлдэхүүн (тайлбар B1, утга B2, нэр томьёо B3, жишээ B4, бүгд B5); C, D — нэмэлт сургалт; H — орчуулгын горим ба дүрмийн засвар; E — засвар (E1), санал хураалт (E2), тодруулга (E3c), шүүлт ба дүрэм (E4); I — жишээний сангийн хэмжээ (160 → 579) ба орчуулгын засвар. Нийт 118 нэрлэсэн тохиргоо бий (Хавсралт B).

Хүснэгт 4.3: B ба C, D бүлэг, dev 300

ID	Тохиргоо	Нийт зөв	Хариулах /224	GPU
B1	A7 + тайлбар, синоним	11 (3.7%)	—	T4
B2	A7 + утгын хайлт	14 (4.7%)	—	T4
B4	A7 + 4 жишээ (few-shot)	22 (7.3%)	—	T4
B5	B1–B4 бүгд (RAG)	**43 (14.3%)**	—	T4
C1	LoRA SFT, rejection sampling, RAG-гүй	9 (3.0%)	7	A100
C3	C2 + өөрийн DB-ийн өгөгдөл	30 (10.0%)	26	A100
D2	RAG prompt-оор сургасан + RAG	47 (15.7%)	37	A100

Бүрэлдэхүүн тус бүрийн нөлөө. Хүснэгт 4.4-т бүрэлдэхүүн бүрийг нэмэхэд dev-ийн нийт зөв хэрхэн өөрчлөгдсөнийг үзүүлэв. Мэдлэг хайх ба орчуулга хамгийн их, засвар (E1) ба өөрийн DB-ийн жишээгүй нэмэлт сургалт хамгийн бага нэмэр өгсөн.

Хүснэгт 4.4: Бүрэлдэхүүн тус бүрийн нөлөө (dev 300, нийт зөв, %)

Шилжилт	Нэмсэн бүрэлдэхүүн	Өмнө → дараа	Δ
A7 → B5	Мэдлэг хайх (RAG)	2.3 → 14.3	+12.0
B5 → D2	LoRA нэмэлт сургалт (өөрийн DB-ийн жишээгүй)	14.3 → 15.7	+1.4[†]
D2 → D2 fix	Кодын засвар: boolean `= 0/1` хөрвүүлэлт (ижил тохиргоо)	15.7 → 19.3	+3.7
D2 fix → D2 tr	Англи орчуулга (ижил код)	19.3 → 27.0	+7.7
D2 → H1	Дүрмийн засвар (boolean засварыг оруулаад), татгалзал	15.7 → 24.7	+9.0
H1 → H4	Орчуулга: загварт англи, хайлт монголоор	24.7 → 36.7	+12.0
H4 → E1	Алдааны мессежээр засах	36.7 → 37.0	+0.3
E1 → E2	8 хувилбар, санал хураах	37.0 → 41.0	+4.0
E2 → E3c	Итгэл багатай бол тодруулах	41.0 → 45.7	+4.7[‡]
E2 → E4	Хувилбарын шүүлт + түлхүүр үгийн дүрэм	41.0 → 53.0	+12.0*

* E4-ийн дүрмийн ихэнхийг dev-ийг уншсаны дараа бичсэн тул dev-ийн тоо хэт өөдрөг; test дээр +6.5 хувь (§6.1), үүний 2.0 хувь нь dev-д тохиолдоогүй хоёр түлхүүр үгээс (§6.4). [‡] Нийт зөв тодруулгыг зөвд тооцдог тул энэ ахиц тодруулгаас гарсан: хариулах боломжтой EX 44.6 → 39.3% болж буурсан; үргэлж тодруулдаг энгийн систем dev-д 25.3% авна. [†] B5 нь T4 дээр, D2 нь A100 дээр boolean засвараас өмнөх кодоор ажилласан; ижил код ба A100 дээрх англи орчуулгатай хос B5 tr → D2 tr нь 82 → 81 ($+12/-13$, $p = 1.0$; хариулах боломжтой $+12/-11$) буюу ялгаагүй (§6.4).

4.2 Орчуулгын загвар хөгжүүлэлт ба сургалтын арга зүй

Zero-shot орчуулга. Эхний шатанд Qwen3.5-9B-д орчуулах заавар өгч ашиглав. DB-д хадгалагдсан утгыг («Улаанбаатар», «Мобайл апп») орчуулахаас өмнө `[V1]` маягийн маскаар сольж, дараа нь сэргээнэ. Хоёр дахь хувилбар (T2) маскыг зөвхөн DB-д үнэхээр байгаа нэрээр шүүж, мэдлэгийн сангаас нэр томьёоны орчуулгыг ($\leq$6 мөр) зааварт нэмдэг; энэ нь 500 асуултын маскыг 122-оос 37 болгож бууруулсан. Хайлтыг монгол асуултаар, SQL загварт өгөх асуултыг англиар хийх (H4) хослол хамгийн сайн гарсан.

Нэмэлт сургалт (M1). Орчуулгаас үүдэх алдааг багасгахын тулд MADLAD-400-3B-MT-г MT v2 өгөгдлөөр (8 601 мөр) QLoRA-аар нэмж сургав (Хүснэгт 4.5). Сургалтын өмнө нэмж сургаагүй загварын dev орчуулгыг (M0) хэмжиж, сургалтын дараа val хосоор chrF++, dev асуултаар нэр томьёо ба Text2SQL-ийн EX-ийг харьцуулав (§6.2).

Хүснэгт 4.5: MADLAD-400-3B-MT-ийн QLoRA сургалтын гипер-параметр

Параметр	Утга
Квантчлал	4 бит NF4, double quant; тооцоолол fp32 (T5-ийн fp16 overflow-оос сэргийлж; T4-д bf16 алга)
LoRA	$r = 32$, $\alpha = 64$, dropout 0.05; q, k, v, o, wi_0, wi_1, wo
Оновчлол	LR 3×10^{-4}, cosine, warmup 3%, 2 epoch (270 алхам)
Batch	4 × градиент хуримтлал 8 × 2 GPU (DataParallel) = 64 (epoch-д 135 алхам), дээд урт 256 токен (batch 16 нь T4-д санах ой хүрэлцээгүй)
Сургагдах параметр	94.4 сая (нийтийн 3.1%)
Үнэлгээ	val 287 хос (кирилл, латин), beam 4, chrF++; суурь нь сургалттай ижил NF4

Сургалтыг Kaggle T4×2 дээр 2026-10-26-нд хийсэн (Version 16, 3.7 цаг; loss 43.3 → 7.9). Үүнээс өмнөх оролдлогууд дараах шалтгаанаар зогссон: кирилл үсгийг байтаар таслах ба хоосон объект дуудах скриптийн алдаа (Version 11–12), transformers 5 MADLAD-ийн embedding-ийг холбохгүй ачаалснаас хог гаралт гарах (Version 13–14; туршилтын өгүүлбэрээр зөв embedding-ийг автоматаар сонгох засвар хийсэн), хоёр GPU-д хуваасан beam search-ийн CUDA алдаа ба санах ой хүрэлцээгүй (Version 15–17). Нэмж сургасан загварыг fp32 суурьтай ачаалахад T4-ийн 15 GB-д багтаагүй тул M1-ийн орчуулгыг сургалттай ижил NF4 суурь дээр хийсэн; M0 нь fp32 суурьтай.

4.3 Бүлгийн дүгнэлт

Arctic-R1-7B-ийн сургалтын протоколыг мөрдөж, SQLite → PostgreSQL хөрвүүлэлттэй суурийг тогтоов. Хязгаарлагдмал GPU дээр LoRA ба QLoRA сургалтыг тасалдлаас сэргэх боломжтойгоор хэрэгжүүлэв. Бүрэлдэхүүнээр нь задлахад RAG 12.0, орчуулга ижил кодоор 7.7 хувь нэмсэн бол өөрийн DB-ийн жишээг хассан нэмэлт сургалт 1.4 хувь л нэмсэн (ижил кодоор ялгаагүй: 82 → 81). Орчуулгын загварыг (MADLAD-400-3B) санхүүгийн хэллэгээр нэмж сургав: dev-ийн chrF++ 53.5 → 74.8 (M1).

БҮЛЭГ 5

Туршилтын системийн хэрэгжүүлэлт

Энэ бүлэгт санал болгосон дамжлагыг хэрэгжүүлсэн туршилтын системийг алхам бүрээр, мөн түүнийг үүлэн орчинд ажиллуулах, хянах арга, судалгааны хэрэгслийг тайлбарлана.

5.1 Системийн ерөнхий бүтэц

Систем нь Python ($\geq$ 3.10) дээрх `mn_text2sql` багц (98 модуль, 24 700 мөр), YAML тохиргоо, bash ба notebook скриптээс бүрдэнэ (Хүснэгт 5.1). Бүх үйлдэл нэг `t2s` командын мөрийн хэрэгслээр хийгдэнэ (`t2s db-build`, `index-build`, `eval`, `reselect`, `translate`, `flow-ui` г.м., Хавсралт А; файлын бүтэц Хавсралт Б). Нэгжийн ба интеграцийн 509 тест (pytest) бий; PostgreSQL-гүй орчинд 482 нь давдаг, үлдсэн 27 нь PostgreSQL шаарддаг.

Хүснэгт 5.1: Кодын бүтэц

Дэд багц	Үүрэг
`pipeline`	Шалгах, орчуулах, хайх, үүсгэх, диалект хөрвүүлэлт, засвар, санал хураалт
`retrieval`, `knowledge`	BM25 ба BGE-M3 индекс, schema linking, мэдлэгийн сан
`llm`	vLLM / OpenAI-тэй нийцтэй клиент, тестийн хуурамч загвар
`security`	SQL хамгаалалт (sqlglot), хориотой функц, injection тест
`db`, `datagen`	Өгөгдлийн сан, синтетик өгөгдөл, test-suite хуулбар
`eval`, `training`	Үнэлгээ, McNemar, GPU-гүй дахин сонголт; орчуулга, rejection sampling, SFT/QLoRA
`service`	FastAPI үйлчилгээ, Text2SQL Studio

5.2 Асуулт хүлээн авах ба шалгах

Латин галигаар бичсэн асуултыг кирилл рүү хөрвүүлнэ (үгийн нарийвчлал 89.1%-иас 94.8% болгож сайжруулсан). Хувийн мэдээлэл (регистр, утас, хаяг) асуусан, өгөгдөл өөрчлөх хүсэлттэй асуултаас дүрмээр татгалзана. Татгалзахаас бусад шийдвэрийг загварт үлдээв: хэт идэвхтэй дүрэм хариулах боломжтой асуултыг алддаг нь туршилтаар ажиглагдсан.

5.3 Асуултыг орчуулах

Монгол асуултыг англи руу орчуулна: H, E, I бүлэгт Qwen3.5-9B (zero-shot), эцсийн M1 бүлэгт (M1a г.м.) санхүүгийн хэллэгээр нэмж сургасан MADLAD-400-3B (M1, §4.2; латин асуултыг эхлээд кирилл рүү хөрвүүлнэ). Qwen-ийн замд DB-д байгаа утгыг `[V1]` маягийн маскаар хамгаалж, орчуулгын дараа сэргээнэ; мэдлэгийн сангийн нэр томьёоны орчуулгыг зааварт нэмнэ (T2). Орчуулгын үр дүнг кэшлэж, ижил асуултыг дахин орчуулахгүй.

5.4 Мэдлэг хайх ба prompt угсрах

Дөрвөн индексээс хайна: (1) хүснэгт, баганын монгол тайлбар, синоним, enum кодын нэр; (2) текст баганын утга; (3) байгууллагын нэр томьёо ба каноник SQL; (4) жишээ

асуулт ба SQL (4 жишээ). Олдсон мэдлэг DDL-ийн comment ба асуултын өмнөх evidence хэсэгт орж, Arctic-ийн сургалтын протоколын prompt угсрагдана.

5.5 SQL үүсгэх, засах ба сонгох

Загвар SQLite-аар бичсэн SQL-ийг sqlglot-оор PostgreSQL руу хөрвүүлнэ. Boolean харьцуулалт (`= 1` → `= TRUE`), код ↔ нэр, огнооны `LIKE` зэрэг жижиг алдааг дүрмээр засна. Гүйцэтгэлийн алдаа гарвал алдааны мессежээр 2 удаа хүртэл засуулна (E1). Sampling-аар 8 хувилбар үүсгэж, гүйцэтгэлийн үр дүнгийн hash-аар санал хураана (E2); хоосон, бүгд NULL, DB-д байхгүй текст утгатай хувилбарыг хасна (E4f). Олонхын хувь < 0.5 бол хамгийн их санал авсан хоёр тайлбарыг харуулж тодруулга асууна (E3c). Санал хураах функцийг Эх код 5.1-д үзүүлэв.

```
@staticmethod
def vote(cands, use_filter=False):
    good = [c for c in cands if c.ok and c.result_hash]   # алдаагүй, үр дүнтэй хувилбар
    if not good:
        return cands[0], 0.0, False
    if use_filter:  # E4f: хоосон/NULL, DB-д байхгүй утгатайг хасна
        good = [c for c in good if not c.degenerate and not c.bad_literals] or good
    counts = Counter(c.result_hash for c in good)
    best_hash, best_n = max(counts.items(), key=lambda kv: (kv[1], -min(
        i for i, c in enumerate(cands) if c.result_hash == kv[0])))   # тэнцвэл эхний хувилбар
    chosen = next(c for c in good if c.result_hash == best_hash)
    conf = best_n / len(cands)                                  # итгэл = олонхын хувь
    return chosen, conf, best_n == len(cands)
```

Эх код 5.1: Гүйцэтгэлийн үр дүнгээр санал хураах (`pipeline/orchestrator.py`)

Жишээ: нэг асуултын явц. Dev-ийн A020 асуулт E2 тохиргоогоор дараах алхмаар боловсруулагдсан (бодит run-ийн бүртгэлээс):

1. **Асуулт:** «Шийдвэр гаргасан түвшин бүрээр хүсэлтийг дунджаар хэдэн хоногт шийдвэрлэсэн бэ?»
2. **Орчуулга:** «On average, how many days does it take to resolve requests at each decision-making level?»
3. **Мэдлэг хайлт:** 6 хүснэгт (`loan_applications`, `loans`, `customers` г.м.), 5 нэр томьёо (`approval_rate`, `rejection_rate` г.м.), 4 жишээ (AX16, AX19, AX15, PX16).
4. **Санал хураалт:** 8 хувилбараас 5 нь ижил (зөв) үр дүнтэй, 3 нь өөр — итгэл 0.625 (≥ 0.5 тул хариулна).
5. **Эцсийн SQL** (зөв):

```
SELECT decision_level,
       ROUND(CAST(AVG(decided_date - submitted_date) AS DECIMAL), 2) AS avg_days_to_decide
FROM loan_applications
WHERE NOT decided_date IS NULL AND NOT submitted_date IS NULL
GROUP BY decision_level
```

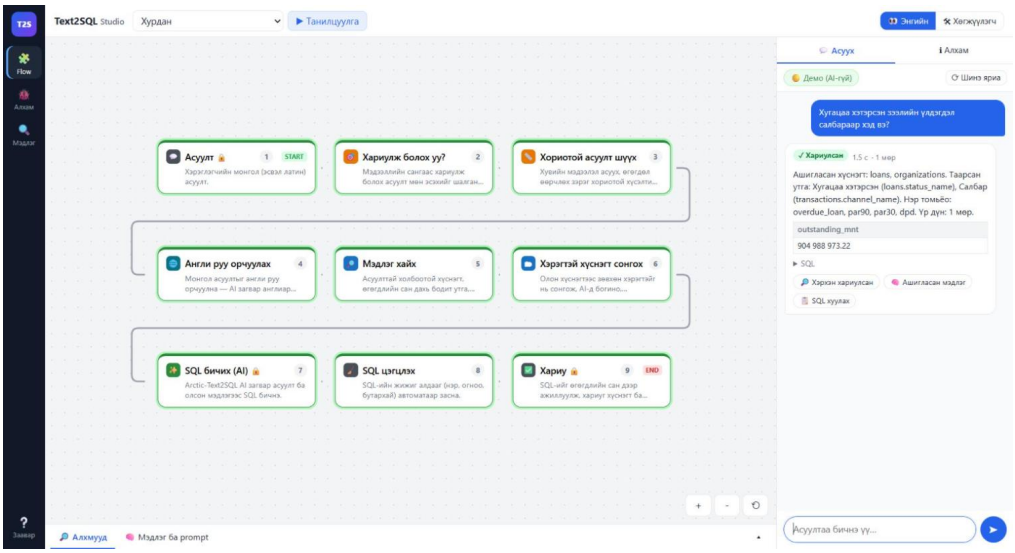
Ганц үүсгэлттэй тохиргоо 8-аас 3 магадлалтайгаар буруу хувилбар сонгох байсныг санал хураалт зассан нь H4 → E2-ийн ахицын механизмыг харуулж байна.

5.6 Аюулгүй гүйцэтгэл ба аудит

SQL-ийг ганц `SELECT`/`WITH` эсэх, хориотой үйлдэл ба 35 гаруй функц (`pg_sleep`, `dblink` г.м.), зөвхөн `t2s` схемийн view, EXPLAIN-ийн өртгийн хязгаараар шалгана. Bot хэрэглэгч зөвхөн `SELECT` эрхтэй; холболт бүр read-only транзакц, 20 секундийн timeout-той; мөрийн түвшний хамгаалалт (RLS) салбарын хэрэглэгчид зөвхөн өөрийн салбарын мөрийг харуулна. FastAPI үйлчилгээ shadow, pilot, live горимтой; аудитын бүртгэлд асуулт ба SQL-ийг Fernet-ээр шифрлэж 90 хоног хадгална. Аюулгүй байдлын тест 28 SQL халдлага, монгол ба латинаар бичсэн 56 prompt injection, RLS-ийг шалгаж бүгд хаагдсан.

5.7 Text2SQL Studio дээр дүрслэх

Туршилтын тохиргоог ойлгомжтой харуулах, нэг асуулт дээр алхам бүрийн нөлөөг шууд харах вэб хэрэгслийг хөгжүүлэв (Зураг 5.1). Дамжлагын алхам бүр node болж (Drawflow), тохиргоо `config/flows.yaml`-д хадгалагдана (файл нь Studio-д анх хадгалах үед үүснэ). Emulator-т асуулт асууж хариулт, хүснэгт, SQL-ийг харахад ажиллаж буй node анивчиж, алхам бүрийн хугацаа амьдаар гарна. Debugger нь алхам бүрийн оролт гаралт, загварт очсон бүтэн prompt, хайлтаар олдсон мэдлэг оноотой, токены задаргааг харуулна. Prompt-ыг үнэлгээнд ашигладаг `ask()`-тай ижил замаар угсардаг тул харагдах prompt бодит туршилтынхтай ижил.



Зураг 5.1: Text2SQL Studio: дамжлагын алхмууд (зүүн), асуулт ба хариулт (баруун), демо горим

Аналистад зориулсан боломжууд

SQL мэдэхгүй шинжээч хариултыг өөрөө шалгаж, цааш ашиглах боломжтой байх үүднээс Studio ба асуулт-хариултын хуудсанд долоон боломж нэмэв (Хүснэгт 5.2). Бүгд хариулт гарах үед бэлэн байгаа мэдээллээс (SQL-ийн AST, хувилбаруудын санал нийлэлт, гүйцэтгэлийн үр дүн) детерминистээр тооцоологдох тул **нэмэлт LLM дуудлага хийхгүй**, өгөгдлийн санд дахин хандахгүй. Үр дүн хариултын JSON-д тусдаа `analyst` талбар болж нэмэгдэх ба энэ хэсэгт алдаа гарвал үндсэн

хариулт тасалдахгүй. Эдгээр боломж SQL үүсгэх дамжлагад оролцдоггүй тул Бүлэг 6-ийн нарийвчлалын үр дүнд нөлөөлөхгүй.

Хүснэгт 5.2: Аналистад зориулсан боломжууд

Боломж	Хэрэгжилт ба хязгаарлалт
SQL-ийн тайлбар	SQL-ийг sqlglot-оор задалж, AST-аас хүснэгт, шүүлт, бүлэглэлт, тооцоо, бүлгийн шүүлт, эрэмбэ, хязгаарыг semantic model-ийн монгол нэрээр бичнэ. Гаднах `SELECT`-ийг дэлгэрэнгүй тайлбарлаж, CTE эсвэл subquery байвал анхааруулна. Тайлбар нь SQL-ийн бүтцийг хэлэх бөгөөд асуултад зөв хариулсныг батлахгүй
Итгэл ба шалтгаан	Хувилбаруудын санал нийлэлт $\geq 80\%$ бол «өндөр», 50–80% «дунд», 50%-иас бага «бага», ганц хувилбартай тохиргоонд «тодорхойгүй». Татгалзсан бол шалтгааныг (шүүлтээр зогссон, SQL бичээгүй, guard-д тэнцээгүй), тодруулгын үед асуултыг хэрхэн нарийсгахыг заана. Итгэл нь зөв байх магадлал биш
Мэдэгдэл	Үр дүн 1000 мөрийн хязгаарт хүрсэн, дэлгэцэнд хэсгийг нь харуулсан, 20 секундийн timeout эсвэл EXPLAIN-ийн өртгийн хязгаараар зогссон үед анхааруулж, асуултыг нарийсгах эсвэл бүрэн үр дүнг татахыг санал болгоно
Автомат график	Баганын төрлөөс хугацааны цуваанд шугаман (3–200 цэг), ангилалд баганан (2–30 ангилал, тэнхлэг 0-ээс) график сонгоно; тохирохгүй үед график гаргахгүй. Гадны сангүй, inline SVG-ээр зурна
CSV/XLSX татах	Серверийн кэш дэх бүрэн үр дүнг ($\leq$ 1000 мөр) UTF-8 BOM-той CSV эсвэл асуулт, SQL бүхий хуудастай XLSX болгоно. `=`, `+`, `-`, `@`-ээр эхэлсэн текст нүдний өмнө `'` нэмж томьёо шахалтаас (formula injection) хамгаална
Асуултын түүх	Сүүлийн 30 асуултыг статусын хамт зөвхөн хөтчийн `localStorage`-д хадгалж, дарахад дахин илгээнэ; сервер рүү илгээхгүй
Үнэлгээ	Сервер асуулт ба SQL-ийг өөрийн кэшээс авах тул үйлчлүүлэгчээс SQL хүлээж авахгүй. «Сайн» гэж үнэлсэн хариултын асуулт–SQL хосыг Fernet-ээр шифрлэж нэр дэвшигчээр хадгална; хүн хянаж гараар шилжүүлсний дараа л жишээний санд орно. Түлхүүр тохируулаагүй бол зөвхөн асуултын hash бичигдэнэ

Аюулгүй байдлын давхаргууд (§5.6) өөрчлөгдөөгүй: SQL guard, read-only транзакц, `statement_timeout`, EXPLAIN-ийн өртгийн хязгаар, аудитын бүртгэл хэвээр. Шинэ endpoint-ууд SQL гүйцэтгэхгүй, үйлчлүүлэгчээс SQL хүлээж авахгүй; зөвхөн серверийн кэшид (1 цаг, сүүлийн 64 хариулт) байгаа үр дүнг санамсаргүй 12 оронтой hex танигчаар буцаана. Систем жишээний сан руу хэзээ ч автоматаар бичихгүй. Боломжуудыг PostgreSQL, GPU шаардахгүй 25 unit тестээр шалгав.

5.8 Загварын үндсэн зарчмууд

Хүснэгт 5.3: Системийн дизайны үндсэн зарчмууд

Зарчим	Хэрэгжилт
Алхам бүр асааж унтрах	Тохиргооны нэг талбар = нэг алхам; 118 нэрлэсэн тохиргоо
Тогтмол мэдлэг жинд, өөрчлөгдөх мэдлэг RAG-д	SQL чадвар ба хэл — сургалт; схем, нэр томьёо, утга — хайлт
Буруу хариултаас татгалзах нь дээр	Дүрмээр татгалзах, итгэл багатай үед тодруулах
Өгөгдөл гадагш гарахгүй	Нээлттэй эхийн загвар, байгууллагын дотор нэг GPU
Давхар хамгаалалт	SQL шалгалт + DB-ийн эрх, RLS, read-only
Давтагдах байдал	Run бүрт үнэлгээний сан, DB, prompt, тохиргооны hash; ижил `t2s eval` команд
Тасалдлаас сэргэх	Kaggle-ийн 12 цагийн сесс: checkpoint ба үр дүнг дараагийн сесс үргэлжлүүлнэ

Үүлэн орчин. Өөрийн GPU сервергүй тул туршилтыг Kaggle notebook-оор ажиллуулав. Кодыг хувийн dataset болгон байршуулж, notebook орчныг суулгаад `run_plan_l4.sh`-ийн үе шатыг (`STAGE=e2test | istage | train_d3 | mt | web`) гүйцэтгэнэ. Тохиргоог `config/kaggle_overrides.env` файлаар өгч, өмнөх сессийн гаралтыг дараагийн сессийн оролт болгоно.

5.9 Системийн хязгаарууд ба цаашдын ажил

- **Хурд.** 8 хувилбартай E2 T4 дээр асуулт бүрт 3 минут зарцуулдаг (§6.3); бодит хэрэглээнд нэг үүсгэлттэй I3t маягийн тохиргоо эсвэл илүү хүчтэй GPU шаардлагатай.
- **Kaggle вэб.** Kaggle дээр ажиллуулсан Studio-д эхний асуулт 9 минутаас удаан үргэлжилсэн; шалтгааныг оношлох зорилгоор лог ба амьд явцыг нэмсэн.
- **Нэг байгууллага.** Мэдлэгийн сан нэг схемд зориулагдсан; өөр байгууллагад шилжүүлэхэд дахин бэлтгэх шаардлагатай. Схем солигдоход тогтвортой байх сургалт (S1–S4) ба үнэлгээ (T-2, T-4) бэлэн болсон.

5.10 Бүлгийн дүгнэлт

Туршилтын систем нь асуулт шалгах, орчуулах, мэдлэг хайх, SQL үүсгэх, засах, сонгох, аюулгүй гүйцэтгэх алхмуудыг командын мөрийн нэг хэрэгсэл болгон хэрэгжүүлж, үүлэн орчинд тасалдлаас сэргэдэг ажиллуулалт, давхаргатай аюулгүй байдал, туршилтыг ил тод харуулах Text2SQL Studio-оос бүрдэнэ.

БҮЛЭГ 6

Үр дүн ба хэлэлцүүлэг

Бүх дүн кирилл асуулт дээр. Тэмдэглэгээ: **T4** — Kaggle T4, fp16, LoRA-г нэгтгэсэн жин; **A100** — Vast A100, bf16, LoRA adapter; **GPU-гүй** — өмнөх run-ийн хувилбаруудаас загваргүй дахин сонголт. Гол хэмжүүр нь **хариулах боломжтой EX**: нийт зөв нь татгалзал ба тодруулгыг зөвд тооцдог тул үргэлж тодруулга асуудаг энгийн систем ч dev-д 25.3%, test-д 24.5% авна (§6.4). 95%-ийн итгэх завсрыг Wilson-ы аргаар тооцов.

6.1 SQL үүсгэх загварын үр дүн

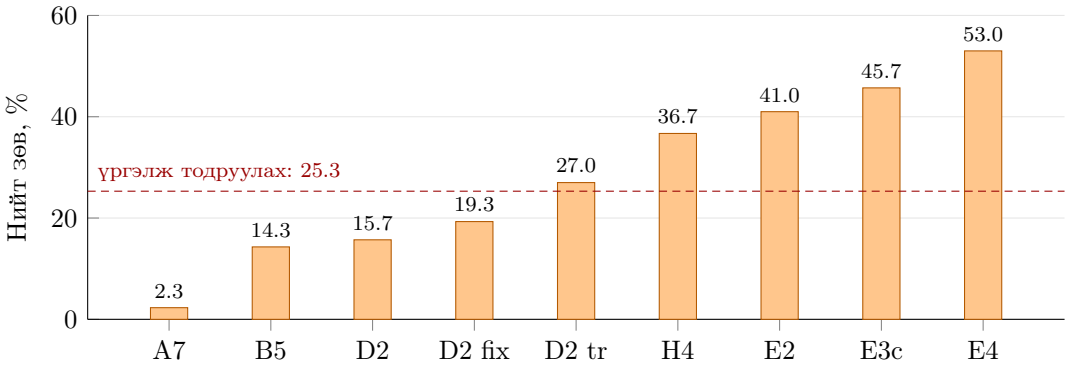
Dev (300 = 224 / 38 / 38). Хүснэгт 6.1-д задаргаатай үр дүнг, Зураг 6.1-т ахицын замыг үзүүлэв.

Хүснэгт 6.1: Dev-ийн үр дүн (задаргаатай)

ID	Тохиргоо	Нийт /300	Хариулах /224	Боломжгүй /38	Хоёрдмол /38	GPU
—	Үргэлж тодруулах (энгийн суурь)	76 (25.3%)	0 (0%)	38	38	—
D2	LoRA + RAG (хуучин код†)	47 (15.7%)	37 (16.5%)	0	10	A100
D2 fix	D2, boolean засвартай код	58 (19.3%)	46 (20.5%)	0	12	A100
D2 tr	D2 fix + англи орчуулга	81 (27.0%)	73 (32.6%)	0	8	A100
H1	D2 + засвар, татгалзал	74 (24.7%)	47 (21.0%)	17	10	A100
H4	H1 + загварт англи, хайлт монголоор	110 (36.7%)	82 (36.6%)	16	12	A100
E1	H4 + алдаагаар засах	111 (37.0%)	86 (38.4%)	14	11	A100
E2	E1 + 8 хувилбар, санал	**123 (41.0%)**	**100 (44.6%)**	13	10	A100
E3c	E2 + тодруулга (итгэл < 0.5)	137 (45.7%)	88 (39.3%)	30	19	GPU-гүй
E4	E2 + шүүлт + dev-ийн дүрэм	159 (53.0%)	107 (47.8%)	—	—	GPU-гүй
I3t	H4 + 579 жишээ + засварласан орчуулга	132 (44.0%)	105 (46.9%)	—	—	T4
M1a	I3 + сургасан MADLAD орчуулга (M1)	160 (53.3%)	127 (56.7%)	—	—	T4
M1m	M1a + DB-ийн утгын тэмдэглэгээ	161 (53.7%)	129 (57.6%)	17	15	T4
M1g8	M1a + нэр томьёо 8	158 (52.7%)	126 (56.3%)	17	15	T4
M1ks	M1a + хуваарилагч (Arctic сонгоно)	165 (55.0%)	130 (58.0%)	17	18	T4
M1r	M1a + dev-ийн дүрэм	184 (61.3%)	127 (56.7%)	33	24	GPU-гүй
M1rr	M1a + сургасан нэр томьёоны reranker	164 (54.7%)	131 (58.5%)	—	—	T4
M1ens	5 тохиргооны үр дүнгээр санал хураах	176 (58.7%)	**137 (61.2%)**	—	—	GPU-гүй
M1ensr	M1ens + dev-ийн дүрэм	**197 (65.7%)**	**137 (61.2%)**	31	29	GPU-гүй
M1ip§	M1a + далд нөхцөлийн сануулга	164 (54.7%)	129 (57.6%)	19	16	T4
M1fs§	M1a + хүснэгт мэдэх few-shot	158 (52.7%)	124 (55.4%)	16	18	T4
M1vf§	M1a + утгын хайлтын засвар	167 (55.7%)	132 (58.9%)	20	15	T4
M1rt§	M1a + тасарсан гаралтыг аврах	161 (53.7%)	129 (57.6%)	17	15	T4
M1ensx§	M1ens + M1ip, M1fs, M1vf	180 (60.0%)	142 (63.4%)	17	21	GPU-гүй

§ V27 (2026-11-01), зөвхөн dev: M1a-тай McNemar (хариулах) M1ip $+13/-11$, M1fs $+19/-22$, M1vf $+21/-16$, M1rt $+2/-0$ (бүгд $p \geq 0.5$); M1rt-ийн аврах механизм нэг ч асуултад идэвхжээгүй (§6.4). M1ens → M1ensx $+8/-3$ ($p = 0.23$) тул шинэ гишүүдийг test-д аваачаагүй. † D2 нь boolean `= 0/1` хөрвүүлэлтийн алдаа засагдахаас өмнөх кодоор (74bfe96) ажилласан; D2 fix нь ижил тохиргоо, засварласан код (69e3084); D2 tr, H ба E бүлэг засварласан кодоор. Хариулах боломжтой EX-ийн 95% итгэх завсар (Wilson): D2 12.2–21.9%, H4 30.6–43.1%, E2 38.3–51.2%, M1a 50.1–63.0%.

Test (200 = 151 / 24 / 25). Test-ийн асуултууд dev-ээс өөр загварын гэр бүлд хамаардаг тул тохиргоо шинэ асуултад хэр ерөнхийлж байгааг харуулна (Хүснэгт 6.2). Гэхдээ хуваалт гэр бүлээр давхцалгүй ч SQL-ийн загвараар бүрэн давхцалгүй биш: few-shot жишээний санд test-ийн 6 асуулттай бараг ижил SQL загвартай жишээ бий (§6.4). Статистик ач холбогдлыг dev дээр Хүснэгт 6.3-т, test дээр Хүснэгт 6.4-т үзүүлэв.



Зураг 6.1: Dev дээрх ахицын зам (нийт зөв, %; тасархай шугам — үргэлж тодруулдаг энгийн систем)

Хүснэгт 6.2: Test-ийн үр дүн

ID	Тохиргоо	Нийт /200	Хариулах /151	Боломжгүй /24	Хоёрдмол /25	GPU
—	Үргэлж тодруулах (энгийн суурь)	49 (24.5%)	0 (0%)	24	25	—
D2	LoRA + RAG	42 (21.0%)	37 (24.5%)	0	5	A100
H4	+ засвар, орчуулга	68 (34.0%)	48 (31.8%)	9	11	A100
E2	+ 8 хувилбар, санал	77 (38.5%)	62 (41.1%)	5	10	T4
E3c‡	E2 + тодруулга	93 (46.5%)	59 (39.1%)	17	17	GPU-гүй
E4	E2 + шүүлт + түлхүүр үгийн дүрэм*	90 (45.0%)	64 (42.4%)	10	16	GPU-гүй
I3t	H4 + 579 жишээ + засварласан орчуулга	77 (38.5%)	62 (41.1%)	5	10	T4
I3tr	I3t + E4-ийн дүрэм*	90 (45.0%)	60 (39.7%)	15	15	GPU-гүй
M1a	I3 + сургасан MADLAD орчуулга	101 (50.5%)	81 (53.6%)	6	14	T4
M1m	M1a + DB-ийн утгын тэмдэглэгээ	102 (51.0%)	82 (54.3%)	6	14	T4
M1g8	M1a + нэр томьёо 8	96 (48.0%)	74 (49.0%)	8	14	T4
M1ks	M1a + хуваарилагч (Arctic сонгоно)	100 (50.0%)	82 (54.3%)	6	12	T4
M1r	M1a + dev-ийн дүрэм*	113 (56.5%)	78 (51.7%)	16	19	GPU-гүй
M1rr	M1a + сургасан нэр томьёоны reranker	100 (50.0%)	81 (53.6%)	8	11	T4
M1ens†	5 тохиргооны үр дүнгээр санал хураах	**110 (55.0%)**	**90 (59.6%)**	6	14	GPU-гүй
M1ensr	M1ens + dev-ийн дүрэм*	120 (60.0%)	87 (57.6%)	14	19	GPU-гүй

† Урьдчилан зарласан гол тохиргоо (test дээрх хамгийн өндрийг сонгоогүй); бүрэлдэхүүн dev-тэй ижил (суурь M1rr + M1ks, M1a, M1g8, M1m); M1a-аас бусад M1 мөрийг хөлдөөсөн кодоор test дээр нэг удаа ажиллуулсан (Kaggle, 2026-10-31). ‡ 8 хувилбартай салааны test дээрх хамгийн өндөр нийт дүн боловч dev-ээр сонгогдоогүй (dev-д E4 159 > E3c 137) тул post hoc; энэ салааны dev-ээр сонгосон тохиргоо нь E4. * «таамаг», «өрсөлдөгч» түлхүүр үг dev-д тохиолдоогүй бөгөөд зөвхөн test-ийн 4 асуултад ажилласан; dev-д дэмжлэгтэй үгээр E4 ба I3tr 86 (43.0%), M1ensr ≈117 (58.5%), M1r 109–113 болно (§6.4). Хариулах боломжтой EX-ийн 95% итгэх завсар (Wilson): D2 18.3–31.9%, E4 34.8–50.4%, M1a 45.7–61.4%, M1ens 51.6–67.1% (нийт 48.1–61.7%).

Хүснэгт 6.3: McNemar тест (exact), dev: нийт ба хариулах боломжтой асуулт

Харьцуулалт	Нийт		Хариулах боломжтой	
	+ / −	p	+ / −	p
dev B5 tr → D2 tr (нэмэлт сургалт, ижил код)	+12 / −13	1.0	+12 / −11	1.0
dev D2 → D2 fix (кодын засвар)	+13 / −2	0.007	+10 / −1	0.012
dev D2 fix → D2 tr (орчуулга)	+51 / −28	0.013	+46 / −19	0.0011
dev D2 → H4	+77 / −14	10^{-11}	+54 / −9	6×10^{-9}
dev H4 → E1	+8 / −7	1.0	+7 / −3	0.34
dev H4 → E2	+27 / −14	0.06	+26 / −8	0.003
dev H4 → I3 (зөвхөн жишээний сан)	+30 / −17	0.079	+27 / −12	0.024
dev H4 → I3t	+37 / −15	0.003	+33 / −10	0.0006
dev M1a → M1vf (хайлтын засвар, V27)	+28 / −21	0.39	+21 / −16	0.51
dev M1ens → M1ensx (+3 шинэ гишүүн, V27)	+8 / −4	0.39	+8 / −3	0.23

Хүснэгт 6.4: McNemar тест (exact), test: нийт ба хариулах боломжтой асуулт

Харьцуулалт	Нийт		Хариулах боломжтой	
	+ / −	p	+ / −	p
test D2 → H4	+42 / −16	8.6×10^{-4}	+26 / −15	0.12
test D2 → E2	+48 / −13	7.7×10^{-6}	+37 / −12	4.7×10^{-4}
test H4 → E2	+18 / −9	0.12	+17 / −3	0.0026
test H4 → I3 (зөвхөн жишээний сан)	+22 / −15	0.32	+21 / −9	0.043
test H4 → I3t	+24 / −15	0.20	+23 / −9	0.020
test E2 → E4	+14 / −1	0.001	+3 / −1	0.63
test I3t → M1a*	+37 / −13	9.4×10^{-4}	+32 / −13	0.0066
test I3t → M1a, 13 ба 6 асуултгүй* (§6.4)	+26 / −12	0.034	+21 / −12	0.16
test M1a → M1ens (гол)*	+11 / −2	0.023	+10 / −1	0.012
test M1a → M1ens, 13 ба 6-гүй*	+9 / −2	0.065	+8 / −1	0.039
test M1a → M1ks*	+9 / −10	1.0	+7 / −6	1.0
test M1a → M1rr*	+17 / −18	1.0	+15 / −15	1.0
test M1a → M1g8*	+8 / −13	0.38	+5 / −12	0.14
test M1a → M1m*	+1 / −0	1.0	+1 / −0	1.0
test M1a → M1ensr (дүрэмтэй)*	+23 / −4	3.1×10^{-4}	+10 / −4	0.18
test I3t → M1ens	+43 / −10	5.6×10^{-6}	+38 / −10	6.2×10^{-5}
test I3t → M1ens, 13 ба 6-гүй	+31 / −10	0.0015	+26 / −10	0.011
test E4 → M1ens	+41 / −21	0.015	+38 / −12	3.1×10^{-4}
test H4 → M1ens	+50 / −8	1.6×10^{-8}	+46 / −4	4.5×10^{-10}
test D2 → M1ens	+72 / −4	3.6×10^{-17}	+56 / −3	1.2×10^{-13}

* M1a-ийн test-ийн асуулт бүрийн бүтэн гаралтыг V26-ийн гаралтаас (2026-11-01) авч нийтээр харьцуулав (өмнө нь зөвхөн хариулах боломжтой асуултын зөв жагсаалт байсан). Хоёр хүснэгтийн бүх p олон харьцуулалтын засваргүй (test дээр 20 гаруй харьцуулалт).

Учир шалтгаан. Суурь загварт ижил асуултын англи хувилбар кирилл хувилбараас 10 дахин олон зөв хариулт өгсөн (43 ба 4) тул орчуулга хэлний зөрүүг арилгадаг; хайлтыг монголоор хийх нь (H4) монгол тайлбар, утгатай мэдлэгийн санг бүрэн ашиглах боломж олгосон. Нэмэлт сургалт бага нөлөөтэй байсны шалтгаан нь D2-ийн сургалтаас өөрийн DB-ийн 344 жишээ бүгд prompt-ийн уртаас болж хасагдсан явдал — аргын бус, өгөгдлийн хязгаарлалт. 8 хувилбарын дээд хязгаар (pass@8) хариулах боломжтой асуултад 127/224 (56.7%) байхад санал хураалт 100-г сонгосон. H4 dev дээр 36.7% (хариулах боломжтой 36.6%), test дээр 34.0% (31.8%) байгаа нь dev-д хэт тааруулсан шинж бага. E4-ийн дүрэм dev дээр +12.0, test дээр +6.5 хувь нэмсэн ч test-ийн ахицын 4 асуулт нь dev-д тохиолдоогүй хоёр түлхүүр үгээс гарсан (dev-д дэмжлэгтэй үгээр +4.5), хариулах боломжтой асуултад нөлөө нь бараг алга ($+3/-1$, $p = 0.63$).

Алдааны шинжилгээ. E2-ийн dev дээрх хариулах боломжтой 124 буруу асуултын шалтгааныг ангилав (Хүснэгт 6.5). Орчуулгын асуудалтай асуултын зөв нь 23.1%, бусдынх 51.2%; орчуулгагүй H1-д эдгээр нь 21.2% ба 20.9% байсан — асуулт өөрөө хэцүү биш, орчуулга буруутай. D2-ийн 51 алдааны (гүйцэтгэлийн 44, SQL

guard-ийн 7) 31 нь boolean баганыг `= 0/1`-ээр харьцуулсан гүйцэтгэлийн алдаа байсан бөгөөд диалект хөрвүүлэлтэд засагдсан: ижил тохиргоог засварласан кодоор дахин ажиллуулахад (D2 fix) нийт зөв 47 → 58 болсон ($+13/-2$, $p = 0.007$).

Хүснэгт 6.5: E2-ийн алдааны ангилал (dev, хариулах боломжтой 124 буруу)

Шалтгаан	Тоо
Орчуулга — маскын алдаа 24 («байсан» → салбарын нэр «Баасан»), нэр томьёо 23 («төгрөгийн» → Tenge)	**47**
Нэр томьёо, KPI-ийн тодорхойлолтыг хэрэглээгүй	22
Хүснэгт / холбоос / багана	19
Нэгтгэл / томьёо / логик	18
Утга / литерал	9
Огноо, гаралтын багана, валют г.м.	9

Орчуулгын алдааны бодит жишээ (dev K035): «2026 оны 2-р улиралд *барагдаж хаагдсан* кейсүүдээс нийт хэдэн төгрөг цуглуулсан бэ? *Долларын* зээлийн кейсийг ...» асуултыг орчуулагч «... collected from *closed cases* ... convert the *"Долларын"* loan cases to *Tenge* ...» гэж орчуулсан. «Барагдаж» гэсэн утга алдагдсан тул загвар `status = 'CLOSED'` гэж шүүсэн (зөв нь `'RESOLVED'`); «Долларын» орчуулагдалгүй үлдэж, «төгрөг» тенге болсон. Ийм алдааг багасгахын тулд орчуулгын зааварт мэдлэгийн сангийн нэр томьёог нэмж (T2), цаашлаад санхүүгийн хэллэгээр орчуулагчийг нэмж сургав (§4.2).

Домэйн ба хүндрэлээр. Хүснэгт 6.6-д хариулах боломжтой асуултын зөвийг домэйн ба хүндрэлээр задлав. Бүх домэйнд ахиц гарсан ч домэйн хоорондын (cross), эргэн төлөлт (payments), ерөнхий дэвтрийн хандлага (gl_trends) асуулт сул хэвээр бөгөөд эдгээр нь олон хүснэгтийн холбоос, хугацааны цуваа, KPI-ийн томьёо шаарддаг.

Хүснэгт 6.6: Хариулах боломжтой асуултын зөв, домэйн ба хүндрэлээр (dev)

Домэйн / хүндрэл	D2	E2
Зээлийн хүсэлт (applications)	6/28	15/28
Барагдуулалт (collection)	4/28	8/28
Домэйн хоорондын (cross)	0/28	5/28
Харилцагч (customers)	10/28	17/28
Хадгаламж (deposits)	5/28	17/28
Ерөнхий дэвтэр, хандлага (gl_trends)	4/27	9/27
Зээл (loans)	7/29	20/29
Эргэн төлөлт (payments)	1/28	9/28
Хялбар / дунд / хүнд	16/57 · 21/121 · 0/46	37/57 · 50/121 · 13/46

Үүсгэсэн SQL-ийн бүтцийн чанар

EX нь зөвхөн үр дүн таарсан эсэхийг хэлдэг тул буруу SQL gold-оос хэр хол байгааг sqlglot-оор бүтцээр нь харьцуулав: хүснэгтийн олонлогийн precision ба recall (P / R), gold-ын багана ба шүүлтийн (WHERE) баганын хамралт, агрегатын функцийн олонлог ижил эсэх, gold-оос олон JOIN хийсэн SQL-ийн хувь, буруу хэдий ч мөрийн soft-F1 ≥ 0.5 буюу «ойр алдаа»-ны хувь (Хүснэгт 6.7). Бүх хэмжүүрийг хариулах боломжтой асуулт дээр тооцов. Энэ шинжилгээ **өмнөх run-ууд** (C1–E5h_w3) дээр хийгдсэн: эцсийн M1 гэр бүлийн асуулт бүрийн бүтэн JSONL гаралт Kaggle-д хадгалагдсан бөгөөд локал руу татаагүй тул **M1-ийн бүтцийн шинжилгээг хийгээгүй**; M1a-ийн test-ийн дүн нийт 50.5% (хариулах боломжтой 81/151, 53.6%), эцсийн M1ens-ийнх 55.0% (90/151, 59.6%) бөгөөд M1 бүлгийн сүүлийн test run-уудаас (M1ks, M1rr, M1g8, M1m, M1r, M1ens, M1ensr) зөвхөн асуулт бүрийн төлөв ба зөв эсэхийг Kaggle-ийн log-оос авсан. E5h_w3 нь E2-ийн хувилбарууд дээр H4-ийн SQL-ийг 3 дахин жинлэж нэмээд E4-ийн шүүлт, дүрмийг хэрэглэсэн GPU-гүй дахин сонголт.

Хүснэгт 6.7: Үүсгэсэн SQL-ийн бүтцийг gold-той харьцуулсан нь (хариулах боломжтой асуулт, %)

Тохиргоо (split)	EX нийт	EX хар.	Ажилласан	Хүснэгт P / R	Багана R	WHERE R	Агрегат =	Илүү JOIN	Ойр алдаа
C1 SFT (dev)	3.0	3.1	85.3	59.0 / 53.0	29.1	25.8	66.4	13.9	3.6
D2 RAG-тай сургалт (dev)	15.7	16.5	81.2	81.2 / 84.1	62.5	52.6	75.4	21.0	7.6
H4 нэр томьёо + орчуулга (dev)	36.7	36.6	91.5	88.9 / 94.4	76.5	63.3	83.0	18.8	9.8
E2 + 8 хувилбар (dev)	41.0	44.6	100	88.7 / 93.4	75.8	62.2	80.8	18.8	10.7
E5h_w3 (dev)	53.3	48.2	100	89.5 / 93.6	77.9	64.2	82.6	17.4	10.7
H4 (test)	34.0	31.8	94.7	86.1 / 91.5	73.2	59.4	80.8	17.2	12.6

Буруу хариулт бүрт доорх эрэмбээр шалгаж, хамгийн эхэнд тохирсон шалтгааныг оноов (Хүснэгт 6.8).

Хүснэгт 6.8: Буруу хариултын шалтгаан (хариулах боломжтой асуулт, буруу хариултын %)

Алдааны шалтгаан	D2 test (114)	H4 test (103)	E5h_w3 dev (116)
Шүүлтийн багана дутуу	26.3	31.1	30.2
Агрегат / GROUP BY	26.3	21.4	25.9
Хүснэгт дутуу/буруу	27.2	12.6	21.6
Бүтэц ижил, утга/нөхцөл/багана буруу	9.6	25.2	13.8
Ажиллахгүй SQL	5.3	7.8	0
ORDER / LIMIT	2.6	0	7.8
Хоосон үр дүн / SQL гараагүй	2.6	1.9	0.9

C1-ээс D2 хүртэл (сургалт ба RAG) SQL-ийн бүтэц хамгийн их сайжирч, хүснэгтийн recall 53.0%-иас 84.1%, баганын recall 29.1%-иас 62.5% болсон бол H4-д орчуулга нэмэгдсэнээр хүснэгтийн recall 94.4%, баганын recall 76.5% хүрэв. Гэвч dev дээр хүснэгтийн recall 93–94%, агрегатын таарц 81–83% байхад хариулах боломжтой асуултын EX 37–48% хэвээр байгаа нь алдааны ихэнх нь нарийн хэсэгт гарч байгааг харуулна: хамгийн том эх үүсвэр нь шүүлтийн багана дутуу байх (26–31%), агрегат ба GROUP BY (21–26%), утга ба нөхцөлийн алдаа юм. Хүснэгт сонголтын алдаа 13–27% боловч gold хүснэгт prompt-д 97% тохиолдолд орсон байсан тул энэ нь

хайлтаас бус, загвар төстэй хүснэгтүүдийг (`loans` ба `loan_applications`, `deposits` ба `accounts` г.м.) андуурснаас үүдэлтэй. AST-ийн хэмжээний харьцааны медиан 1.0–1.1, илүү JOIN хийсэн SQL 17–24% байгаа тул загвар асуулгыг хэт төвөгтэй болгодоггүй, засварын алхам бүхий E2, E5h_w3-д ажилласан SQL-ийн хувь 100% болсон.

6.2 Орчуулгын загварын үр дүн

Гурван орчуулагчийн dev (300 асуулт) дээрх үзүүлэлтийг Хүснэгт 6.9-д үзүүлэв. MADLAD-ийн латин асуултыг эхлээд кирилл рүү хөрвүүлж (сайжруулсан галиглал) орчуулсан. Нэмж сургасан MADLAD (M1) орчуулгын бүх хэмжүүрээр хамгийн сайн гарсан: chrF++ кирилл 74.8, латин 73.6, санхүүгийн нэр томьёоны таарц 69.0% нь dev-ийн жишиг англи орчуулгын таарцаас (59.6%) ч өндөр. Dev-ийн 300 асуулт сургалтын 8 601 мөрийн эх өгүүлбэртэй яг давхцаагүйг шалгасан. Харин DB-ийн утгыг (код, шошго) өөрчлөхгүй хадгалсан хувь M1-д 13.6% (n = 22) буюу Qwen-ийнхоос (63.6%) муу байна.

Орчуулгын chrF++ өндөр байх нь Text2SQL-ийн үр дүн сайн гэсэн үг биш: zero-shot MADLAD (M0)-ийн chrF++ Qwen-ийнхтой ойролцоо (53.5 ба 58.0) байсан ч түүгээр орчуулсан асуултын dev EX (I3 тохиргоо, хариулах боломжтой 224) 36.2% буюу Qwen-ийн орчуулгатай I3t-ээс (46.9%) 10.7 хувиар бага гарсан. Харин нэмж сургасан M1-ээр орчуулсан ижил тохиргоо (M1a) хариулах боломжтой 127/224 буюу **56.7%** (95% итгэх завсар 50.1–63.0%), нийт 160/300 (53.3%) зөв хариулж, I3t-ээс 22 асуултаар (+9.8 хувь) илүү гарав. Энэ нь нэг үүсгэлттэй, dev-ийн дүрэмгүй тохиргоогоор E4-тэй (159/300) тэнцэх үр дүн юм. Асуулт бүрээр хослуулахад M1a I3t-ээс $+40/-18$ ($p = 0.0054$) илүү. Test-ийн хариулах боломжтой асуултад I3t 62 $\rightarrow$ M1a 81 ($+32/-13$, $p = 0.0066$); M1-ийн өгөгдлийн зааварт test-ийн алдааны шинжилгээнээс нэр томьёо орсон тул нөлөөлсөн 13 асуултыг хасахад 59 $\rightarrow$ 72 ($+25/-12$, $p = 0.047$), few-shot санд бараг ижил SQL загвартай 6 асуултыг ч хасахад 57 $\rightarrow$ 66 ($+21/-12$, $p = 0.16$) болж test дээрх ахиц батлагдахгүй (§6.4).

M1a дээр гурван нэмэлт хэмжив (Хүснэгт 6.1). DB-ийн утгыг «» тэмдэгээр хамгаалах (M1m) нь ялгаагүй ($+2/-0$, $p = 0.5$). Нэр томьёоны тоог 4-өөс 8 болгох (M1g8) нь $+13/-14$ буюу тэнцүү: хамааралгүй тодорхойлолт загварыг төөрөгдүүлэх нь тусалсантайгаа ижил. Хайлтын 12 нэр томьёоноос хэрэгтэйг Arctic өөрөө сонгох «хуваарилагч» (M1ks) нь хамгийн өндөр 130/224 ($+15/-12$, $p = 0.70$) — зөв чиглэл боловч статистикийн хувьд батлагдаагүй. Харин эдгээр дөрвөн тохиргооны аль нэг нь зөв хариулсан асуулт 146/224 (65.2%) тул олон хувилбараас зөвийг сонгох нь цаашдын хамгийн том боломж. Үүнийг шалгахын тулд хоёр арга туршив. (1) bge-reranker-v2-m3 cross-encoder-ийг өөрийн жишээ асуултын нэр томьёоны шошгоор (үнэлгээний асуултаас тусдаа) нэмж сургасан: хэрэгтэй нэр томьёог хайлтын эхний 4-өөр 77.2% олдог байсныг дунджаар 1.4 нэр томьёогоор 79.3% олдог болгосон ч SQL-ийн үр дүн (M1rr, 131/224) M1a-аас ялгаагүй ($+18/-14$, $p = 0.60$). (2) M1a, M1ks, M1g8, M1m, M1rr тохиргооны SQL-ийг ажиллуулж, үр дүнгээр нь олонхын санал авсан чуулга (M1ens) 137/224 (61.2%) болж M1a-аас $+11/-1$ ($p = 0.006$) илүү гарав — сонголтын аргаар статистикийн хувьд батлагдсан анхны ахиц. Dev-ийн дүрэм нэмсэн M1ensr нийт 197/300 (65.7%) хүрсэн ч дүрмийг dev-ийг харж гаргасан тул энэ тоо хэт өөдрөг.

Эцсийн test. M1ens-ийг test дээр ажиллуулахаас өмнө түүнийг гол тохиргоо гэж зарласан бөгөөд test дээрх хамгийн өндрийг сонгохгүй. Чуулгын бүрэлдэхүүн dev-тэй яг ижил (суурь M1rr + M1ks, M1a, M1g8, M1m); M1a-аас бусад гишүүдийг хөлдөөсөн кодоор test дээр нэг удаа ажиллуулж (Kaggle, 2026-10-31), чуулгыг

GPU-гүй дахин сонголтоор гаргахад M1ens нийт 110/200 (55.0%; 95% итгэх завсар 48.1–61.7%), хариулах боломжтой 90/151 (**59.6%**; 51.6–67.1%) зөв хариулж, M1a-аас $+10/-1$ ($p = 0.012$) илүү гарав (Хүснэгт 6.2, 6.4). Dev дээрх ахиц ($+11/-1$, $p = 0.006$) давтагдаж, dev ба test-ийн зөрүү бага байна (хариулах боломжтой 61.2% → 59.6%). Test-ээс мэдээлэл авсан 13 ба загвар төстэй 6 асуултыг хасахад ч ахиц хэвээр: M1a 66/132 (50.0%) → M1ens 73/132 (55.3%), $+8/-1$, $p = 0.039$ (засваргүй). Qwen орчуулгатай I3t-ээс ч $+38/-10$ ($p = 6.2 \times 10^{-5}$; 19 асуултгүй $+26/-10$, $p = 0.011$) илүү тул сургасан орчуулагч ба чуулгын нийлмэл ахиц test дээр батлагдсан. Гэвч гишүүдийн аль нь ч test дээр M1a-аас илүү гараагүй (M1ks $+7/-6$, M1rr $+15/-15$, M1m $+1/-0$, бүгд $p = 1.0$; M1g8 $+5/-12$, $p = 0.14$): ахиц нь ганц тохиргооноос бус, dev-ээр сонгосон таван тохиргооны SQL-ийг гүйцэтгэлийн үр дүнгээр санал хураахаас гарсан (таван тохиргооны аль нэг нь зөв хариулсан асуулт 102/151, 67.5%). Иймд хамгийн сайн ганц тохиргоо нь M1a (50.5%) хэвээр, урьдчилан зарласан эцсийн систем нь M1ens. Dev-ийн дүрэм нэмсэн M1ensr нийт 120/200 (60.0%) авсан ч гол дүн биш: дүрмийг dev-ийг харж тааруулсан, test-ийн хариулах боломжгүй 4 асуултыг dev-д тохиолдоогүй түлхүүр үгээр татгалзсан (dev-д дэмжлэгтэй үгээр ≈117/200, 58.5%), хариулах боломжтой 5 асуултад буруу ажиллаж M1ens-ийн 3 зөв хариултыг алдагдуулсан (90 → 87; M1a → M1ensr $+10/-4$, $p = 0.18$; §6.4).

Хүснэгт 6.9: Орчуулгын үзүүлэлт (dev, 300 асуулт)

Үзүүлэлт	Кирилл	Латин
chrF++ (Qwen3.5-9B, засварласан кэш)	58.0	33.9
chrF++ (MADLAD-400-3B zero-shot, M0)	53.5	51.1
chrF++ (MADLAD-400-3B QLoRA, M1)	**74.8**	**73.6**
Нэр томьёо зөв (Qwen / M1)	46.3% / **69.0%**	26.7% / **67.5%**
Text2SQL EX, хариулах боломжтой (Qwen I3t / M0a / M1a)	46.9% / 36.2% / **56.7%**	
Латин → кирилл хөрвүүлэлтийн үгийн нарийвчлал	—	89.1% → 94.8%
Маскласан асуулт (T2 засвар, dev+test 500)		122 → 37
Орчуулгын нөлөө Text2SQL-д (ижил код: D2 fix → D2 tr, dev нийт зөв)		+7.7 хувь ($p = 0.013$)

6.3 Системийн хугацааны хоцрогдлын үнэлгээ

Хүснэгт 6.10: Тохиргооны асуулт тутмын дундаж хугацаа (Kaggle T4×2)

Тохиргоо	с / асуулт	Тайлбар
H4, I3t (нэг үүсгэлт, орчуулгатай)	20–30	Нийт dev 300 ≈ 2–2.5 цаг
B бүлэг (урт RAG prompt, анхны хувилбар)	53	Prompt 13–20 мянган токен
E2 (8 хувилбар + засвар)	175	dev 300 ≈ 14.6 цаг
E3c, E4 (дахин сонголт)	≈ 0	GPU-гүй, E2-ийн хувилбараас
M1a (нэг үүсгэлт, MADLAD)	38	dev 300 ≈ 3.2 цаг
M1ens (5 тохиргооны чуулга)	≈ 5 × M1a	Сонголт GPU-гүй; 5 гишүүний нийлбэр

Хүснэгтийн тоо нь run-ийн нийт хугацааг асуултын тоонд хуваасан дундаж (throughput) юм. Асуултуудыг зэрэг боловсруулдаг тул нэг асуултын хүлээлт (latency) үүнээс урт: H4 A100 дээр p50 7.9 с, p95 57.5 с, M1a T4 дээр p50 ≈ 61 с. Иймд «нэг асуултад 30 секундээс бага» шаардлага (ФБ4, §2.2) T4 дээр хангагдаагүй.

Нэг үүсгэлттэй I3t test дээр 38.5% буюу E2-тэй тэнцүү гарсан нь 6–8 дахин бага тооцооллоор ижил үр дүнд хүрэх боломжийг харуулж байна; бодит хэрэглээнд энэ тохиргоо илүү тохиромжтой. Эцсийн M1ens-ийн санал хураалт өөрөө GPU шаардахгүй боловч таван гишүүн тохиргоог тус бүр ажиллуулах тул тооцоолол нь гишүүдийн нийлбэр буюу M1a-ийнхаас ойролцоогоор 5 дахин их; хурд чухал үед хамгийн сайн ганц тохиргоо M1a (test 50.5%) тохиромжтой.

6.4 Зорилго ба таамаглалын биелэлт

Хүснэгт 6.11: Зорилго ба таамаглалын биелэлт

№	Нотолгоо	Дүгнэлт
H1	A7 → B5 +12.0 хувь (dev; асуулт бүрийн гаралт хадгалагдаагүй ч нийт 7 → 43 тул ямар ч хослолд $p \leq 2.1 \times 10^{-7}$). Зөвхөн жишээний сан 160 → 579 (224 нь dev-ийн асуулт тул dev-д давуу): H4 → I3 хариулах боломжтой dev $+27/-12$, $p = 0.024$; test $+21/-9$, $p = 0.043$ (загвар төстэй 6-г хасвал $+19/-9$, $p = 0.087$; I3t-д орчуулгын кэш мөн солигдсон тул H4 → I3t-ийг нотолгоонд аваагүй)	Dev-д батлагдсан
H2	Dev, ижил код: D2 fix → D2 tr +7.7 хувь ($+51/-28$, $p = 0.013$; хариулах боломжтой $+46/-19$, $p = 0.0011$). Test-д орчуулгыг дангаар нь хэмжээгүй: D2 → H4 (орчуулга, засвар, татгалзал хамт) нийт $p = 8.6 \times 10^{-4}$ боловч хариулах боломжтой $+26/-15$, $p = 0.12$. Сургасан орчуулагч I3t → M1a +9.8 хувь (dev, $+40/-18$, $p = 0.0054$); test-ийн хариулах боломжтой +12.6 хувь ($p = 0.0066$) боловч 13 асуултыг хасвал $p = 0.047$ (засваргүй), загвар төстэй 6-г ч хасвал $+21/-12$, $p = 0.16$	Dev-д батлагдсан, test-д батлагдаагүй
H3	B5 → D2 +1.4 хувь (өөр GPU ба код); ижил кодоор B5 tr → D2 tr 82 → 81 ($+12/-13$, $p = 1.0$; хариулах боломжтой $+12/-11$); өөрийн DB-ийн жишээ сургалтад ороогүй	Батлагдаагүй (D3-аар шалгана)
H4	test H4 → E2 хариулах боломжтой $+17/-3$, $p = 0.0026$; нийт $p = 0.12$. Таван тохиргооны SQL-ийг үр дүнгээр санал хураах чуулга: test M1a → M1ens хариулах боломжтой $+10/-1$, $p = 0.012$ (13 ба 6 асуултгүй $+8/-1$, $p = 0.039$; dev $+11/-1$, $p = 0.006$)	Хариулах боломжтой асуултад батлагдсан (засваргүй p)

Үр дүнгийн хязгаарлалт. (1) E4-ийн татгалзал, тодруулгын түлхүүр үгийн ихэнх ба E3c-ийн 0.5 босгыг dev-ээс гаргасан тул test-ийн тоог гол гэж үзнэ; харин «таамаг», «өрсөлдөгч» гэсэн хоёр үг dev-д огт тохиолдоогүй, үнэлгээний сан үүсгэх зааврааас (`evalset/AUTHORING.md`) орсон бөгөөд зөвхөн test-ийн 4 асуултад ажилласан тул ижил дүрэмтэй E4, M1r, M1ensr-ийн test дүн ч өөдрөг (§6.4). (2) Асуулт ба gold SQL-ийг LLM agent-ууд бичиж, өөр agent-ууд хянасан; хүний шалгалт хийгдээгүй — гэхдээ 178 асуултын gold SQL-ийг схем, нэр томьёотой тулгаж дахин шалгахад (аль ч тохиргоо шийдээгүй dev 53, test 55 ба санамсаргүй 70) буруу 0, эргэлзээтэй 6 гарсан. Харин энэ шалгалт валютыг хамраагүй: 13 gold SQL (dev K010, P009, K018, K029, K038, P008, P031–P033; test X028, P010, K007, K047) мөнгөн дүнг валютаар ялгахгүй, төгрөгт хөрвүүлэхгүй нэмдэг тул USD мөр байвал gold буруу байж болзошгүй; PostgreSQL дээр шалгаагүй (нээлттэй). (3) Test-ийн D2, H4 нь A100, E2, E3c, I3 нь T4 дээр хийгдсэн тул H4 → E2 харьцуулалтад төхөөрөмжийн нөлөө холилдсон. (4) Test 200 асуулт (± 7 хувь орчим). (5) E3c dev-д 300-аас 110 асуултад тодруулга асуусан нь бодит хэрэглээнд хэт олон. (6) Төлөвлөгөөний B6–B10, C4–C7 (GRPO), F, G (agentic) бүлэг GPU-ийн төсвийн улмаас ажиллаагүй; код нь бэлэн. (7) Sampling-тэй E2-ийг (ба түүний хувилбараас гаргасан E3c, E4, E5h) төлөвлөгөөнд заасан 3 seed-ийн оронд зөвхөн seed 1-ээр ажиллуулсан тул түүврийн хэлбэлзэл хэмжигдээгүй. (8) D2-ийг B5-ийн RAG prompt-оор **монгол асуулттай** (орчуулагүй) сургасан боловч H, E, I, M бүлгийн бүх run (гол M1a, M1ens ч) загварт англи орчуулгыг өгдөг (`en_prompt`); иймд D2 дээр хэмжсэн орчуулгын ахицад хэлний

нөлөө ба сургалт–үнэлгээний prompt-ийн зөрүү холилдсон. (9) C бүлгийн BIRD орчуулгад литерал хамгаалах алхам (`bird/data.py`-ийн `_protect`) богино литералыг бусад үг болон өмнөх орлуулгын тэмдэгтийн дотор ч сольдог байсан (жишээ нь `'F'` литерал «Find»-ийн F-ийг солино) тул C1–C3 ба ижил өгөгдлөөр сургасан D2-ийн сургалтын зарим асуулт гажсан; тоог нь хэмжээгүй. (10) Intent шалгалт «өөрчил» агуулсан асуултыг бичих хүсэлт гэж татгалздаг ч энэ үг «бүтэц өөрчилсөн зээл» нэр томьёонд орно: test-ийн L058 «Бүтэц өөрчилсөн зээл хэд байна?» (хоёрдмол) асуултыг D2 зөв хариулсан бол ижил дүрэмтэй H4, E2, E4, I3, I3t татгалзсан (test D2 $\rightarrow$ H4-ийн хоёрдмол асуултын цорын ганц алдагдал, $+7/-1$); dev-д энэ үг зөвхөн жинхэнэ бичих хүсэлтэд гардаг тул илрээгүй. Дүрмийн түлхүүр үг домэйны үгтэй давхцах нь E4-ийн дүрмийн test дээрх алдааны нэг хэсгийг ч тайлбарлана (P014: «цалингаас суутгах» $\rightarrow$ «цалин»).

Үнэлгээний хүчинтэй байдлын эрсдэл

Хадгалсан run-ийн файлаас (`results/runs`) дахин тооцоход гол тоонууд (зөв хариултын тоо, McNemar) яг давтагдсан боловч доорх долоон зүйл зарим дүгнэлтийг өөдрөг болгож байв; тохируулсан тоог Хүснэгт 6.12-д үзүүлэв.

Хүснэгт 6.12: Мэдрэмжийн шинжилгээ: үндсэн ба тохируулсан тоо

Үзүүлэлт	Үндсэн тоо	Тохируулсан тоо	Шалтгаан
(1) Орчуулга (dev, нийт)	D2 $\rightarrow$ D2 tr $+11.3$ хувь	D2 fix $\rightarrow$ D2 tr $+7.7$ ($+51/-28$, $p = 0.013$)	D2 хуучин кодоор; кодын засвар $+3.7$
(2) Test D2 $\rightarrow$ H4	нийт $+42/-16$, $p = 8.6 \times 10^{-4}$	хариулах $+26/-15$, $p = 0.12$	ахиц голдуу татгалзал, тодруулгаас
(2) Test E2 $\rightarrow$ E4	нийт $+14/-1$, $p = 0.001$	хариулах $+3/-1$, $p = 0.63$	дүрэм голдуу боломжгүй, хоёрдмолд
(3) Энгийн суурь	—	үргэлж тодруулах: test 24.5%, dev 25.3%	D2-оос (21.0, 15.7%) өндөр
(4) 8 хувилбарын салаа, test	E3c 93/200 (46.5%)	E4 90/200 (45.0%)	dev-д E4 159 > E3c 137
(5) E4, test	90/200 (45.0%); E2 $\rightarrow$ E4 $p = 0.001$	86/200 (43.0%); $+10/-1$, $p = 0.012$; I3tr 90 $\rightarrow$ 86	2 түлхүүр үг dev-д 0 удаа
(5) M1r, M1ensr, test	M1ensr 120/200 (60.0%), M1r 113/200 (56.5%)	M1ensr $\approx$117 (58.5%); M1r 109–113	ижил 4 асуулт; M1a-ийн эдгээрийн гаралт локалд алга
(6) I3t $\rightarrow$ M1a, test хариулах	62 $\rightarrow$ 81, $+32/-13$, $p = 0.0066$	13 асуултгүй: 59 $\rightarrow$ 72 (52.2%), $+25/-12$, $p = 0.047$ (засваргүй)	MT-ийн заавар test-ийн шинжилгээний дараа
(7) I3t $\rightarrow$ M1a, test хариулах	62 $\rightarrow$ 81/151 (53.6%), $p = 0.0066$	6-гүй: 60 $\rightarrow$ 75/145 (51.7%), $+28/-13$, $p = 0.028$; 6 ба 13-гүй: 57 $\rightarrow$ 66/132 (50.0%), $+21/-12$, $p = 0.16$	жишээний санд бараг ижил SQL загвар; эдгээр 6-д M1a 6/6, I3t 2/6
(6, 7) M1a $\rightarrow$ M1ens, test хариулах	81 $\rightarrow$ 90/151 (59.6%), $+10/-1$, $p = 0.012$	6 ба 13-гүй: 66 $\rightarrow$ 73/132 (55.3%), $+8/-1$, $p = 0.039$	эдгээр 19-д M1a 15, M1ens 17 (6-д 6/6)

(1) **Кодын хувилбар.** Dev-ийн D2 нь boolean засвараас өмнөх кодоор ажилласан тул D2 $\rightarrow$ D2 tr-ийн $+11.3$ хувьд кодын засварын $+3.7$ холилдсон байв. (2) **Нийт ба хариулах боломжтой.** Test-ийн D2 $\rightarrow$ H4 нийт ахиц голдуу хариулах боломжгүй ($+9/-0$, $p = 0.004$) ба хоёрдмол ($+7/-1$, $p = 0.07$) асуултаас гарсан; E2 $\rightarrow$ E4 мөн

адил. (3) **Онооны дүрэм.** Нийт зөв нь хариулах боломжгүй асуултад хариулаагүй бүх хариуг (`abstain_on_error` асааллттай үед гүйцэтгэлийн алдааг ч), хоёрдмол ба боломжгүй асуултад аливаа тодруулгыг зөвд тооцдог тул үргэлж тодруулга асуудаг систем D2-оос өндөр оноо авна. (4) **Post hoc сонголт.** E3c 8 хувилбартай салаанд test дээр хамгийн өндөр боловч dev-ээр сонгогдоогүй; M1 бүлэгт ч test дээрх хамгийн өндөр нийт дүнтэй M1ensr-ийг бус, урьдчилан зарласан M1ens-ийг гол гэж үзнэ. (5) **E4-ийн түлхүүр үг.** `pipeline/selection.py`-ийн «таамаг», «өрсөлдөгч» үг dev-д 0 удаа гарсан, үнэлгээний сан үүсгэх зааврааас орсон бөгөөд зөвхөн test-ийн хариулах боломжгүй 4 асуултад (A053, K062, X052, L057) ажилласан. Дүрэм test-ийн хариулах боломжтой 5 асуултад буруу ажилласан (P014, D033, D042-оос татгалзаж, L044, C046-д тодруулга асуусан): дүрмийн нарийвчлал dev-д 25/25, test-д 10/15. Ижил дүрмийг M1a, M1ens дээр хэрэглэсэн M1r, M1ensr-д ч эдгээр 4 асуулт татгалзагдаж, ижил 5 асуултад дүрэм буруу ажилласан; M1a ба M1ens эдгээрийн 3-ыг (D033, L044, C046) зөв хариулж байсан тул хариулах боломжтой EX M1r-д 81 → 78, M1ensr-д 90 → 87 болж буурсан. Dev-д дэмжлэгтэй үгээр M1ensr ≈117/200 (58.5%; A053-ыг M1ens аль хэдийн зөв хариулсан), M1r 109–113 болно (M1a-ийн эдгээр 4 асуултын гаралт локалд алга). (6) **Орчуулагчийн сургалтын өгөгдөл.** Test-ийн орчуулгын алдааг шинжилсний дараа (шимтгэл → interest, сэрэмжлүүлэг → reminder, хураагдсан → collected) MT өгөгдөл бичих заавар (`docs/mt_authoring/BRIEF.md`) эдгээр «урхи»-г жагсаасан; «хураагдсан» зөвхөн test-д гардаг (dev-д 0), T2-ийн «засагдсан жишээ»-ний 8-аас 6 нь test-ийн асуулт байв. Иймд M1-ийн сургалтын өгөгдөлд test-ээс мэдээлэл авсан нэр томьёо орсон; нөлөөлсөн 13 асуулт: A008, C012, G014, G018, G021, G022, K008, K011, K026, L039, P010, P011, P029. (7) **SQL загварын төстэй байдал.** Few-shot жишээний санд (`examples_plus`) test-ийн хариулах боломжтой 6 асуулттай (P030, A040, C036, A015, L024, L020) бараг ижил SQL загвартай (томьёо ижил; шүүлт, хязгаар, огноо өөр) жишээ бий. M1a ба M1ens эдгээрийн 6-г, I3t 2-ыг, H4 0-ийг зөв хариулсан; энэ нь I, M бүлгийн үнэмлэхүй түвшин ба H4, D2-той харьцуулалтад нөлөөлнө. Жишээний сан ижил ч I3t → M1a-ийн ахицад мөн нөлөөлсөн: эдгээр 6 дээр $+4/-0$. Хайлт монгол асуултаар хийгддэг тул хоёуланд ижил жишээ олддог бөгөөд сайн орчуулсан англи асуулт загварт бараг ижил жишээний SQL-ийг танин хуулахад тусалсан байх магадлалтай; ийм ахиц ойролцоо жишээгүй шинэ асуултад ерөнхийлөхгүй. 6-г хасахад I3t → M1a $+28/-13$ ($p = 0.028$), 13-ыг ч хасахад 57 → 66/132 (43.2% → 50.0%), $+21/-12$, $p = 0.16$ буюу ач холбогдолгүй.

Хэмжилтийн шуугиан ба бусад шалгалт. Ижил prompt-оор ч vLLM-ийн (T4, fp16, хоёр GPU) гаралт бүрэн давтагддаггүй: M1a ба M1rt-ийн prompt 300/300 ижил боловч 29 гаралт өөр, хариулах боломжтой асуултын ≈1% эргэсэн. Prompt-ийн аливаа өөрчлөлт (few-shot, сануулга, утгын олдвор) хариулах боломжтой асуултын 16–19%-ийг хоёр тийш эргүүлдэг: V27-ийн дөрвөн run-ийн M1a-аас ялгаа $+13/-11$ … $+21/-16$ (бүгд $p \geq 0.5$; Хүснэгт 6.1), таван run-ийн аль нэгэнд зөв 162, бүгдэд зөв 91 асуулт. Иймд ганц run-ий ± 5 асуултын ялгааг ахиц гэж үзээгүй; батлагдсан ахиц нь McNemar-аар шалгасан чуулга (M1a → M1ens). M1rt (тасарсан reasoning-ийг аврах) нэг ч асуултад идэвхжээгүй: `max_tokens`-д хүрсэн 36 гаралт бүгд reasoning-ээ хааж SQL-ээ аль хэдийн бичсэний дараа түүнийгээ давтсан тул «тасралт» гэж үзсэн өмнөх дүгнэлт буруу байв. Gold SQL-ийн валютын сэжиг (мөнгөн дүнг USD ба MNT хольж нэмэх) шалгагдсан: dev-ийн 9, test-ийн 4 gold-ийг валюттай хүснэгтүүдийг зөвхөн MNT мөрөөр сольж дахин ажиллуулахад 13/13 ижил үр дүн гарсан.

Тохируулсан тоогоор dev дээрх орчуулгын нөлөө, сургасан орчуулагчийн dev дээрх ахиц ($+40/-18$, $p = 0.0054$), D2-оос M1a хүртэлх ахиц (хариулах боломжтой асуултад хоёр бүлгийг хасахад 22.0% → 50.0%, $+41/-4$, $p \approx 10^{-8}$) ба чуулгын

M1a-аас давсан ахиц (50.0% → 55.3%, $+8/-1$, $p = 0.039$, засваргүй) ач холбогдолтой хэвээр. Харин сургасан орчуулагчийн test дээрх ахиц хоёр бүлгийг хасахад батлагдахгүй ($p = 0.16$; зөвхөн 13-ыг хасахад гарах $p = 0.047$ нь test дээрх 20 гаруй харьцуулалтын засваргүй утга), H2-ийн test дээрх нотолгоо ба E4-ийн дүрмийн test дээрх нэмэр сул бөгөөд test-ийн хариулах боломжтой EX хоёр бүлгийг хасахад M1a-д 53.6%-иас 50.0%, M1ens-д 59.6%-иас 55.3% хүртэл буурна.

6.5 Ёс зүйн асуудал

Өгөгдлийн зөвшөөрөл ба нууцлал. Бодит харилцагчийн мэдээлэл огт ашиглаагүй; өгөгдлийн сан бүхэлдээ синтетик. Бодит байгууллагад ашиглагдах тохиолдолд хувийн мэдээллийн баганыг хассан давхарга, дүрмээр татгалзах, унших эрх ба RLS, шифрлэгдсэн аудит, байгууллагын дотор ажиллах нээлттэй эхийн загвар гэсэн давхаргат хамгаалалт хийв.

Хазайлт ба хортой хэрэглээ. Суурь загвар кирилл асуултад 1.3%, латин асуултад 0% зөв хариулсан нь латинаар бичдэг хэрэглэгчдэд чанар мууталй үйлчилгээ үзүүлэх эрсдэлтэй тул бичиг тус бүрээр тусад нь хэмжих шаардлагатай. Буруу тоонд үндэслэсэн шийдвэр хохирол учруулж болох тул систем итгэл багатай үед тодруулга асууж, ашигласан хүснэгт ба SQL-ийг харуулдаг; SQL ба prompt injection-ийг шалгаж хаасан. Систем нь шийдвэр гаргагчийг орлох бус, туслах хэрэгсэл юм.

Хиймэл оюуны хэрэгслийн ашиглалт. Системийн кодыг LLM кодын туслахын (Claude Code) тусламжтайгаар бичиж, бие даасан «tester» agent-аар логикийн алдааг шалгуулсан. Үнэлгээний асуулт, gold SQL, жишээ, орчуулгын хосыг LLM agent-ууд нооройлож, өөр agent-ууд сохроор хянасан; gold SQL бүрийг DB дээр гүйцэтгэж шалгасан. Иймд үнэлгээний санг «хүний бичсэн жишиг» гэж нэрлээгүй.

6.6 Бүлгийн дүгнэлт

Test дээр dev-ээр сонгосон тохиргоонуудын нийт зөв нэмэлт сургалттай суурь D2-ийн 21.0%-иас H4 34.0%, I3t 38.5%, сургасан орчуулагчтай M1a 50.5%, урьдчилан зарласан эцсийн чуулга M1ens 55.0% хүрсэн (8 хувилбартай салаанд E4 45.0%; dev-д дэмжлэгтэй түлхүүр үгээр нийт 43.0%). Гол хэмжүүр болох хариулах боломжтой EX-ээр D2 24.5% → M1a 53.6% ($+50/-6$, $p \approx 10^{-9}$) → M1ens 59.6% (M1a-аас $+10/-1$, $p = 0.012$) бөгөөд §6.4-ийн хоёр бүлэг асуултыг хасахад ч 22.0% → 50.0% → 55.3% ($+41/-4$; $+8/-1$, $p = 0.039$) хэвээр. M1a нь хамгийн сайн ганц тохиргоо (гишүүдийн аль нь ч түүнээс илүү гараагүй), M1ens нь эцсийн систем бөгөөд dev ба test-ийн зөрүү бага (хариулах боломжтой 61.2% → 59.6%). RAG ба орчуулга хамгийн их нэмэр өгсөн (dev; орчуулга ижил кодоор +7.7 хувь), санал хураалт (8 хувилбар ба 5 тохиргооны чуулга) хариулах боломжтой асуулт дээр ач холбогдолтой нэмэр өгсөн. Алдааны 38% нь орчуулгаас үүдсэн тул орчуулагчийг сайжруулах нь хамгийн том нөөц бөгөөд латин асуултын орчуулга хамгийн сул хэвээр.

Дүгнэлт

Энэхүү ажлаар нэг GPU-д ажиллах нээлттэй эхийн Arctic-Text2SQL-R1-7B загварт суурилсан, банк бус санхүүгийн байгууллагын өгөгдлийн сан дээр монгол хэлээр асуусан асуултыг SQL болгож хариулдаг системийг бүтээж, бүрэлдэхүүн бүрийн нөлөөг хяналттай туршилтаар хэмжив.

Шинэ асуултаас бүрдсэн test дээр (dev-ээр сонгосон тохиргоо; хаалтад гол хэмжүүр болох хариулах боломжтой EX) нэмэлт сургалттай суурь (D2) 21.0% (24.5%) байсан бол орчуулга ба засвартай H4 34.0% (31.8%), 8 хувилбарын санал хураалт ба дүрэмтэй E4 45.0% (42.4%; dev-д дэмжлэгтэй түлхүүр үгээр нийт 43.0%) хүрэв. H4-ийн нийт ахиц ач холбогдолтой ($p = 8.6\times10^{-4}$) боловч хариулах боломжтой асуултад батлагдаагүй ($+26/-15$, $p = 0.12$): ахицын ихэнх нь татгалзал ба тодруулгаас гарсан. Dev дээр мэдлэг хайлт (+12.0 хувь) ба ижил кодоор хэмжсэн орчуулга (+7.7) хамгийн их, өөрийн DB-ийн жишээгүй нэмэлт сургалт (+1.4; ижил кодоор 82 → 81) ба алдааны мессежээр засах (+0.3) хамгийн бага нэмэр өгсөн. Алдааны 38% нь орчуулгаас үүдсэн тул санхүүгийн хэллэгийн орчуулгын өгөгдөл бэлтгэж, орчуулагчийг нэмж сургав: 2 828 хосын өгөгдлөөс бэлтгэсэн 8 601 мөрөөр QLoRA сургасан MADLAD-400-3B-ийн chrF++ 53.5 → 74.8 (Qwen3.5-9B 58.0) болж, түүгээр орчуулсан нэг үүсгэлттэй тохиргоо (M1a) dev-ийн хариулах боломжтой асуултад 56.7% буюу Qwen орчуулгатай I3t-ээс 9.8 хувь өндөр гарсан ($+40/-18$, $p = 0.0054$); test дээр хариулах боломжтой асуултад 41.1% → 53.6% ($+32/-13$, $p = 0.0066$), нийт 101/200 (50.5%) болсон. Гэвч M1-ийн сургалтын өгөгдөлд test-ийн орчуулгын алдааны шинжилгээнээс гарсан нэр томьёо орсон тул нөлөөлсөн 13 асуултыг хасахад ахиц 59 → 72 ($+25/-12$, засваргүй $p = 0.047$), few-shot санд бараг ижил SQL загвартай 6 асуултыг ч хасахад 57 → 66 ($+21/-12$, $p = 0.16$) болж test дээр батлагдахгүй (§6.4). Харин M1a ба түүний дөрвөн хувилбарын (M1ks, M1g8, M1m, M1rr) SQL-ийг гүйцэтгэлийн үр дүнгээр санал хураадаг, урьдчилан зарласан эцсийн систем M1ens-ийг test дээр нэг удаа хэмжихэд нийт 110/200 (**55.0%**), хариулах боломжтой 90/151 (**59.6%**) зөв хариулж, M1a-аас $+10/-1$ ($p = 0.012$) илүү гарсан бөгөөд дээрх 13 ба 6 асуултыг хасахад ч ахиц хэвээр ($+8/-1$, засваргүй $p = 0.039$); dev дээрх ахиц ($+11/-1$, $p = 0.006$) давтагдаж, dev ба test-ийн зөрүү бага байв (хариулах боломжтой 61.2% → 59.6%, §6.2). Гишүүдийн аль нь ч дангаараа M1a-аас илүү гараагүй тул хамгийн сайн ганц тохиргоо нь M1a (50.5%), урьдчилан зарласан эцсийн систем нь M1ens; dev-ийн дүрэм нэмсэн M1ensr-ийн 60.0% нь dev-ийг харж тааруулсан дүрэм ба dev-д тохиолдоогүй түлхүүр үгээс хамаардаг тул гол дүн биш. Сэдэв батлах даалгаврын зорилтуудын биелэлтийг Хүснэгт 6.13-д нэгтгэв.

Хүснэгт 6.13: Зорилгын биелэлтийн нэгтгэл

№	Зорилт	Биелэлт
1	Мэдлэгийн сан (RAG) бүрдүүлэх	28 view, 425 багана, 45 нэр томьёо, 20 KPI, 635 жишээ (үнэлсэн I, M run-д 579, үүнээс 224 нь dev-ийн асуулт; §3.1)
2	Prompt ба pipeline боловсруулах	7 алхамтай дамжлага, 118 нэрлэсэн тохиргоо (Бүлэг 2, 5)
3	Монгол хэл ба өөрийн DB-д тохируулан сургах	C1–C3, D2 (A100), D3 (T4); орчуулагчийн M1 сургалт (chrF++ 53.5 → 74.8; Qwen3.5-9B 58.0); H3 батлагдаагүй
4	Олон хувилбараас сонгох, засах, татгалзах	E1, E2, E3c, E4, M1ens; test хариулах боломжтой EX H4 → E2 $+17/-3$ ($p = 0.0026$), M1a → M1ens $+10/-1$ ($p = 0.012$)
5	Тестийн багцаар хэмжиж тайлагнах	dev 300 + test 200; test 21.0% → 55.0% (урьдчилан зарласан M1ens; хариулах боломжтой 24.5% → 59.6%); хамгийн сайн ганц тохиргоо M1a 50.5% (53.6%), §6.1

Оруулсан хувь нэмэр. (1) Монгол хэлний Text2SQL-ийн 500 асуулттай үнэлгээний сан; (2) бага нөөцтэй хэл ба 7B загварт мэдлэг хайлт ба орчуулга хамгийн их нөлөөтэйг харуулсан эмпирик нотолгоо (орчуулгыг ижил кодоор McNemar тестээр; мэдлэг хайлтын A7 → B5-д асуулт бүрийн гаралт хадгалагдаагүй ч нийт 7 → 43 тул ямар ч хослолд $p \leq 2.1 \times 10^{-7}$); (3) алдааны эх үүсвэрийн хэмжилт ба орчуулгын өгөгдөл; (4) үнэгүй үүлэн квот дээр давтагдахуйц систем ба Text2SQL Studio хэрэгсэл.

Цаашдын чиглэл. Test-ийн нийт EX одоо урьдчилан зарласан эцсийн систем M1ens-д 55.0% (хариулах боломжтой 59.6%), хамгийн сайн ганц тохиргоо M1a-д 50.5% байна. Dev-ийн дүрэм нэмсэн M1ensr 60.0% авсан ч дүрмийг dev-ийг харж тааруулсан, хоёр түлхүүр үг нь dev-д тохиолдоогүй тул энэ тоо өөдрөг; хос харьцуулалтын нэмэр test дээр хэмжигдээгүй. Доорх ажлыг хүлээгдэх нөлөө ба зардлаар эрэмбэлэв. «Бэлтгэсэн» гэж тэмдэглэсэн ажлын код ба тохиргоо бэлэн боловч GPU дээр үнэлээгүй тул нарийвчлалд үзүүлэх нөлөө нь хэмжигдээгүй.

1. **Сургасан хос сонгогч.** Тохиргоонууд өөр өөр асуултыг зөв хариулдаг: dev-ийн хариулах боломжтой асуултын 146/224-ийг дөрвөн тохиргооны аль нэг нь зөв хариулсан бол чуулга (M1ens) 137/224-т хүрсэн; test дээр ч таван гишүүний аль нэг нь зөв хариулсан 102/151 асуултаас чуулга 90-ийг сонгосон. Иймд CHASE-SQL [24], XiYan-SQL [26], JudgeSQL [27]-ийн адил гүйцэтгэлээр шошголсон хувилбарын хосоор сонгогч сургаж, dev дээр чуулгатай McNemar-аар харьцуулна.

2. **Hidden state дээрх хариулах боломжгүй асуултын ангилагч.** Татгалзалт одоо dev-ийн хэллэгээс бичсэн дүрэмд тулгуурладаг. Бэлтгэсэн ерөнхий шинжүүдийн логистик регресс (abstain v2) dev-ийн family-аар хуваасан cross-validation-д 154.5 ± 1.7 зөв хариулт авч, in-sample дүрмийн 159-ийг давсангүй; дүрэмтэй хослуулахад 160.9 ± 1.0 болсон. Иймд LatentRefusal [29]-ийн адил

загварын завсрын hidden state дээр хөнгөн ангилагч сургах нь дараагийн алхам.

3. **CTE/задаргааны генератор (бэлтгэсэн: M1cte).** Хэцүү, CTE, харьцааны асуулт хамгийн сул тул дэд алхмыг `WITH`-ээр төлөвлүүлдэг зааварtай генераторыг DIN-SQL [59]-ийн санаагаар чуулгын шинэ гишүүн болгоно. Одоогийн гишүүд ижил prompt-той тул алдаагаа давтдаг; нөлөөг dev дээр хэмжээгүй.

4. **Хүснэгт ялгах сануулга (бэлтгэсэн: M1th).** Буруу хариултад төстэй хүснэгтийг андуурах (жишээ нь `loan_writeoffs` ба `loan_payments`) түгээмэл тул semantic model-оос бичсэн 14 хосын сануулгыг prompt-д нэмнэ. FK замаар завсрын хүснэгт нэмэх аргыг (FK-bridge) мөн бэлтгэсэн боловч dev-ийн 97.3%-д gold хүснэгт prompt-д аль хэдийн байдаг тул нөлөө бага байх төлөвтэй. Аль алиных нь EX-ийн нөлөө хэмжигдээгүй.

5. **Өөрийн схемийн синтетик өгөгдөл ба LoRA-г дахин сургах.** Semantic model-оос 7 хэв маягаар 2 779 асуулт–SQL хос үүсгэсэн; гүйцэтгэлээр шүүх, rejection sampling хийх, D3-ийг дахин сургах алхмууд үлдсэн. Шүүгээгүй синтетик өгөгдөл нарийвчлалыг бууруулж болохыг Arctic-Text2SQL-R1 [3] харуулсан тул SING-SQL [16], OmniSQL [12]-ийн адил шүүлтийг заавал хийж, dev дээр synth-гүй сургалттай харьцуулна.

6. **Бодит өгөгдөл ба хэрэглэгчийн лог.** DB ба асуултууд синтетик. Бодит өгөгдлийн хамгаалалттай хуулбар дээр shadow горимоор туршиж, Studio-ийн үнэлгээгээр цугласан, хүн хянасан асуулт–SQL хосоор үнэлгээний ба жишээний санг баяжуулна; үнэлгээний санг хоёр домэйн шинжээчээр шалгаж, латин асуултыг тусад нь хэмжинэ.

7. **Хариултын хугацааг бууруулах.** 8 хувилбартай тохиргоо T4 дээр асуулт бүрт ∼3 минут зарцуулдаг бол эцсийн M1ens таван гишүүн тохиргооныхоо нийлбэр хугацааг шаарддаг (§6.3). Санал нийлэлт хангалттай үед хувилбар үүсгэхийг эрт зогсоох, орчуулга ба мэдлэг хайлтыг кэшлэх, илүү хүчтэй GPU ашиглах замаар бодит хэрэглээнд тохирох хугацаанд хүргэнэ.

Нийгмийн нөлөө. Монгол хэлээр өгөгдлийн сангаас тоо мэдээ авах боломж нь SQL мэдэхгүй ажилтнуудын шинжээчээс хамаарах хамаарлыг бууруулж, шийдвэр гаргалтыг хурдасгана. Нээлттэй эхийн загвар ба нэг GPU-д суурилсан тул жижиг, дунд байгууллага ч өгөгдлөө гадагш гаргахгүйгээр ашиглах боломжтой.

ХАВСРАЛТ А

Ажиллуулах тушаалууд

Орчин бэлтгэх ба өгөгдлийн сан.

```
pip install -e .
export T2S_ADMIN_DSN=postgresql://postgres@localhost:55432/postgres
t2s db-build            # схем + синтетик өгөгдөл (648 205 мөр), t2s view
t2s testsuite-build     # 8 test-suite хуулбар
t2s knowledge-check     # мэдлэгийн сан <-> DB-ийн нийцэл
t2s index-build         # BM25 + BGE-M3 индекс
t2s check-gold --testsuite  # dev + test gold SQL, 8 хуулбар дээр ч
```

Үнэлгээ.

```
t2s eval --run A7,B5 --split dev          # туршилтын ID-аар
t2s eval --run E2 --split test            # шилдэг тохиргоог test дээр нэг удаа
t2s eval --run B5 --oracle                # дамжлагыг gold SQL-ээр шалгах
t2s reselect --from E2 --to E4 --tag h_H4 --split dev  # GPU-гүй дахин сонголт
t2s derive-abstain --from E2 --to E3c --tag h_H4 \
    --threshold 0.5 --action clarify
t2s compare --a <H4.jsonl> --b <E2.jsonl>     # McNemar
t2s report && t2s report-latex
```

Орчуулга, аюулгүй байдал, үйлчилгээ.

```
t2s translate --split dev --t2            # орчуулгын кэш (T2)
t2s security-test                         # 28 SQL халдлага, 56 prompt injection
    , RLS
t2s serve                                 # FastAPI (shadow / pilot / live)
t2s flow-ui --demo --port 8090            # Text2SQL Studio, загваргүй демо
```

Kaggle үе шат (`config/kaggle_overrides.env`-ээр сонгоно):

```
STAGE=e2test    bash scripts/server/run_plan_l4.sh   # E2 test
STAGE=istage    bash scripts/server/run_plan_l4.sh   # I3, I3t dev/test
STAGE=train_d3  bash scripts/server/run_plan_l4.sh   # D3 QLoRA (checkpoint-ooc
    юргэлжилнэ)
STAGE=mt        bash scripts/server/run_plan_l4.sh   # MT M0 bake-off + MADLAD
    QLoRA
STAGE=t2s_inv   bash scripts/server/run_plan_l4.sh   # S1-S4 өгөгдөл, сургалт, T
    -2/T-4
STAGE=web       bash scripts/server/run_plan_l4.sh   # Studio + загвар + tunnel
```

ХАВСРАЛТ Б

Төслийн файлын бүтэц

```
text2sql-new/
  src/mn_text2sql/       Python багц (98 модуль)
    pipeline/            orchestrator, translate, dialect, postproc, selection, intent_check
    retrieval/ knowledge/ BM25, BGE-M3, schema linking
    llm/ security/ db/ datagen/ eval/ training/ text/
    service/             FastAPI, Text2SQL Studio (static/builder.html), flow.py
  config/                experiments.yaml (118 тохиргоо), models.yaml
                         flows.yaml (Studio-д анх хадгалахад үүснэ)
  knowledge/             semantic_model, glossary, metrics, examples*.jsonl
  evalset/               dev.jsonl (300), test.jsonl (200), AUTHORING.md
  evalset_shift/         T-2 (нэр сольсон схем), T-4 (тодорхойлолт)
  data/mt/v2/            MT v2: 2 828 хос, SFT мөр, human_review.html
  data/t2s_inv/          S1-S4 сургалтын prompt
  db/                    DB-ийн хуулбар ба CHANGES.md
  scripts/server/        run_plan_l4.sh (STAGE=...)
  scripts/notebook/      bootstrap.sh, pack_code.py, merge_lora.py, make_web_kaggle.py
  scripts/mt/ scripts/t2s_inv/  MT ба тогтвортой сургалтын скрипт
  notebooks/             Kaggle / Colab notebook
  results/runs/<split>/<ID>/   асуулт бүрийн үр дүн, summary, meta
  tests/                 pytest
  docs/                  WORKLOG, MT_INVARIANT_PLAN, AGENT, CLOUD ...
  report_diplom/         энэ тайлан
```

ХАВСРАЛТ В

Туршилтын тохиргооны жагсаалт

Хүснэгт В.1: Ажиллуулсан болон бэлэн тохиргоонууд (`config/experiments.yaml`)

ID	Тайлбар
A1	Суурь загвар, кирилл асуулт, тайлбаргүй схем, RAG-гүй
A2 / A3	A1-ийн англи / латин галиг хувилбар
A4	Асуултыг англи руу машин орчуулах (Kaggle-д кэшгүй тул ажиллаагүй)
A6	Prompt-д PostgreSQL dialect заах
A7	SQLite-аар үүсгээд sqlglot-оор PostgreSQL руу хөрвүүлэх
B1–B4	A7 + тайлбар, синоним (B1); утгын хайлт (B2); нэр томьёо (B3); 4 жишээ (B4)
B5	B1–B4 бүгд (RAG); «B5 tr» = + англи орчуулга
C1	LoRA SFT (rank 32), rejection sampling, RAG-гүй үнэлгээ
C2	C1 + gold-оор чиглүүлсэн CoT
C3	C2 + өөрийн DB-ийн синтетик өгөгдөл ба 160 жишээ
D2	B5-ийн RAG prompt-оор сургасан adapter + RAG; «D2 tr» = + орчуулга
D3	Богино (schema linking) prompt, QLoRA (112/116 алхам, үнэлгээ хүлээгдэж байна)
H1	D2 + postproc (код ↔ нэр, огноо, ROUND), хувийн мэдээлэл/бичих хүсэлтээс татгалзах, алдаатай SQL-ээс татгалзах
H2	H1 + монгол асуулт ба англи орчуулга хамт
H3	H1 + асуултыг англи орчуулгаар солих
H4	H1 + загварт англи, хайлт ба жишээ сонголт монголоор
E1	H4 + гүйцэтгэлийн алдааны мессежээр засах ($\leq$2)
E2	E1 + 8 хувилбар (sampling), гүйцэтгэлийн үр дүнгээр санал хураах
E3c	E2 + санал нийлэлт $<$ 0.5 бол тодруулга
E4f	E2 + хоосон, бүгд NULL, DB-д байхгүй утгатай хувилбарыг хасах; улирлын формат засвар
E4	E4f + түлхүүр үгээр татгалзах (цалин, инфляц, таамаг г.м.; ихэнх нь dev-ээс, «таамаг», «өрсөлдөгч» нь үнэлгээний сангийн зааврас — §6.4), бүдэг хугацаанд тодруулга
I1 / I2	H4 + dev-ийн асуулт жишээ болгон (өөрийн гэр бүлийг хасаж) / H4 + шинэ 195 жишээ
I3	H4 + 160 + 224 + 195 = 579 жишээ
I3t / I3t2	I3 + засварласан орчуулга / T2 орчуулга (маскын шүүлт, нэр томьёоны RAG)
I3r, I3tr	Тухайн тохиргоо + E4-ийн дүрэм (загваргүй)
J1	I3t + нэр томьёог англиар
K1–K3	I3t2 + agentic давталт (tool, critic, planner) — код бэлэн
WEB	Вэбийн тохиргоо: schema linking, богино prompt

ID	Тайлбар
F1–F10, G1–G6	Төлөвлөгөөний шинэлэг санаа ба agentic горим — код бэлэн, ажиллаагүй

ХАВСРАЛТ Г

Ажлын түүх

Төсөл 2026-10-27-нд git-д бүртгэгдсэн (commit `eef96a4`) тул түүнээс өмнөх ажлын түүхийг `docs/WORKLOG.md`-ээс нэгтгэв (2026 он, Улаанбаатарын цаг).

Хүснэгт Г.1: Ажлын гол үе шат

Огноо	Хийсэн ажил
10-15	Заавар ба туршилтын төлөвлөгөөг код болгосон: CLI, дамжлага, RAG, үнэлгээ, сургалт, аюулгүй байдал; dev 300, test 200, 160 жишээ
10-16	Agentic горим, LaTeX тайлангийн анхны хувилбар; Kaggle ба Modal-д бэлтгэсэн
10-17	A, B бүлэг (Kaggle T4); C1–C3 сургалт (Modal); D2 сургалт ба H бүлэг (Vast A100)
10-18	E2 dev 41.0%; test D2 21.0%, H4 34.0%, E2 38.5%, E3c 46.5%; 195 шинэ жишээ; E4
10-19	I3, I3t dev ба test; E4 test 45.0%; D3 QLoRA 112/116 алхам; 280 жишээ
10-20	T2 орчуулга (маск 122 → 37); agentic K1–K3 тохиргоо
10-23	Орчуулгын fine-tune ба тогтвортой сургалтын төлөвлөгөө; MT v0 өгөгдөл
10-25	MT v2 (2 828 хос), S1–S4, T-2/T-4; Kaggle STAGE=mt эхэлсэн; Text2SQL Studio; локал PostgreSQL демо
10-26	Танилцуулга ба энэ тайлан; Kaggle дээр MADLAD-400-3B-ийн QLoRA сургалт (Version 16)

Ном зүй

[1] Liang Shi et al. “A Survey on Employing Large Language Models for Text-to-SQL Tasks”. In: *ACM Computing Surveys* 58.2 (2025), pp. 1–37. DOI: 10.1145/3737873. arXiv: 2407.15186 [cs.CL].

[2] Jinyang Li et al. “Can LLM Already Serve as A Database Interface? A BIg Bench for Large-Scale Database Grounded Text-to-SQLs”. In: *Advances in Neural Information Processing Systems 36 (NeurIPS 2023), Datasets and Benchmarks Track*. 2023. arXiv: 2305.03111 [cs.CL]. URL: https://arxiv.org/abs/2305.03111.

[3] Zhewei Yao et al. *Arctic-Text2SQL-R1: Simple Rewards, Strong Reasoning in Text-to-SQL*. 2025. arXiv: 2505.20315 [cs.CL]. URL: https://arxiv.org/abs/2505.20315.

[4] Longxu Dou et al. “MultiSpider: Towards Benchmarking Multilingual Text-to-SQL Semantic Parsing”. In: *Proceedings of the AAAI Conference on Artificial Intelligence* 37.11 (2023), pp. 12745–12753. DOI: 10.1609/aaai.v37i11.26499. arXiv: 2212.13492 [cs.CL].

[5] Khanh Trinh Pham et al. “Multilingual Text-to-SQL: Benchmarking the Limits of Language Models with Collaborative Language Agents”. In: *Databases Theory and Applications (ADC 2025)*. Lecture Notes in Computer Science. Springer Nature Singapore, 2026, pp. 108–123. DOI: 10.1007/978-981-95-6196-4_8. arXiv: 2509.24405 [cs.CL].

[6] Mengyuan Zhang et al. *MM-Eval: A Hierarchical Benchmark for Modern Mongolian Evaluation in LLMs*. 2024. arXiv: 2411.09492 [cs.CL]. URL: https://arxiv.org/abs/2411.09492.

[7] Gyubok Lee et al. *TrustSQL: Benchmarking Text-to-SQL Reliability with Penalty-Based Scoring*. 2024. arXiv: 2403.15879. URL: https://arxiv.org/abs/2403.15879.

[8] Tao Yu et al. “Spider: A Large-Scale Human-Labeled Dataset for Complex and Cross-Domain Semantic Parsing and Text-to-SQL Task”. In: *Proceedings of the 2018 Conference on Empirical Methods in Natural Language Processing (EMNLP)*. Brussels, Belgium: Association for Computational Linguistics, 2018, pp. 3911–3921. DOI: 10.18653/v1/D18-1425. arXiv: 1809.08887 [cs.CL].

[9] Ruiqi Zhong, Tao Yu, and Dan Klein. “Semantic Evaluation for Text-to-SQL with Distilled Test Suites”. In: *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP)*. Association for Computational Linguistics, 2020, pp. 396–411. DOI: 10.18653/v1/2020.emnlp-main.29. arXiv: 2010.02840 [cs.CL].

[10] Irina Saparina and Mirella Lapata. "AMBROSIA: A Benchmark for Parsing Ambiguous Questions into Database Queries". In: *Advances in Neural Information Processing Systems 37 (NeurIPS 2024), Datasets and Benchmarks Track*. 2024. arXiv: 2406.19073 [cs.CL]. URL: https://arxiv.org/abs/2406.19073.

[11] Adithya Bhaskar et al. "Benchmarking and Improving Text-to-SQL Generation under Ambiguity". In: *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing (EMNLP)*. Association for Computational Linguistics, 2023, pp. 7053–7074. DOI: 10.18653/v1/2023.emnlp-main.436.

[12] Haoyang Li et al. "OmniSQL: Synthesizing High-quality Text-to-SQL Data at Scale". In: *Proceedings of the VLDB Endowment* 18.11 (2025), pp. 4695–4709. DOI: 10.14778/3749646.3749723. arXiv: 2503.02240 [cs.CL]. URL: https://arxiv.org/abs/2503.02240.

[13] Binyuan Hui et al. *Qwen2.5-Coder Technical Report*. 2024. arXiv: 2409.12186 [cs.CL]. URL: https://arxiv.org/abs/2409.12186.

[14] Zhihong Shao et al. *DeepSeekMath: Pushing the Limits of Mathematical Reasoning in Open Language Models*. 2024. arXiv: 2402.03300 [cs.CL]. URL: https://arxiv.org/abs/2402.03300.

[15] Yuxin Zhang et al. *Reward-SQL: Boosting Text-to-SQL via Stepwise Reasoning and Process-Supervised Rewards*. 2025. arXiv: 2505.04671 [cs.CL]. URL: https://arxiv.org/abs/2505.04671.

[16] Hasan Alp Caferoğlu, Mehmet Serhat Çelik, and Özgür Ulusoy. *SING-SQL: A Synthetic Data Generation Framework for In-Domain Text-to-SQL Translation*. 2025. arXiv: 2509.25672 [cs.CL]. URL: https://arxiv.org/abs/2509.25672.

[17] Patrick Lewis et al. "Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks". In: *Advances in Neural Information Processing Systems 33 (NeurIPS 2020)*. 2020. arXiv: 2005.11401 [cs.CL]. URL: https://arxiv.org/abs/2005.11401.

[18] Shayan Talaei et al. *CHESS: Contextual Harnessing for Efficient SQL Synthesis*. 2024. arXiv: 2405.16755 [cs.LG]. URL: https://arxiv.org/abs/2405.16755.

[19] Haoyang Li et al. "CodeS: Towards Building Open-source Language Models for Text-to-SQL". In: *Proceedings of the ACM on Management of Data* 2.3 (2024), pp. 1–28. DOI: 10.1145/3654930. arXiv: 2402.16347. URL: https://arxiv.org/abs/2402.16347.

[20] Dawei Gao et al. "Text-to-SQL Empowered by Large Language Models: A Benchmark Evaluation". In: *Proceedings of the VLDB Endowment* 17.5 (2024), pp. 1132–1145. DOI: 10.14778/3641204.3641221. arXiv: 2308.15363 [cs.DB].

[21] Karime Maamari et al. *The Death of Schema Linking? Text-to-SQL in the Age of Well-Reasoned Language Models*. 2024. arXiv: 2408.07702 [cs.CL]. URL: https://arxiv.org/abs/2408.07702.

[22] Zhenbiao Cao et al. *RSL-SQL: Robust Schema Linking in Text-to-SQL Generation*. 2024. arXiv: 2411.00073 [cs.CL]. URL: https://arxiv.org/abs/2411.00073.

[23] Xuezhi Wang et al. "Self-Consistency Improves Chain of Thought Reasoning in Language Models". In: *International Conference on Learning Representations (ICLR)*. 2023. arXiv: 2203.11171. URL: https://arxiv.org/abs/2203.11171.

[24] Mohammadreza Pourreza et al. “CHASE-SQL: Multi-Path Reasoning and Preference Optimized Candidate Selection in Text-to-SQL”. In: *The Thirteenth International Conference on Learning Representations (ICLR 2025)*. 2025. arXiv: 2410.01943 [cs.LG]. URL: https://arxiv.org/abs/2410.01943.

[25] Dongjun Lee et al. “MCS-SQL: Leveraging Multiple Prompts and Multiple-Choice Selection For Text-to-SQL Generation”. In: *Proceedings of the 31st International Conference on Computational Linguistics (COLING 2025)*. Association for Computational Linguistics, 2025, pp. 337–353. arXiv: 2405.07467 [cs.CL]. URL: https://aclanthology.org/2025.coling-main.24/.

[26] Yifu Liu et al. *XiYan-SQL: A Novel Multi-Generator Framework For Text-to-SQL*. 2025. arXiv: 2507.04701 [cs.CL]. URL: https://arxiv.org/abs/2507.04701.

[27] Jiayuan Bai et al. *JudgeSQL: Reasoning over SQL Candidates with Weighted Consensus Tournament*. 2025. arXiv: 2510.15560 [cs.CL]. URL: https://arxiv.org/abs/2510.15560.

[28] Jie Huang et al. “Large Language Models Cannot Self-Correct Reasoning Yet”. In: *The Twelfth International Conference on Learning Representations (ICLR 2024)*. 2024. arXiv: 2310.01798 [cs.CL]. URL: https://arxiv.org/abs/2310.01798.

[29] Xuancheng Ren et al. *LatentRefusal: Latent-Signal Refusal for Unanswerable Text-to-SQL Queries*. 2026. arXiv: 2601.10398 [cs.CL]. URL: https://arxiv.org/abs/2601.10398.

[30] Oleg Somov and Elena Tutubalina. *Confidence Estimation for Error Detection in Text-to-SQL Systems*. arXiv comment: to be published in AAAI 2025 Proceedings. 2025. arXiv: 2501.09527 [cs.LG]. URL: https://arxiv.org/abs/2501.09527.

[31] Aviral Dawar et al. *IndicDB – Benchmarking Multilingual Text-to-SQL Capabilities in Indian Languages*. 2026. arXiv: 2604.13686 [cs.CL]. URL: https://arxiv.org/abs/2604.13686.

[32] Ali Buğra Kanburoğlu and F. Boray Tek. “TUR2SQL: A Cross-Domain Turkish Dataset For Text-to-SQL”. In: *2023 8th International Conference on Computer Science and Engineering (UBMK)*. IEEE, 2023, pp. 206–211. DOI: 10.1109/UBMK59864.2023.10286686.

[33] Burak Aktaş et al. “BIRDTurk: Adaptation of the BIRD Text-to-SQL Dataset to Turkish”. In: *Proceedings of the Second Workshop on Natural Language Processing for Turkic Languages (SIGTURK 2026)*. Association for Computational Linguistics, 2026, pp. 155–171. DOI: 10.18653/v1/2026.sigturk-1.13.

[34] Salmane Chafik, Saad Ezzini, and Ismail Berrada. *Dialect2SQL: A Novel Text-to-SQL Dataset for Arabic Dialects with a Focus on Moroccan Darija*. Also in Proceedings of the WACL 2025 workshop. 2025. arXiv: 2501.11498 [cs.SE]. URL: https://arxiv.org/abs/2501.11498.

[35] Ashish Kattamuri et al. *Bridging the Semantic Gap: Contrastive Rewards for Multilingual Text-to-SQL with GRPO*. 20th International Workshop on Semantic and Social Media Adaptation & Personalization. 2025. arXiv: 2510.13827 [cs.CL]. URL: https://arxiv.org/abs/2510.13827.

[36] Julen Etxaniz et al. “Do Multilingual Language Models Think Better in English?” In: *Proceedings of the 2024 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (Volume 2: Short Papers)*. Association for Computational Linguistics, 2024, pp. 550–564. DOI: 10.18653/v1/2024.naacl-short.46. arXiv: 2308.01223 [cs.CL].

[37] Haoyang Huang et al. “Not All Languages Are Created Equal in LLMs: Improving Multilingual Capability by Cross-Lingual-Thought Prompting”. In: *Findings of the Association for Computational Linguistics: EMNLP 2023*. Association for Computational Linguistics, 2023, pp. 12365–12394. DOI: 10.18653/v1/2023.findings-emnlp.826. arXiv: 2305.07004 [cs.CL].

[38] Quulgan Minggad, Xiao Zinan, and Yuan Sun. “MonCulture-Eval: A Hierarchical Benchmark for Evaluating Mongolian Cultural Capabilities of Large Language Models across Scripts and Regions”. In: *Findings of the Association for Computational Linguistics: ACL 2026*. Association for Computational Linguistics, 2026, pp. 28997–29014. DOI: 10.18653/v1/2026.findings-acl.1449.

[39] Dianqing Lin et al. “Can Large Language Models Translate Unseen Languages in Underrepresented Scripts?” In: *Proceedings of the 2025 Conference on Empirical Methods in Natural Language Processing (EMNLP)*. Suzhou, China: Association for Computational Linguistics, 2025, pp. 23137–23150. URL: https://aclanthology.org/2025.emnlp-main.1179/.

[40] Б. Очир. *Монгол болон англи хэлний асуултыг олон диалектын SQL болгон хөрвүүлэх нээлттэй эх агент системийн туршилт судалгаа*. Өмнөх ажил, text2sql-thesis репозиторий. 2026.

[41] Jeffrey Johnson et al. *QueryGPT – Natural Language to SQL Using Generative AI*. Uber Engineering Blog. Sept. 2024. URL: https://www.uber.com/us/en/blog/query-gpt/ (visited on 09/21/2026).

[42] Albert Chen et al. *Practical Text-to-SQL for Data Analytics*. LinkedIn Engineering Blog. Dec. 2024. URL: https://www.linkedin.com/blog/engineering/ai/practical-text-to-sql-for-data-analytics (visited on 09/21/2026).

[43] Snowflake Inc. *Cortex Analyst*. Snowflake Documentation. 2026. URL: https://docs.snowflake.com/user-guide/snowflake-cortex/cortex-analyst (visited on 10/26/2026).

[44] Databricks. *What is an AI/BI Genie space*. Databricks Documentation. 2026. URL: https://docs.databricks.com/genie/index.html (visited on 10/26/2026).

[45] Microsoft. *Introduction to Q&A tooling to train Power BI Q&A*. Microsoft Learn. 2026. URL: https://learn.microsoft.com/en-us/power-bi/natural-language/q-and-a-tooling-intro (visited on 10/26/2026).

[46] Amazon Web Services. *Getting started with Amazon QuickSight Q*. Amazon QuickSight User Guide. 2026. URL: https://docs.aws.amazon.com/quicksight/latest/user/quicksight-q-get-started.html (visited on 10/26/2026).

[47] Vanna.AI. *Vanna: open-source Python RAG framework for SQL generation*. GitHub. 2026. URL: https://github.com/vanna-ai/vanna (visited on 10/26/2026).

[48] Canner. *Wren AI: open-source GenBI agent with a semantic layer*. GitHub. 2026. URL: https://github.com/Canner/WrenAI (visited on 10/26/2026).

[49] Quinn McNemar. “Note on the Sampling Error of the Difference Between Correlated Proportions or Percentages”. In: *Psychometrika* 12.2 (1947), pp. 153–157.

[50] Snowflake. *Arctic-Text2SQL-R1-7B: model card*. 2025. URL: https://huggingface.co/Snowflake/Arctic-Text2SQL-R1-7B (visited on 10/16/2026).

[51] Toby Mao et al. *sqlglot: A no-dependency SQL parser, transpiler, optimizer, and engine*. Version 30.18.0. MIT License. 2026. URL: https://github.com/tobymao/sqlglot (visited on 09/21/2026).

[52] Woosuk Kwon et al. “Efficient Memory Management for Large Language Model Serving with PagedAttention”. In: *Proceedings of the 29th Symposium on Operating Systems Principles (SOSP 2023)*. ACM, 2023, pp. 611–626. DOI: 10.1145/3600006.3613165. arXiv: 2309.06180 [cs.LG].

[53] Edward J. Hu et al. “LoRA: Low-Rank Adaptation of Large Language Models”. In: *The Tenth International Conference on Learning Representations (ICLR 2022)*. 2022. arXiv: 2106.09685 [cs.CL]. URL: https://openreview.net/forum?id=nZeVKeeFYf9.

[54] Tim Dettmers et al. “QLoRA: Efficient Finetuning of Quantized LLMs”. In: *Advances in Neural Information Processing Systems 36 (NeurIPS 2023)*. 2023. arXiv: 2305.14314 [cs.LG]. URL: https://proceedings.neurips.cc/paper_files/paper/2023/hash/1feb87871436031bdc0f2beaa62a049b-Abstract-Conference.html.

[55] Sneha Kudugunta et al. “MADLAD-400: A Multilingual And Document-Level Large Audited Dataset”. In: *Advances in Neural Information Processing Systems 36 (Datasets and Benchmarks Track)*. 2023.

[56] Maja Popović. “chrF++: words helping character n-grams”. In: *Proceedings of the Second Conference on Machine Translation*. 2017, pp. 612–618.

[57] Stephen Robertson and Hugo Zaragoza. “The Probabilistic Relevance Framework: BM25 and Beyond”. In: *Foundations and Trends in Information Retrieval* 3.4 (2009), pp. 333–389.

[58] Jianlyu Chen et al. “M3-Embedding: Multi-Linguality, Multi-Functionality, Multi-Granularity Text Embeddings Through Self-Knowledge Distillation”. In: *Findings of the Association for Computational Linguistics: ACL 2024*. Association for Computational Linguistics, 2024, pp. 2318–2335. DOI: 10.18653/v1/2024.findings-acl.137. arXiv: 2402.03216. URL: https://aclanthology.org/2024.findings-acl.137/.

[59] Mohammadreza Pourreza and Davood Rafiei. “DIN-SQL: Decomposed In-Context Learning of Text-to-SQL with Self-Correction”. In: *Advances in Neural Information Processing Systems 36 (NeurIPS 2023)*. 2023. arXiv: 2304.11015 [cs.CL]. URL: https://arxiv.org/abs/2304.11015.