Шинжлэх Ухаан, Технологийн Их Сургууль
Мэдээлэл, Холбооны Технологийн Сургууль




Батчулуун Очир

# Том хэлний загварт (LLM) суурилсан Text-to-SQL агентыг хөгжүүлэх нь

Бакалаврын төгсөлтийн ажил

Улаанбаатар хот

Шинжлэх Ухаан, Технологийн Их Сургууль
Мэдээлэл, Холбооны Технологийн Сургууль

Компьютерын ухааны тэнхим

# Том хэлний загварт (LLM) суурилсан Text-to-SQL агентыг хөгжүүлэх нь

Мэргэжлийн индекс: 061902000000002306
Мэргэжил: Хиймэл оюун

*Удирдагч:* Доктор (Ph.D) Д.Золзаяа
*Зөвлөгч:* Б.Батзолбоо
*Гүйцэтгэгч:* Б.Очир

Улаанбаатар хот
2026 он

Батлав. Удирдагч: ..... /Доктор (Ph.D) Д.Золзаяа/

# ТӨГСӨЛТИЙН АЖЛЫН ТӨЛӨВЛӨГӨӨ

**Сэдэв: «Том хэлний загварт (LLM) суурилсан Text-to-SQL агентыг хөгжүүлэх нь»**

| № | Ажлын бүлгийн нэр | Эзлэх хувь | Дуусах хугацаа |
|---|---|---|---|
| 1 | Оршил | 5% | 2026-09-30 |
| 2 | Холбоотой ажлуудын судалгаа | 12% | 2026-09-30 |
| 3 | Арга зүй ба дэвшүүлсэн санаа | 12% | 2026-10-28 |
| 4 | Өгөгдөл боловсруулалт | 10% | 2026-10-28 |
| 5 | Загвар хөгжүүлэлт ба урсгал | 15% | 2026-10-28 |
| 6 | Туршилтын системийн хэрэгжүүлэлт | 12% | 2026-11-25 |
| 7 | Үр дүн ба хэлэлцүүлэг | 16% | 2026-11-25 |
| 8 | Ёс зүйн асуудал | 8% | 2026-11-25 |
| 9 | Дүгнэлт | 10% | 2026-12-16 |

Төлөвлөгөөг боловсруулсан оюутан: ..... /Б.Очир/

# ТӨГСӨЛТИЙН АЖЛЫН ХИЙГДСЭНИЙ ХУГАЦАА

| № | Хийж гүйцэтгэх ажил | Биелэх хугацаа | Удирдагчийн гарын үсэг |
|---|---|---|---|
| 1 | Үзлэг 1 | 2026-09-30 | |
| 2 | Үзлэг 2 | 2026-10-28 | |
| 3 | Үзлэг 3 | 2026-11-25 | |
| 4 | Урьдчилан хамгаалалт | 2026-12-23 | |
| 5 | Үндсэн хамгаалалт | Нэгдсэн хуваарийн дагуу | |

**Ажлын товч дүгнэлт**

.....

.....

.....

.....

Удирдагч: ..... /Доктор (Ph.D) Д.Золзаяа/

## ЗӨВШӨӨРӨЛ

Оюутан Б.Очир-ийн бичсэн төгсөлтийн ажлыг ШУТИС-д хамгаалуулахаар тодорхойлов.

Тэнхимийн эрхлэгч: ..... /Доктор (PhD), дэд проф. А.Хүдэр/

Шинжлэх Ухаан, Технологийн Их Сургууль
Мэдээлэл, Холбооны Технологийн Сургууль

**ШҮҮМЖЛЭГИЙН ХУУДАС**

Компьютерын ухааны тэнхимийн төгсөх курсийн оюутан Б.Очир-ийн «Том хэлний загварт (LLM) суурилсан Text-to-SQL агентыг хөгжүүлэх нь» сэдэвт төгсөлтийн ажлын шүүмж.

1. Сэдвээр дэвшүүлсэн асуудал, үүнтэй холбоотой онолын материалыг яаж судалсан байдал.
   .....
   .....

2. Ажлын ерөнхий агуулга. Шийдсэн зүйлүүд, гаргасан үр дүн.
   .....
   .....

3. Эмх цэгцтэй, стандарт хангасан байдал.
   .....
   .....

4. Давуу тал болон дутуу зүйлүүд.
   .....
   .....

5. Анхаарч тэмдэглэх зүйлүүд.
   .....
   .....

6. Ерөнхий оноо. (5 оноо)
   .....
   .....

Шүүмж бичсэн: ..... /...../

Ажлын газар: .....

Хаяг (Утас): .....

# Зохиогчийн эрх хамгаалал

Миний бие Б.Очир, «Том хэлний загварт (LLM) суурилсан Text-to-SQL агентыг хөгжүүлэх нь» сэдэвт энэ ажил нь минийх бөгөөд дараахыг нотолж байна. Үүнд:

- Горилогч энэ ажлыг тус сургуулиас боловсролын зэрэг авахаар бүхэлд нь буюу голлон хийсэн болно.
- Энэ ажлын аль нэг хэсгийг тус сургуульд эсвэл өөр байгууллагад боловсролын зэрэг, мэргэшил авахаар өмнө нь илгээсэн бол түүнийгээ тодорхой заасан болно.
- Бусад хүмүүсийн хэвлүүлсэн ажлаас зөвлөгөө авсан бол түүнийгээ үндэслэсэн болно.
- Бусад хүмүүсийн ажлаас ишлэл хийхдээ эх үүсвэрийг нь заасан болно.
- Миний ажилд тусалсан голлох бүх эх үүсвэрт талархаж байна.
- Ажлыг бусадтай хамтарсан бол алийг нь бусад хүмүүс хийсэн болохыг тодорхой заасан болно.

Гарын үсэг: _____

Огноо: _____

Шинжлэх Ухаан, Технологийн Их Сургууль
Мэдээлэл, Холбооны Технологийн Сургууль

# Хураангуй

## Том хэлний загварт (LLM) суурилсан Text-to-SQL агентыг хөгжүүлэх нь

Б.Очир

***Түлхүүр үгс: «Text2SQL», монгол хэл, том хэлний загвар, «RAG», машин орчуулга, «LoRA», санал хураалт, ББСБ, «PostgreSQL»***

Санхүүгийн байгууллагын ажилтнууд өгөгдлийн сангаас тоо мэдээ авахдаа SQL бичдэг шинжээчээс хамаардаг. Байгалийн хэлний асуултыг SQL болгох (Text2SQL) системүүд англи хэлний Spider, BIRD жишиг дээр өндөр үр дүн үзүүлж байгаа ч монгол хэлэнд зориулсан систем, үнэлгээний сан, туршилтын нотолгоо бараг байхгүй. Монгол хэлний залгамал үгзүй, кирилл ба латин галигийн холимог бичлэг, өгөгдлийн санд монголоор хадгалагдсан утга, байгууллагын дотоод нэр томьёо (PAR30, идэвхтэй багц) нь англи хэлэнд боловсруулсан аргуудыг шууд хэрэглэхэд саад болдог. Мөн өгөгдөл гадагш гарах ёсгүй тул нэг GPU-д багтах нээлттэй эхийн загвар ашиглах шаардлагатай.

Энэхүү ажлаар банк бус санхүүгийн байгууллагын (ББСБ) 28 хүснэгт бүхий PostgreSQL өгөгдлийн сан (648 205 мөр синтетик өгөгдөл) дээр монгол асуултад хариулах Text2SQL системийг нээлттэй эхийн Arctic-Text2SQL-R1-7B загвар дээр бүтээж, бүрэлдэхүүн бүрийн нөлөөг хяналттай туршилтаар хэмжив. Үүний тулд dev 300, test 200 асуулт бүхий монгол үнэлгээний сан (хариулах боломжгүй ба хоёрдмол асуулттай) бэлтгэж, загварын гэр бүлээр нь давхцалгүй хуваав. Систем нь асуултыг шалгах (хувийн мэдээлэл, бичих хүсэлтээс татгалзах), Qwen3.5-9B-ээр англи руу орчуулах (утгыг маскаар хамгаалах), мэдлэг хайх (BM25 ба BGE-M3: хүснэгт, утга, нэр томьёо, жишээ), өөрийн DB-ийн RAG prompt-оор LoRA-аар нэмж сургасан загвараар SQL үүсгэх, алдааг засах, 8 хувилбараас гүйцэтгэлийн үр дүнгээр санал хураах, итгэл багатай үед тодруулга асуух алхмуудаас бүрдэнэ. Мөн туршилтын тохиргоог node-оор угсарч, алхам бүрийн prompt ба мэдлэгийг харуулдаг «Text2SQL Studio» вэб хэрэгслийг хөгжүүлэв.

Dev дээр нийт зөв хариулт суурь загварын 2.3%-иас (RAG-гүй) 53.0% хүртэл өсөв. Шинэ асуултаас бүрдсэн test дээр нэмэлт сургалттай суурь (D2) 21.0% байсан бол орчуулга ба засвартай H4 34.0% (McNemar $p = 8.6 \times 10^{-4}$), 8 хувилбарын санал хураалттай E2 38.5% (хариулах боломжтой асуултын EX 41.1%), тодруулгатай E3c 46.5%, жишээний сан ба орчуулгын засвартай I3tr 45.0% болов. Бүрэлдэхүүнээр нь задлахад мэдлэг хайх (+12.0 пункт) ба орчуулга (+11.3) хамгийн их, өөрийн DB-ийн жишээгүй нэмэлт сургалт (+1.4) хамгийн бага нэмэр өгсөн. Алдааны шинжилгээгээр E2-ийн алдааны 38% нь орчуулгаас үүдсэн тул санхүүгийн хэллэгийн 2 828 хос бүхий орчуулгын өгөгдөл ба схем, тодорхойлолт өөрчлөгдөхөд тогтвортой байх SQL бичигчийн сургалтын өгөгдлийг бэлтгэв. Ажлын гол хувь нэмэр нь монгол хэлний анхны Text2SQL үнэлгээний сан, бүрэлдэхүүн тус бүрийн нөлөөг статистик тестээр баталсан туршилт, нэг GPU дээр ажиллах давтагдахуйц систем болон судалгааны хэрэгсэл юм.

# Талархал

Энэхүү ажлыг гүйцэтгэх явцад судалгааны чиглэлийг тодорхойлох, туршилтын арга зүйг боловсруулахад үнэтэй зөвлөгөө өгсөн удирдагч багш Доктор (Ph.D) Д.Золзаяа, зөвлөгч багш Б.Батзолбоо нарт чин сэтгэлийн талархал илэрхийлье.

Мөн ажлын турш дэмжиж, урам зориг өгсөн гэр бүл, найз нөхөддөө талархлаа илэрхийлье.

# Товчилсон үгс

| | |
|---|---|
| **ББСБ** | Банк бус санхүүгийн байгууллага |
| **LLM** | **L**arge **L**anguage **M**odel (том хэлний загвар) |
| **Text2SQL** | Байгалийн хэлний асуултыг SQL болгон хөрвүүлэх даалгавар |
| **SQL** | **S**tructured **Q**uery **L**anguage |
| **RAG** | **R**etrieval-**A**ugmented **G**eneration |
| **SFT** | **S**upervised **F**ine-**T**uning |
| **RL** | **R**einforcement **L**earning |
| **GRPO** | **G**roup **R**elative **P**olicy **O**ptimization |
| **LoRA** | **Lo**w-**R**ank **A**daptation |
| **CoT** | **C**hain-**o**f-**T**hought |
| **EX** | **Ex**ecution accuracy (гүйцэтгэлийн нарийвчлал) |
| **TS-EX** | **T**est-**S**uite execution accuracy |
| **BM25** | **B**est **M**atching 25 (түлхүүр үгийн хайлтын оноо) |
| **DDL** | **D**ata **D**efinition **L**anguage |
| **RLS** | **R**ow-**L**evel **S**ecurity |
| **PII** | **P**ersonally **I**dentifiable **I**nformation |
| **GPU** | **G**raphics **P**rocessing **U**nit |
| **vLLM** | LLM-ийн өндөр хурдны inference сервер |
| **BIRD** | **B**ig Bench for Large-scale Database Grounded Text-to-SQL Evaluation |
| **KPI** | **K**ey **P**erformance **I**ndicator |
| **JSONL** | JSON **L**ines (мөр бүр нэг JSON бичлэг) |
| **AML** | **A**nti-**M**oney **L**aundering (мөнгө угаахтай тэмцэх) |
| **CTE** | **C**ommon **T**able **E**xpression (SQL-ийн `WITH` дэд асуулга) |
| **HF** | **H**ugging **F**ace (загварын сан) |
| **KL** | **K**ullback–**L**eibler зөрүү |
| **KYC** | **K**now **Y**our **C**ustomer (харилцагчийг таних) |
| **LCS** | **L**ongest **C**ommon **S**ubsequence |
| **LR** | **L**earning **R**ate (сургалтын алхмын хэмжээ) |
| **LSH** | **L**ocality-**S**ensitive **H**ashing |
| **PAR30** | **P**ortfolio **a**t **R**isk 30 (30 хоногийн босготой хугацаа хэтэрсэн багцын хувь) |
| **SOV** | **S**ubject–**O**bject–**V**erb үгийн дараалал |
| **TRL** | **T**ransformer **R**einforcement **L**earning (Hugging Face-ийн сан) |
| **YAML** | YAML Ain't Markup Language (тохиргооны файлын формат) |
| **MT** | **M**achine **T**ranslation (машин орчуулга) |
| **QLoRA** | **Q**uantized **LoRA** (4 битээр шахсан жин дээрх LoRA) |
| **chrF++** | Тэмдэгт ба үгийн n-gram-д суурилсан орчуулгын чанарын хэмжүүр |
| **NPL** | **N**on-**P**erforming **L**oan (чанаргүй зээл) |
| **RQ** | **R**esearch **Q**uestion (судалгааны асуулт) |

# Гарчиг

**Зохиогчийн эрх хамгаалал** **i**

**Хураангуй** **ii**

**Талархал** **iii**

**Товчилсон үгс** **iv**

**Оршил** **1**
Судалгааны үндэслэл, орчин . . . . . 1
Асуудлын тодорхойлолт . . . . . 1
Таамаглал . . . . . 2
Зорилго . . . . . 2
Зорилтууд . . . . . 2
Хамрах хүрээ ба хязгаарлалт . . . . . 2
Судалгааны хувь нэмэр . . . . . 3
Ажлын бүтэц . . . . . 3

**1 Холбоотой ажлуудын судалгаа** **4**
1.1 Холбоотой судалгаанууд . . . . . 4
1.2 Ижил төстэй бүтээгдэхүүний судалгаа . . . . . 5
1.3 Харьцуулсан шинжилгээ . . . . . 6
1.4 Судалгааны цоорхой . . . . . 7
1.5 Бүлгийн дүгнэлт . . . . . 7

**2 Арга зүй ба дэвшүүлсэн санаа** **8**
2.1 Санал болгож буй загвар ба архитектур . . . . . 8
2.2 Системийн архитектурын дэлгэрэнгүй тайлбар . . . . . 8
2.3 SQL үүсгэх загвар . . . . . 10
2.4 Орчуулгын загвар ба мэдлэг хайлт . . . . . 11
2.5 Бүлгийн дүгнэлт . . . . . 11

**3 Өгөгдөл боловсруулалт** **12**
3.1 SQL үүсгэх загварын өгөгдөл . . . . . 12
3.2 Орчуулгын загварын өгөгдөл . . . . . 13
3.3 Өгөгдлийн нэгдсэн үзүүлэлт ба хуваалт . . . . . 13
3.4 Бүлгийн дүгнэлт . . . . . 14

**4 Загвар хөгжүүлэлт ба урсгал** **15**
4.1 SQL үүсгэх загвар хөгжүүлэлт ба сургалтын арга зүй . . . . . 15
4.2 Орчуулгын загвар хөгжүүлэлт ба сургалтын арга зүй . . . . . 16
4.3 Бүлгийн дүгнэлт . . . . . 17

**5 Туршилтын системийн хэрэгжүүлэлт** **18**
5.1 Системийн ерөнхий бүтэц . . . . . 18
5.2 Асуулт хүлээн авах ба шалгах . . . . . 18
5.3 Асуултыг орчуулах . . . . . 18
5.4 Мэдлэг хайх ба prompt угсрах . . . . . 18
5.5 SQL үүсгэх, засах ба сонгох . . . . . 19
5.6 Аюулгүй гүйцэтгэл ба аудит . . . . . 19
5.7 Text2SQL Studio дээр дүрслэх . . . . . 20
5.8 Загварын үндсэн зарчмууд . . . . . 21
5.9 Системийн хязгаарууд ба цаашдын ажил . . . . . 21
5.10 Бүлгийн дүгнэлт . . . . . 21

**6 Үр дүн ба хэлэлцүүлэг** **22**
6.1 SQL үүсгэх загварын үр дүн . . . . . 22
6.2 Орчуулгын загварын үр дүн . . . . . 24
6.3 Системийн хугацааны хоцрогдлын үнэлгээ . . . . . 25
6.4 Зорилго ба таамаглалын биелэлт . . . . . 26
6.5 Ёс зүйн асуудал . . . . . 26
6.6 Бүлгийн дүгнэлт . . . . . 26

**Дүгнэлт** **28**

**А Ажиллуулах тушаалууд** **30**

**Б Төслийн файлын бүтэц** **31**

**В Туршилтын тохиргооны жагсаалт** **32**

**Г Ажлын түүх** **34**

**Ном зүй** **35**

# Зургийн жагсаалт

2.1 Санал болгож буй дамжлага (улбар шар: загвар ашигладаг алхам) . 8
2.2 Нэг асуултын дарааллын диаграм (E2 тохиргоо) . . . . . 10

5.1 Text2SQL Studio: дамжлагын алхмууд (зүүн), асуулт ба хариулт (баруун), демо горим . . . . . 20

6.1 Dev дээрх ахицын зам (нийт зөв, %) . . . . . 22

# Хүснэгтийн жагсаалт


1.1 Ижил төстэй бүтээгдэхүүний харьцуулалт . . . . . 6
1.2 Холбоотой судалгааны харьцуулалт . . . . . 7

2.1 Функциональ ба функциональ бус шаардлага . . . . . 9
2.2 SQL үүсгэх загварын үзүүлэлт . . . . . 11
2.3 Туслах загваруудын үзүүлэлт . . . . . 11

3.1 Мэдлэгийн сангийн бүрэлдэхүүн . . . . . 12
3.2 Орчуулгын өгөгдөл (MT v2) . . . . . 13
3.3 Үнэлгээний сангийн хуваалт ба ангилал . . . . . 13
3.4 Үнэлгээний сангийн жишээ асуултууд . . . . . 14
3.5 Өгөгдлийн чанарын нэгдсэн үзүүлэлт . . . . . 14

4.1 Суурь загвар (A бүлэг), dev 300, Kaggle T4 . . . . . 15
4.2 Гүйцэтгэсэн сургалтууд . . . . . 15
4.3 B ба C, D бүлэг, dev 300 . . . . . 16
4.4 Бүрэлдэхүүн тус бүрийн нөлөө (dev 300, нийт зөв, %) . . . . . 16
4.5 MADLAD-400-3B-MT-ийн QLoRA сургалтын гипер-параметр . . . . 17

5.1 Кодын бүтэц . . . . . 18
5.2 Системийн дизайны үндсэн зарчмууд . . . . . 21

6.1 Dev-ийн үр дүн (задаргаатай) . . . . . 22
6.2 Test-ийн үр дүн . . . . . 22
6.3 McNemar тест (exact) . . . . . 23
6.4 E2-ийн алдааны ангилал (dev, хариулах боломжтой 124 буруу) . . . 23
6.5 Хариулах боломжтой асуултын зөв, домэйн ба хүндрэлээр (dev) . . . 24
6.6 Орчуулгын үзүүлэлт (dev, 300 асуулт) . . . . . 25
6.7 Тохиргооны асуулт тутмын дундаж хугацаа (Kaggle T4×2) . . . . . 25
6.8 Зорилго ба таамаглалын биелэлт . . . . . 26
6.9 Зорилгын биелэлтийн нэгтгэл . . . . . 28

B.1 Ажиллуулсан болон бэлэн тохиргоонууд (`config/experiments.yaml`) . 32

Г.1 Ажлын гол үе шат . . . . . 34

# Оршил

## Судалгааны үндэслэл, орчин

Банк бус санхүүгийн байгууллагын (ББСБ) өдөр тутмын шийдвэр тоо мэдээнд тулгуурладаг: салбар бүрийн хугацаа хэтэрсэн зээлийн үлдэгдэл, сарын шинэ зээлийн тоо, барагдуулалтын үр дүн гэх мэт. Эдгээр мэдээллийг өгөгдлийн сангаас авахдаа ажилтнууд SQL бичих чадвартай шинжээч эсвэл урьдчилан бэлтгэсэн тайланд хамаардаг. Шинэ асуулт гарах бүрд хүсэлт илгээж хүлээх нь цаг алддаг бөгөөд шинжээчийн ачааллыг нэмэгдүүлдэг.

Байгалийн хэлний асуултыг SQL болгох (Text2SQL) системүүд том хэлний загварын (LLM) хөгжлийн хэрээр англи хэлний жишгүүд дээр өндөр түвшинд хүрсэн [1, 2]. Нээлттэй эхийн 7B хэмжээтэй Arctic-Text2SQL-R1 загвар BIRD-ийн test дээр 68.5% гүйцэтгэлийн нарийвчлал (EX) үзүүлдэг [3]. Гэвч англи бус хэл дээр эдгээр загварын нарийвчлал мэдэгдэхүйц буурдаг [4, 5]. Санхүүгийн өгөгдөл байгууллагаас гадагш гарах ёсгүй тул арилжааны API-д суурилсан шийдэл тохиромжгүй бөгөөд нэг GPU-д багтах нээлттэй эхийн загварыг монгол хэл ба байгууллагын домэйнд тохируулах шаардлагатай.

## Асуудлын тодорхойлолт

Монгол асуулт $q$, өгөгдлийн сангийн схем $S$ ба байгууллагын мэдлэг $K$ (баганын тайлбар, нэр томьёо, жишээ) өгөгдсөн үед гүйцэтгэлийн үр дүн нь лавлах (gold) SQL-ийнхтэй таарах SQL $\hat{s}$-ийг үүсгэх, эсвэл асуулт хариулах боломжгүй (хувийн мэдээлэл, өгөгдөлд байхгүй) бол татгалзах, хоёрдмол бол тодруулга асуух шаардлагатай. Энэ даалгаврыг дараах бэрхшээлүүд хүндрүүлнэ:

1. **Бага нөөцтэй хэл.** Монгол Text2SQL-ийн сургалтын ба үнэлгээний өгөгдөл байхгүй, загварууд монгол хэлийг сул ойлгодог [6]. Хэрэглэгчид кирилл ба латин галигаар («zeeliin hvselt») холимог бичдэг.

2. **Домэйны мэдлэг.** «PAR30», «идэвхтэй багц» зэрэг нэр томьёоны тодорхойлолт байгууллагын дотоод дүрмээс хамаардаг [2].

3. **Том схем.** 28 view, 425 багана бүхий схемийг бүтнээр нь өгөхөд prompt 13–20 мянган токен болж, жижиг загварын анхаарлыг сарниулдаг.

4. **Найдвартай байдал.** Санхүүгийн хэрэглээнд буруу тоо хариулахаас татгалзах нь дээр [7].

## Таамаглал

**H1:** Мэдлэг хайлт (схемийн тайлбар, утга, нэр томьёо, жишээ) нь нийт зөв хариултыг 10-аас дээш пунктээр өсгөнө.

**H2:** Англи төвтэй SQL загварт монгол асуултыг англи руу орчуулж өгөх нь шууд өгөхөөс статистикийн ач холбогдолтой ($p < 0.05$) илүү үр дүн өгнө.

**H3:** Өөрийн өгөгдлийн сангийн RAG prompt-оор нэмж сургасан (fine-tune) загвар RAG-тай суурь загварыг давна.

**H4:** Олон хувилбараас гүйцэтгэлийн үр дүнгээр санал хураах нь хариулах боломжтой асуултын нарийвчлалыг ач холбогдолтой өсгөнө.

## Зорилго

ББСБ-ийн өгөгдлийн сан дээр монгол хэлээр асуусан асуултыг автоматаар SQL болгож хариулдаг систем бүтээх.

## Зорилтууд

Дээрх зорилгод хүрэхийн тулд сэдэв батлах даалгаврын дагуу дараах зорилтуудыг дэвшүүлэв:

1. Өгөгдлийн сангийн схем, утга, бизнесийн нэр томьёо, жишээ асуултаас мэдлэгийн сан (RAG) бүрдүүлэх;
2. Асуулт бүрд хамааралтай мэдээллийг хайж олоод загварт өгөх prompt болон pipeline боловсруулах;
3. Загварыг монгол хэл болон өөрийн өгөгдлийн санд тохируулан сургах (fine-tune);
4. Хариултын зөв байдлыг нэмэгдүүлэх: олон хувилбараас сонгох, алдааг засах, хариулах боломжгүй асуултаас татгалзах;
5. Системийн үр дүнг тестийн асуултын багцаар хэмжиж үнэлэх, тайлагнах.

## Хамрах хүрээ ба хязгаарлалт

**Хамрах хүрээ:**

- ББСБ-ийн PostgreSQL өгөгдлийн сан (28 view бүхий text2sql давхарга) дээрх монгол асуултад SQL үүсгэх систем;
- Кирилл болон латин галигаар бичсэн асуулт, хариулах боломжгүй ба хоёрдмол асуултыг таних;
- Нэг GPU-д ажиллах нээлттэй эхийн загвар (SQL бичигчээр зөвхөн Arctic-Text2SQL-R1-7B).

**Хязгаарлалт:**

- Бодит харилцагчийн мэдээлэл ашиглах эрхгүй тул детерминист синтетик өгөгдөл (seed 42, 2026-06-30-ны байдлаар) ашиглав;

- Өөрийн GPU сервергүй тул үнэлгээг Kaggle T4×2 (долоо хоногт 30 цаг), сургалтыг Modal ба Vast.ai-ийн A100 дээр хязгаарлагдмал төсвөөр хийсэн; иймд төлөвлөгөөний зарим туршилт (GRPO, agentic горим) хийгдээгүй;
- Гол хэмжилт кирилл асуулт дээр хийгдсэн; бодит хэрэглээний (production) баталгаажуулалт хамрагдаагүй.

## Судалгааны хувь нэмэр

1. Хариулах боломжгүй ба хоёрдмол асуулттай, кирилл, латин, англи хувилбартай, загварын гэр бүлээр хуваасан 500 асуулт бүхий монгол хэлний Text2SQL үнэлгээний сан;
2. Мэдлэг хайлт, орчуулга, нэмэлт сургалт, санал хураалт тус бүрийн нөлөөг нэг схем, нэг үнэлгээн дээр McNemar тестээр харьцуулсан эмпирик нотолгоо;
3. Алдааны эх үүсвэрийн хэмжилт ба түүнд тулгуурласан санхүүгийн хэллэгийн орчуулгын өгөгдөл (2 828 хос);
4. Үнэгүй үүлэн квот дээр тасалдлаас сэргэдэг туршилтын систем, алхам бүрийн prompt ба мэдлэгийг харуулдаг «Text2SQL Studio» хэрэгсэл.

## Ажлын бүтэц

Бүлэг 1-т холбоотой судалгаа ба ижил төстэй бүтээгдэхүүнийг тоймлож судалгааны цоорхойг тодорхойлно. Бүлэг 2-т санал болгож буй архитектур, SQL бичигч ба орчуулгын загварын онолын үндсийг, Бүлэг 3-т өгөгдлийн сан, мэдлэгийн сан, сургалтын ба үнэлгээний өгөгдлийг, Бүлэг 4-т загваруудын сургалтын урсгал ба туршилтын тохиргоог тайлбарлана. Бүлэг 5-д туршилтын системийн хэрэгжүүлэлтийг, Бүлэг 6-д үр дүн, хэлэлцүүлэг ба ёс зүйн асуудлыг авч үзээд, эцэст нь Дүгнэлт хэсэгт нэгтгэн дүгнэнэ.

БҮЛЭГ 1

# Холбоотой ажлуудын судалгаа

Энэ бүлэгт Text2SQL, мэдлэг хайлт, олон хэлт ба бага нөөцтэй хэлний чиглэлээр хийгдсэн судалгаа болон зах зээл дээрх ижил төстэй бүтээгдэхүүнийг тоймлож, тэдгээрийн арга зүй, хязгаарлалтыг харьцуулан шинжилнэ. Ингэснээр энэхүү ажлын онол-аргазүйн суурийг тодорхойлж, шийдвэрлэх судалгааны цоорхойг илрүүлнэ.

## 1.1 Холбоотой судалгаанууд

### Text2SQL даалгавар ба жишиг үнэлгээ

Shi нар Text2SQL-ийн хөгжлийг дүрэмд суурилсан, Seq2Seq, урьдчилан сургасан хэлний загвар, LLM гэсэн үе шатаар тодорхойлсон [1]. Spider [8] олон хүснэгттэй, урьд үзээгүй схемд ерөнхийлөх даалгаврыг, BIRD [2] бодит «бохир» өгөгдөл, том схем, гадаад мэдлэг (evidence) шаарддаг нөхцөлийг тавьсан. Нэг асуултад олон зөв SQL байж болох тул текстээр бус гүйцэтгэлийн үр дүнгээр (EX) үнэлдэг; санамсаргүй таарахаас сэргийлэхийн тулд өгөгдлийг өөрчилсөн хэд хэдэн хуулбар DB дээр шалгах test-suite аргыг санал болгосон [9]. TrustSQL нь хариулах боломжгүй асуултыг оруулж, зөв татгалзалтыг зөв хариулттай адил тооцдог [7]; AMBROSIA, AmbiQT нь нэг асуулт олон зөв тайлбартай байж болохыг харуулсан [10, 11].

### Нээлттэй эхийн тусгай Text2SQL загварууд

OmniSQL нь 2.5 сая синтетик хосоор Qwen2.5-Coder-ийг сургаж, 7B загварыг том ерөнхий загваруудтай өрсөлдөхүйц болгосон [12, 13]. Arctic-Text2SQL-R1 нь OmniSQL-оос эхлүүлж, зөвхөн гүйцэтгэлд суурилсан энгийн reward-аар (1: зөв, 0.1: ажилласан ч буруу, 0: алдаа) GRPO [14] хийсэн. Түүний 32B хувилбар BIRD-ийн самбарт 71.83%-иар тэргүүлсэн бол энэ ажилд ашигласан 7B хувилбар BIRD test дээр 68.5% EX авсан [3]. Эдгээр загвар англи өгөгдлөөр сургагдсан тул англи бус асуултад хэр ажиллах нь тодорхойгүй хэвээр байна.

### Мэдлэг хайлт ба жишээ сонголт

RAG нь загварын параметрт байхгүй мэдлэгийг хайлтаар олж prompt-д нэмдэг [15]. Text2SQL-д схемийн тайлбар, хадгалагдсан утга, бизнес нэр томьёо, төстэй асуулт–SQL жишээг хайдаг. CHESS нь утгыг LSH-ээр [16], CodeS нь BM25 ба LCS-ээр [17] хайдаг. DAIL-SQL нь асуултын утгыг далдалж, бүтцээр нь жишээ сонгох нь few-shot-ийн чанарыг сайжруулдгийг харуулсан [18]. Schema linking нь хүчтэй загварт ашиггүй ч жижиг загварт EX-ийг өсгөж болно [19].

### Олон хувилбар, засвар ба найдвартай байдал

Self-consistency нь хэд хэдэн хариу үүсгэж олонхоор сонгоно [20]; Text2SQL-д нэр дэвшигч SQL-ийг гүйцэтгээд үр дүнгээр санал хураадаг. CHASE-SQL олон генератор ба сонгогчийг хослуулах нь ганц генератороос илүү болохыг харуулсан [21]. Харин гадаад дохиогүй self-correction нь заримдаа зөв хариултыг эвддэг [22].

### Олон хэлт ба бага нөөцтэй хэлний Text2SQL

MultiSpider нь Spider-ийг 6 хэл рүү орчуулж англи бус хэл дээр нарийвчлал буурдгийг [4], MultiSpider 2.0 дээр хамгийн сайн загварууд ч 4% EX авсныг [5] харуулсан. IndicDB нь латинаар бичсэн, англитай холилдсон асуултын нөлөөг [23], TUR2SQL ба BIRDTurk нь турк хэлийг [24, 25], Dialect2SQL нь араб аялгууг [26] судалсан. Translate-test стратеги (асуултыг англи руу орчуулж англи төвтэй загварт өгөх)

ихэвчлэн үр дүнтэй [27, 28] боловч Text2SQL-д нэр, утга гажих эрсдэлтэй [23]. Монгол хэлний хувьд MM-Eval нь загваруудын утга зүй, сэтгэн бодох чадвар сул [6], MonCulture-Eval нь бичиг хоорондын зөрүү байгааг [29] харуулсан. Өмнөх дипломын ажил [30] өөр схем дээр Planner → Writer → Critic агентын урсгалыг судалсан.

### Үйлдвэрлэлийн системүүд

Uber QueryGPT нь workspace ба тусгай агентуудтай, бүрэлдэхүүн бүрийг тусад нь үнэлдэг [31]. LinkedIn SQL Bot нь мэдлэгийн граф ашиглаж, асуулгыг EXPLAIN-ээр шалгадаг [32]. Эдгээр нь Text2SQL-ийг ганц загвар биш, олон бүрэлдэхүүнтэй систем гэж үзэх хандлагыг харуулдаг.

## 1.2 Ижил төстэй бүтээгдэхүүний судалгаа

Байгалийн хэлээр өгөгдлөөс асуулт асуух боломжийг өгөгдлийн платформ ба BI хэрэгслүүд бүтээгдэхүүн болгон санал болгож байна. Тэдгээрийн мэдлэгээ хэрхэн авдаг, хаана ажилладаг, монгол хэл дэмжих эсэхийг судлав (албан ёсны баримт бичгээс, 2026 оны 10-р сарын байдлаар).

### Олон улсын арилжааны бүтээгдэхүүн

**Snowflake Cortex Analyst.** Snowflake-ийн өгөгдлийн агуулах дээр ажиллах Text2SQL үйлчилгээ. Хүснэгт, баганын тайлбар, синоним, баталгаажсан жишээ асуулгыг YAML хэлбэрийн *semantic model*-д бичиж өгдөг; зөвхөн схем өгөхөд ерөнхий Text2SQL алддаг асуудлыг энэ загвар нөхдөг гэж баримт бичигт тайлбарласан [33].

**Databricks AI/BI Genie.** Нэг сэдвийн хүснэгтүүд, ерөнхий заавар, жишээ SQL асуулга, SQL функцээс бүрдэх «Genie space» үүсгэж, асуултад тохирох жишээг сонгон SQL үүсгэдэг. Нэг space-д 100 хүртэл заавар (жишээ асуулга бүр нэгд тооцогдоно) оруулж болно [34].

**Microsoft Power BI Q&A ба Copilot.** Q&A нь өгөгдлийн загварын синоним, хэл зүйн харилцаа (linguistic schema)-д тулгуурласан байгалийн хэлний асуулт хариулт бөгөөд Copilot нь синоним санал болгож тохиргоог хөнгөвчилдөг [35].

**Amazon QuickSight Q.** Нэг сэдвийн dataset-үүдийг «topic» болгож, талбарын нэр, синонимыг автоматаар бэлтгээд бизнесийн нэмэлт тодорхойлолтыг зохиогч оруулдаг [36].

### Нээлттэй эхийн бүтээгдэхүүн

**Vanna.** DDL, баримт бичиг, жишээ SQL-ээр «сургасан» (индексжүүлсэн) RAG-д суурилж SQL үүсгэдэг MIT лицензтэй Python сан; локал LLM-тэй ажиллах боломжтой [37].

**Wren AI.** Бизнесийн тодорхойлолт, жишээ, хяналтыг агуулсан semantic layer (MDL)-тэй нээлттэй эхийн «GenBI» систем [38].

### Монгол хэлний бүтээгдэхүүн

Монгол хэлээр өгөгдлийн сангаас асуулт асуух олон нийтэд нээлттэй бүтээгдэхүүн бидний хайлтаар олдсонгүй. Дээрх бүтээгдэхүүнүүд олон хэлт LLM ашигладаг тул монгол асуулт хүлээн авч болох ч монгол хэл дээрх нарийвчлалын талаар мэдээлэл

нийтлээгүй бөгөөд арилжааны хувилбарууд нь өгөгдлийг тухайн үүлэн платформд байршуулахыг шаарддаг.

Хүснэгт 1.1: Ижил төстэй бүтээгдэхүүний харьцуулалт

| Бүтээгдэхүүн | Ажиллах орчин | Мэдлэг өгөх арга | Нээлттэй эх | Монгол хэл |
|---|---|---|---|---|
| Cortex Analyst | Snowflake үүл | Semantic model (YAML): тайлбар, синоним, жишээ асуулга | үгүй | хэмжээгүй |
| AI/BI Genie | Databricks үүл | Заавар, жишээ SQL, SQL функц | үгүй | хэмжээгүй |
| Power BI Q&A / Copilot | Microsoft үүл | Синоним, linguistic schema | үгүй | хэмжээгүй |
| QuickSight Q | AWS үүл | Topic, синоним, бизнес тодорхойлолт | үгүй | хэмжээгүй |
| Vanna | өөрийн сервер | DDL, баримт бичиг, жишээ SQL (RAG) | тийм (MIT) | хэмжээгүй |
| Wren AI | өөрийн сервер | Semantic layer (MDL) | тийм (Apache 2.0) | хэмжээгүй |
| **Энэ ажил** | **байгууллагын дотор, нэг GPU** | **Тайлбар, утга, нэр томьёо, жишээ (RAG) + LoRA сургалт** | **тийм** | **кирилл, латин; хэмжсэн** |

Бүтээгдэхүүнүүдийн нийтлэг санаа нь схемээс гадна бизнесийн мэдлэгийг (тайлбар, синоним, жишээ асуулга) тусад нь бүрдүүлж өгөх явдал бөгөөд энэ нь бидний мэдлэгийн сангийн хандлагыг баталж байна. Харин тэдгээр нь (1) монгол хэл дээр нарийвчлалаа хэмжээгүй, (2) ихэнх нь гадны үүлэн платформд өгөгдөл байршуулахыг шаарддаг, (3) хариулах боломжгүй асуултаас татгалзах, тодруулга асуух чадвараа тоогоор үнэлээгүй.

## 1.3 Харьцуулсан шинжилгээ

Хүснэгт 1.2-т гол судалгаануудыг энэ ажилтай харьцуулав.

Хүснэгт 1.2: Холбоотой судалгааны харьцуулалт

| Ажил | Хэл | Загвар | RAG | Сургалт | Татгалзах | Онцлог |
|---|---|---|---|---|---|---|
| DAIL-SQL [18] | англи | GPT-4 | жишээ | — | — | Жишээ сонголт |
| CHESS [16] | англи | хаалттай | утга, схем | — | — | Утгын хайлт (LSH) |
| OmniSQL [12] | англи | 7–32B нээлттэй | — | SFT | — | 2.5 сая синтетик хос |
| Arctic-R1 [3] | англи | 7–32B нээлттэй | — | GRPO | — | Гүйцэтгэлийн reward |
| TrustSQL [7] | англи | олон | — | — | тийм | Хариулах боломжгүй асуулт |
| MultiSpider [4] | 7 хэл | олон | — | SFT | — | Олон хэлний зөрүү |
| BIRDTurk [25] | турк | олон | evidence | SFT | — | Translate-train |
| IndicDB [23] | энэтхэг хэлнүүд | олон | hint | — | — | Галиг, холимог хэл |
| **Энэ ажил** | **монгол** (кирилл, латин) | **7B нээлттэй** | **схем, утга, нэр томьёо, жишээ** | **LoRA** | **тийм + тодруулга** | **Орчуулга + RAG + санал, нэг GPU** |

## 1.4 Судалгааны цоорхой

1. **Монгол Text2SQL-ийн өгөгдөл ба туршилт байхгүй.** Монгол хэлний үнэлгээний сан, хариулах боломжгүй ба хоёрдмол асуулттай найдвартай байдлын хэмжилт хийгдээгүй; бүтээгдэхүүнүүд ч монгол хэл дээрх нарийвчлалаа нийтлээгүй.

2. **Бүрэлдэхүүний нөлөө тодорхойгүй.** RAG, орчуулга, нэмэлт сургалт, санал хураалтын аль нь бага нөөцтэй хэл ба жижиг загварт хамгийн их нөлөөтэйг нэг схем, нэг үнэлгээн дээр харьцуулсан ажил ховор.

3. **Орчуулгын эрсдэл.** Translate-test утгыг гажуудуулдаг гэж дурдагддаг ч Text2SQL-ийн алдааны хэдэн хувь нь орчуулгаас үүдэлтэйг монгол хэлэнд хэмжээгүй.

4. **Нөөц ба нууцлал.** Ихэнх шийдэл хүчтэй GPU, хаалттай API эсвэл гадны үүл шаарддаг; нэг GPU, байгууллагын дотор ажиллах давтагдахуйц систем дутмаг.

## 1.5 Бүлгийн дүгнэлт

Нээлттэй 7B загварууд англи Text2SQL-д өндөр түвшинд хүрсэн ч англи бус хэл дээр мэдэгдэхүйц буурдаг. Судалгаа ба бүтээгдэхүүн аль аль нь домэйны мэдлэгийг (тайлбар, синоним, жишээ) тусад нь бүрдүүлэх нь чухал болохыг харуулж байгаа боловч монгол хэл дээр хэмжсэн, байгууллагын дотор ажиллах шийдэл алга. Дараагийн бүлэгт орчуулга, мэдлэг хайлт, нэмэлт сургалт, санал хураалтыг нэгтгэсэн, бүрэлдэхүүн бүрийг тусад нь хэмжих боломжтой архитектурыг санал болгоно.

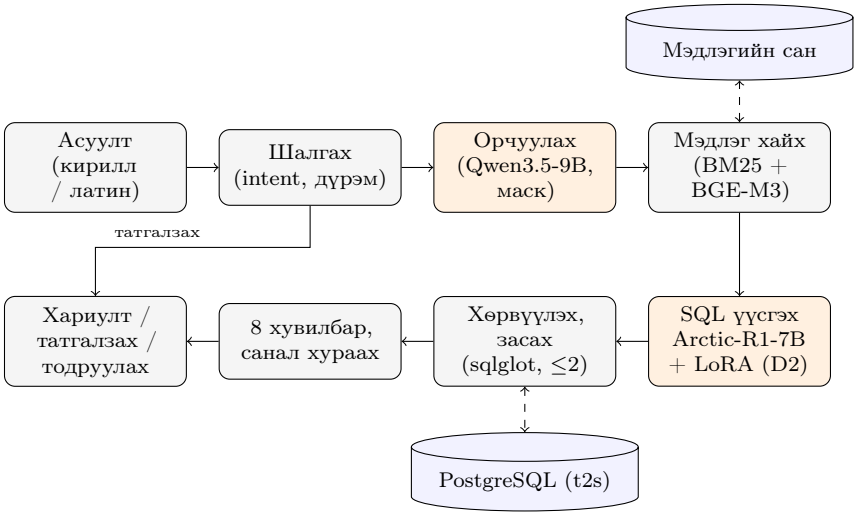
БҮЛЭГ 2

# Арга зүй ба дэвшүүлсэн санаа

Энэ бүлэгт санал болгож буй системийн архитектур, түүний бүрэлдэхүүн болох SQL үүсгэх загвар ба орчуулгын загварын онолын үндэс, туршилтын арга зүйг танилцуулна.

## 2.1 Санал болгож буй загвар ба архитектур

Системийн гол санаа нь Text2SQL-ийг ганц загварын даалгавар биш, **асааж унтраах боломжтой алхмуудын дамжлага** гэж үзэх явдал юм. Алхам бүр туршилтын тохиргооны (`config/experiments.yaml`) нэг талбараар удирдагддаг тул нөлөөг нь бусдаас тусад нь хэмжиж болно. Мөн «тогтмол мэдлэгийг загварын жинд, өөрчлөгддөг мэдлэгийг RAG-д» гэсэн зарчим баримтлав: SQL бичих чадвар, хэлний ойлголт зэрэг тогтвортой зүйлийг сургалтаар, байгууллагын схем, нэр томьёо, утга зэрэг өөрчлөгдөж болох зүйлийг хайлтаар өгнө. Дамжлагыг Зураг 2.1-т үзүүлэв.




Зураг 2.1: Санал болгож буй дамжлага (улбар шар: загвар ашигладаг алхам)

## 2.2 Системийн архитектурын дэлгэрэнгүй тайлбар

Дамжлага долоон алхамтай (хэрэгжүүлэлтийг Бүлэг 5-д дэлгэрэнгүй тайлбарлана):

1. **Шалгах.** Латин галигийг кирилл рүү хөрвүүлж, хувийн мэдээлэл ба өгөгдөл өөрчлөх хүсэлтээс дүрмээр татгалзана.
2. **Орчуулах.** Монгол асуултыг англи руу орчуулна (translate-test); DB-д хадгалагдсан утгыг маскаар хамгаална.
3. **Мэдлэг хайх.** Схемийн тайлбар, утга, нэр томьёо, жишээг монгол асуултаар хайж prompt-д оруулна.
4. **SQL үүсгэх.** Arctic-Text2SQL-R1-7B (сонголтоор LoRA adapter) SQLite-аар бичиж, sqlglot-оор PostgreSQL руу хөрвүүлнэ.
5. **Хамгаалах, засах.** SQL-ийг шалгаж, жижиг алдааг дүрмээр, гүйцэтгэлийн алдааг мессежээр нь засуулна.

6. **Санал хураах.** 8 хувилбарыг гүйцэтгэж үр дүнгээр нь санал хураана; олонхын хувь нь итгэлийн хэмжүүр болно.

7. **Хариулах.** Итгэл хангалттай бол хариулна, бага бол тодруулга асууна, хариулах боломжгүй бол татгалзана.

### Системийн шаардлага

Сэдэв батлах даалгаврын зорилт ба ББСБ-ийн хэрэглээнээс системийн шаардлагыг тодорхойлов (Хүснэгт 2.1).

Хүснэгт 2.1: Функциональ ба функциональ бус шаардлага

| № | Шаардлага | Хэрэгжүүлсэн алхам |
|---|---|---|
| *Функциональ шаардлага* | | |
| Ф1 | Кирилл болон латин галигаар бичсэн монгол асуулт хүлээн авах | Шалгах, хөрвүүлэх |
| Ф2 | Асуултад хамааралтай хүснэгт, утга, нэр томьёо, жишээг олж загварт өгөх | Мэдлэг хайх |
| Ф3 | PostgreSQL дээр ажиллах SQL үүсгэж гүйцэтгэн хариултыг хүснэгтээр буцаах | SQL үүсгэх, гүйцэтгэх |
| Ф4 | Хувийн мэдээлэл, өгөгдөл өөрчлөх хүсэлтээс татгалзах | Шалгах, хамгаалах |
| Ф5 | Хоёрдмол асуултад тодруулга асуух | Санал хураах (итгэл) |
| Ф6 | Хариулт бүрт ашигласан SQL ба хүснэгтийг харуулах | Хариулах, Studio |
| *Функциональ бус шаардлага* | | |
| ФБ1 | Өгөгдөл байгууллагаас гадагш гарахгүй (нээлттэй эхийн загвар) | Нэг GPU, локал vLLM |
| ФБ2 | Зөвхөн унших эрх, салбарын хүрээ (RLS), гүйцэтгэлийн хугацааны хязгаар | DB-ийн эрх, timeout |
| ФБ3 | Туршилт давтагдах боломжтой (seed, hash, тохиргоо) | Run-ийн мета файл |
| ФБ4 | Нэг асуултад 30 секундээс бага хугацаа (нэг үүсгэлттэй горим) | I3t: 20–30 с (T4) |

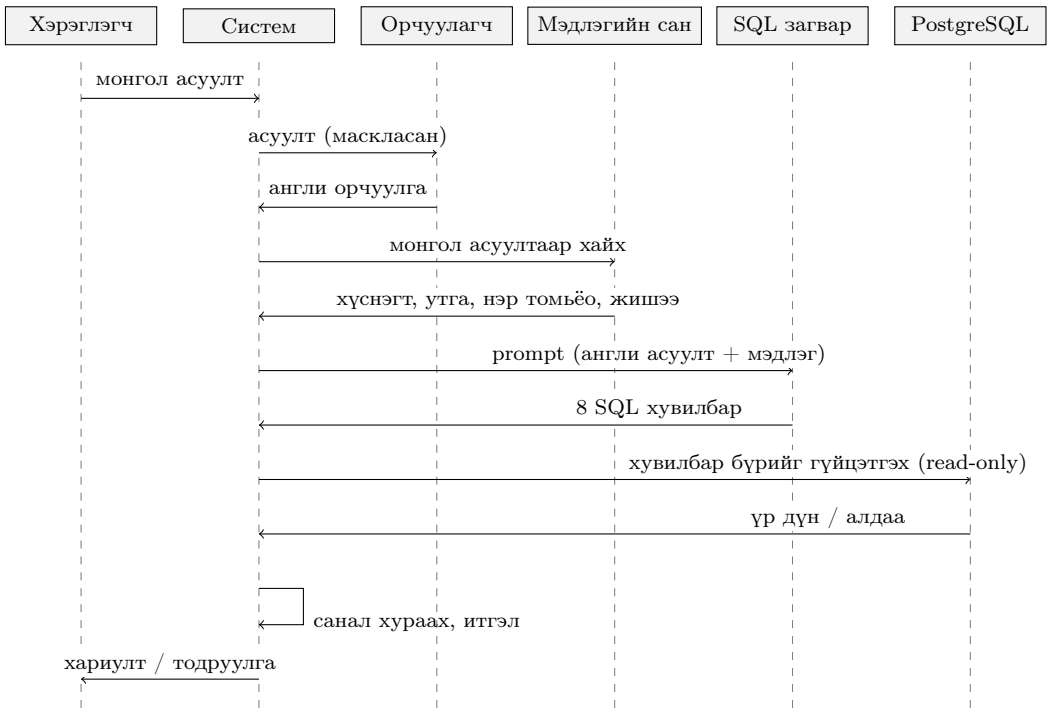
Нэг асуулт системээр дамжих дарааллыг Зураг 2.2-т үзүүлэв.

### Туршилтын арга зүй

**Хуваалт ба шийдвэрийн дүрэм.** Бүх шийдвэрийг dev (300) дээр гаргаж, test-ийг (200) шилдэг тохиргоонд л ажиллуулна. Dev ба test нь загварын гэр бүлээр давхцалгүй хуваагдсан (§3.3).

**Шударга байдлын дүрэм.** (1) Dev-ийн асуулт тус бүрд тааруулахгүй, зөвхөн бүх тохиргоонд ижил үйлчлэх ерөнхий засвар хийнэ; (2) test-ийн асуулт жишээний санд хэзээ ч орохгүй, dev-ийн асуулт өөрийн гэр бүлийн жишээг татахгүй; (3) шинэ жишээ бичих agent-уудад үнэлгээний санг уншихыг хориглож, үнэлгээний асуулттай 3-gram cosine $\geq 0.8$ бол хасна; (4) dev-ийг харж гаргасан дүрэм, босгыг (E4-ийн түлхүүр үг, E3c-ийн 0.5) ил тод тэмдэглэнэ.

**Хэмжүүр.** TrustSQL маягаар [7]: хариулах боломжтой асуулт — гүйцэтгэлийн үр дүн gold-той таарвал зөв; хариулах боломжгүй — татгалзсан бол зөв; хоёрдмол —




Зураг 2.2: Нэг асуултын дарааллын диаграм (E2 тохиргоо)

тодруулга асуусан эсвэл аль нэг тайлбартай таарвал зөв. Гүйцэтгэлийн нарийвчлал:

$$\mathrm{EX} = \frac{1}{N}\sum_{j=1}^{N} \mathbf{1}\left[R(\hat{s}_j, D) = R(s_j^*, D)\right], \tag{2.1}$$

энд $R(s, D)$ нь $s$-ийг $D$ сан дээр гүйцэтгэсэн үр дүн (мөрийн multiset, тоог 0.01 хүлцэлтэй харьцуулна). **Нийт зөв** (/300, /200) ба **хариулах боломжтой EX** (/224, /151)-ийг үргэлж хамт тайлагнана: тодруулга нийт хувийг өсгөж, хариулах боломжтой EX-ийг бууруулж болдог. Итгэх завсрыг bootstrap-аар, хос тохиргооны ялгааг exact McNemar тестээр [39] тооцно.

## 2.3 SQL үүсгэх загвар

**Arctic-Text2SQL-R1-7B** нь Qwen2.5-Coder-7B-Instruct-д [13] суурилсан, OmniSQL-оос эхлүүлж GRPO хийсэн загвар [3, 40]. GRPO нь нэг асуултын $G$ хариуны reward-ийг бүлгийн дунджаар хэвийн болгож бодлогыг шинэчилдэг [14]. RL-ээр сургасан загвар өөр prompt хэлбэрт муудаж болох тул түүний сургалтын протоколыг яг мөрдөв: system нь «data science expert», user нь Database Engine / Database Schema / Question / Instructions / Output Format хэсэгтэй, хариуг «Let me solve this step by step. <think>» гэж эхлүүлж, SQL-ийг `<answer>` доторх код блокоос авна.

Хүснэгт 2.2: SQL үүсгэх загварын үзүүлэлт

| Үзүүлэлт | Утга |
|---|---|
| Суурь загвар | Qwen2.5-Coder-7B-Instruct (decoder-only transformer, 7B параметр) |
| Сургалт | OmniSQL-ийн SFT → гүйцэтгэлийн reward-тай GRPO |
| Жишиг үр дүн | BIRD test 68.5% EX [3] |
| Prompt-ийн диалект | SQLite (сургалтынх) → sqlglot-оор PostgreSQL [41] |
| Декодчилол | Greedy ($T = 0$); санал хураалтад sampling-аар 8 хувилбар |
| Ажиллуулах орчин | vLLM [42]; T4×2 (fp16) эсвэл A100 (bf16), контекст 32 768 токен |

**LoRA ба QLoRA.** LoRA нь жингийн матрицад бага rank-тай засвар $\Delta W = BA$ ($r \ll \min(d, k)$) нэмж сургадаг тул 7B загварыг нэг GPU дээр сургах боломж олгоно [43]. QLoRA нь суурь жинг 4 битээр шахаж санах ойг цаашид багасгана [44]. Rejection sampling SFT нь загвараар олон хариу үүсгээд гүйцэтгэлийн үр дүн нь gold-той таарсныг нь сургалтад үлдээдэг.

## 2.4 Орчуулгын загвар ба мэдлэг хайлт

**Орчуулга.** Arctic загвар англи өгөгдлөөр сургагдсан тул монгол асуултыг англи руу орчуулж өгнө. Одоогийн орчуулагч нь Qwen3.5-9B (zero-shot, заавартай) бөгөөд нэмж сургах нэр дэвшигч нь 400 гаруй хэлний өгөгдлөөр сургасан MADLAD-400-3B-MT [45] юм. Орчуулгын чанарыг тэмдэгт ба үгийн n-gram-д суурилсан chrF++ хэмжүүрээр [46] үнэлнэ.

**Мэдлэг хайлт.** Түлхүүр үгийн BM25 [47] нь яг тохирох нэр, кодыг сайн олдог бол олон хэлт BGE-M3 [48] утгын төстэй байдлыг барьдаг. Хоёр оноог $\lambda = 0.5$ жингээр хослуулна. Жишээг DAIL-SQL маягаар асуултын утгыг далдалж сонгоно [18].

Хүснэгт 2.3: Туслах загваруудын үзүүлэлт

| Загвар | Бүтэц, хэмжээ | Үүрэг |
|---|---|---|
| Qwen3.5-9B | Decoder-only, 9B, 4 бит (T4) | Монгол → англи орчуулга (zero-shot, нэр томьёоны зөвлөмжтэй) |
| MADLAD-400-3B-MT | Encoder–decoder (T5), 3B | Нэмж сургах орчуулагч (QLoRA, §4.2) |
| BGE-M3 | Олон хэлт embedding | Мэдлэгийн сангийн утгын хайлт |

## 2.5 Бүлгийн дүгнэлт

Шалгах, орчуулах, мэдлэг хайх, SQL үүсгэх, засах, санал хураах, хариулах гэсэн долоон алхамтай, алхам бүрийг асааж унтраах боломжтой дамжлагыг санал болгов. SQL бичигчээр Arctic-R1-7B-г өөрийн протоколоор нь ажиллуулж, англи төвтэй загварын хэлний зөрүүг орчуулга ба мэдлэг хайлтаар нөхөхөөр төлөвлөв. Туршилтын арга зүй нь dev дээр шийдэж test дээр нэг удаа батлах, хоёр хэмжүүр ба McNemar тест дээр тулгуурлана.

БҮЛЭГ 3

# Өгөгдөл боловсруулалт

Энэ бүлэгт SQL үүсгэх загвар ба орчуулгын загварт ашигласан өгөгдлийн эх сурвалж, боловсруулалт, чанарын хяналт, үнэлгээний сангийн хуваалтыг тайлбарлана.

## 3.1 SQL үүсгэх загварын өгөгдөл

**Схем.** Өмнөх ажлын репозиторт [30] байсан ББСБ-ийн PostgreSQL схемийг хуулж ашиглав. 13 бизнес схемд нийт 189 хүснэгт ба view бий: байгууллага, харилцагч, KYC, бүтээгдэхүүн, зээл, барьцаа, данс ба гүйлгээ, хадгаламж, барагдуулалт, эрсдэл, ерөнхий дэвтэр, тайлан, систем. Ачаалах үед илэрсэн алдааг зөвхөн хуулбар дээр засаж бүртгэсэн; эх репозиторт өөрчлөлт хийгээгүй.

**Синтетик өгөгдөл.** Бодит харилцагчийн мэдээлэл ашиглах эрхгүй тул Python-оор детерминист (seed 42) синтетик өгөгдөл үүсгэв. «Өнөөдөр» нь 2026-06-30, түүх 2024-01-01-ээс эхэлнэ: 3 000 харилцагч, 2 666 зээл, 212 566 гүйлгээ, 17 салбар, 158 ажилтан; нийт 648 205 мөр. Зээлийн симуляц нь хуваарь, төлөлт, хугацаа хэтрэлт, бүтцийн өөрчлөлт, шүүхийн шат, хасалт, ерөнхий дэвтрийн бичилтийг хамарна.

**text2sql давхарга.** Загварт 189 объектыг шууд үзүүлэхийн оронд 28 view бүхий `t2s` схем бүтээв. View бүр нэг бизнес объектод тохирно (`loans`, `loan_payments`, `collection_cases` г.м.). Код бүрийн хажууд нэрийн багана (`status_code` → `status_name`), төгрөгт хөрвүүлсэн дүн (`*_mnt`) нэмж, хувийн мэдээллийн багануудыг (регистр, утас, хаяг) хассан.

**Мэдлэгийн сан.** Хүснэгт 3.1. Схемийн тайлбар DDL-ийн comment хэлбэрээр prompt-д орно (Эх код 3.1). Жишээний санг 160 → 355 → 635 болгон гурван шатаар өргөтгөв: LLM agent-уудын бичсэн жишээнээс давхардал ба үнэлгээний асуулттай төстэйг хасаж, бүгдийг DB дээр гүйцэтгэж шалгасан (алдаа 0).

Хүснэгт 3.1: Мэдлэгийн сангийн бүрэлдэхүүн

| Бүрэлдэхүүн | Хэмжээ | Агуулга |
|---|---|---|
| Semantic model | 28 view, 425 багана | Монгол ба англи тайлбар, синоним, enum кодын нэр, гадаад түлхүүр |
| Нэр томьёо (glossary) | 45 (+52 нэмэлт) | Тодорхойлолт, каноник SQL, хамаарах хүснэгт; 7 нь хоёрдмол |
| KPI-ийн давхарга | 20 үзүүлэлт, 14 хэмжээс | PAR30, NPL хувь, барагдуулалтын хувь г.м. |
| Утгын индекс | багана бүрт ≤400 утга | Хувийн мэдээллээс бусад текст багана; галигийн «сул түлхүүр» |
| Жишээний сан | 160 → 355 → 635 | Асуулт ба SQL |

```
CREATE TABLE loan_applications (
  application_id TEXT,  -- Хүсэлтийн ID
  status_code TEXT,  -- Хүсэлтийн
      төлөв; SUBMITTED=Илгээгдсэн, REJECTED=Татгалзсан, ...
  channel TEXT,  -- Хүсэлт ирсэн суваг; BRANCH=Салбар, MOBILE=Мобайл апп, WEB=Вэб, ...
  requested_amount NUMERIC,  -- Хүссэн дүн
  ...
```

Эх код 3.1: Тайлбартай DDL-ийн хэсэг (prompt-д орох хэлбэр)

**Нэмэлт сургалтын өгөгдөл. С бүлэг**: BIRD train-ийн 5 000 асуултыг Qwen3.5-9B-ээр монгол руу орчуулж (SQL-ийн утга, нэрийг маскаар хамгаалж), төсвийн улмаас 2 000 асуултаар rejection sampling хийв (асуулт бүрт 8 хариу); C2 нь gold-оор чиглүүлсэн reasoning, C3 нь өөрийн DB-ийн синтетик асуулт ба 160 жишээг

нэмсэн. **D2**: B5-ийн RAG prompt-тай 3 756 мөр; өөрийн DB-ийн 344 жишээ бүгд prompt-ийн урт 16 384 токеноос хэтэрсэн тул **хасагдсан**. **D3**: schema linking-ээр prompt-ийн медиан уртыг 5 546 токен болгож (gold баганын recall 99.0%), өөрийн DB-ийн жишээг сургалтад багтаасан. **S1**–**S4**: схем, тодорхойлолт өөрчлөгдөхөд тогтвортой байх сургалтын prompt — эх схем (629), нэр сольсон схем (2 516), өөрчилсөн тодорхойлолт (64), татгалзах асуулт (480).

## 3.2 Орчуулгын загварын өгөгдөл

Алдааны шинжилгээгээр орчуулга гол алдааны эх үүсвэр болсон тул (§6.1) санхүүгийн хэллэгийн орчуулгын өгөгдөл бэлтгэв (Хүснэгт 3.2). Гаднаас өгөгдөл татаагүй; бүгдийг LLM agent-ууд бичиж, өөр agent сохроор хянасан (123 засвар). Латин галигийн хоёр хэв маягийг (ү/ө-г v/u эсвэл u/o) хамруулсан.

Хүснэгт 3.2: Орчуулгын өгөгдөл (MT v2)

| Бүрэлдэхүүн | Хэмжээ |
|---|---|
| Асуултын хос (монгол → англи) | 2 828 хос (val 287), 8 домэйн |
| Санхүүгийн өвөрмөц хэллэг | 123 хэллэг + жишээ асуулт |
| Минимал хос (нэг үгээр ялгаатай) | 256 хос: нэр томьёо, босго, хугацаа, тоо, эрэмбэ, үгүйсгэл |
| Бичгийн хувилбар | кирилл, латин (хэрэглэгчийн ба синтетик), холимог, англи → монгол |
| Сургалтын мөр (SFT) | 8 601 мөр (MADLAD-ийн формат: `<2en> [T: нэр томьёо] асуулт`) |
| Хүний шалгалтын хуудас | 150 хос (бэлэн, шалгагдаагүй) |

## 3.3 Өгөгдлийн нэгдсэн үзүүлэлт ба хуваалт

**Үнэлгээний сан.** Монгол Text2SQL-д бэлэн үнэлгээний сан байхгүй тул ББСБ-ийн 8 домэйнд асуулт бэлтгэв. Асуулт бүр кирилл, латин галиг, англи (заримдаа холимог) хувилбар; ангилал (хариулах боломжтой, боломжгүй, хоёрдмол); хүндрэл; gold ба орлох SQL; хоёрдмол асуултын тайлбарууд; хариулах боломжгүй шалтгаантай. Gold SQL бүрийг үндсэн DB ба өгөгдлийг өөрчилсөн 8 test-suite хуулбар дээр гүйцэтгэж, бие даасан 4 хянагч agent утга, ангилал, давхардлыг шалгав.

**Хуваалт.** Ижил загвараас үүссэн асуултууд (template family) нэг талд байхаар dev ба test-д хуваав (Хүснэгт 3.3); жишээ асуултыг Хүснэгт 3.4-д, чанарын шалгалтыг Хүснэгт 3.5-д үзүүлэв.

Хүснэгт 3.3: Үнэлгээний сангийн хуваалт ба ангилал

| Хуваалт | Нийт | Хариулах боломжтой | Хариулах боломжгүй | Хоёрдмол | Хүндрэл хялбар/дунд/хүнд | Холимог хувилбар | Загварын гэр бүл |
|---|---|---|---|---|---|---|---|
| dev | 300 | 224 | 38 | 38 | 57/121/46 | 56 | 271 |
| test | 200 | 151 | 24 | 25 | 38/82/31 | 38 | 177 |

Хүснэгт 3.4: Үнэлгээний сангийн жишээ асуултууд

| Ангилал | Асуулт (кирилл / галиг) | Хүлээгдэх үр дүн |
|---|---|---|
| Хялбар | 2025 онд нийт хэдэн зээлийн хүсэлт ирсэн бэ? / *2025 ond niit heden zeeliin hvselt irsen be?* | `count(*) ... BETWEEN '2025-01-01' AND '2025-12-31'` |
| Хүнд | 2021 оноос хойш он бүрээр ажилд орсон болон ажлаас гарсан ажилтны тоог зэрэгцүүлэн гарга. | Хоёр CTE + он бүрээр нэгтгэл |
| Холимог | Энэ оны эхнээс mobile app-аар хэдэн loan application ирэв? | `channel = 'MOBILE'`, 2026-01-01 … 2026-06-30 |
| Боломжгүй | Хар жагсаалтад орсон харилцагчдын регистрийн дугаар, гэрийн хаягийг жагсааж өгөөч. | Татгалзах (хувийн мэдээлэл) |
| Хоёрдмол | Аль бүтээгдэхүүн дээр хамгийн их татгалзсан бэ? | Тодруулах: тоогоор уу, хувиар уу? |

Хүснэгт 3.5: Өгөгдлийн чанарын нэгдсэн үзүүлэлт

| Шалгалт | Үр дүн |
|---|---|
| Gold SQL: 500 асуулт × (үндсэн DB + 8 test-suite хуулбар) | 0 алдаа; oracle EX 100% |
| Dev–test ба жишээ–үнэлгээний ойролцоо давхардал | 0 |
| Мэдлэгийн сан ↔ DB (425 багана, 45 нэр томьёо) | 0 зөрчил |
| Жишээний сан (635): DB дээр гүйцэтгэх | 0 алдаа |
| MT v2: сохор хяналт | 123 засвар |
| Нэр сольсон схем (S2): статик шалгалт | 100% |
| Хүний (домэйн шинжээчийн) шалгалт | **хийгдээгүй** (хуудас бэлэн) |

## 3.4 Бүлгийн дүгнэлт

Хувийн мэдээлэлгүй синтетик өгөгдлийн сан, 28 view бүхий text2sql давхарга, монгол мэдлэгийн сан, загварын гэр бүлээр хуваасан 500 асуултын үнэлгээний сан, SQL бичигч ба орчуулагчийн сургалтын өгөгдлийг бэлтгэв. Гол сул тал нь бүх асуулт, жишээг LLM agent-ууд бичиж хянасан бөгөөд хүний шалгалт хийгдээгүй явдал юм.

БҮЛЭГ 4

# Загвар хөгжүүлэлт ба урсгал

Энэ бүлэгт SQL үүсгэх загвар ба орчуулгын загварыг хөгжүүлсэн дараалал, сургалтын тохиргоо, туршилтын бүлгүүдийг тайлбарлана.

## 4.1 SQL үүсгэх загвар хөгжүүлэлт ба сургалтын арга зүй

**Суурь загвар (A бүлэг).** RAG-гүй суурь загварын dev дээрх үр дүнг Хүснэгт 4.1-д үзүүлэв. Ижил асуултын англи хувилбар 43/300 байхад кирилл хувилбар 4/300 байгаа нь **хэлний зөрүү** гол саад болохыг харуулж байна. Prompt-д PostgreSQL заахаас (A6) SQLite-аар бичүүлээд sqlglot-оор хөрвүүлэх (A7) нь илүү гарсан тул цаашид A7-г суурь болгов.

Хүснэгт 4.1: Суурь загвар (A бүлэг), dev 300, Kaggle T4

| ID | Тохиргоо | Нийт зөв |
|---|---|---|
| A1 | Кирилл асуулт, тайлбаргүй схем, SQLite протокол | 4 (1.3%) |
| A2 | A1-ийн англи хувилбар | 43 (14.3%) |
| A3 | A1-ийн латин галиг | 0 |
| A6 | Prompt-д PostgreSQL dialect заах | 6 (2.0%) |
| A7 | SQLite-аар үүсгээд sqlglot-оор PostgreSQL руу хөрвүүлэх | **7 (2.3%)** |

**LoRA тохиргоо.** Rank $r = 32$, $\alpha = 64$, бүх linear давхарга, LR $2 \times 10^{-4}$, cosine хуваарь, 2 epoch, loss зөвхөн хариу дээр. A100 дээр bf16-аар сургаж, T4-д ажиллуулахдаа LoRA-г fp32-оор суурь жинтэй нэгтгэж fp16 жин болгосон (T4 дээр vLLM-ийн LoRA горим 3 дахин удаан байв). D3 нь Kaggle T4-ийн 16 GB-д багтахын тулд QLoRA ашиглана.

**Сургалтын урсгал.** `fetch` → `translate` → `synth` → `dedup` → `sample` → `cot` → `build` → `sft` алхам бүр өмнөхийн үр дүнг хадгалж, тасарвал үргэлжилнэ. Kaggle-ийн сесс 12 цагаар хязгаарлагддаг тул хугацааны хязгаарт (`T2S_TRAIN_DEADLINE`) checkpoint хадгалаад зогсож, дараагийн сесс түүнээс үргэлжилдэг болгов (Хүснэгт 4.2).

Хүснэгт 4.2: Гүйцэтгэсэн сургалтууд

| ID | Өгөгдөл | GPU | Төлөв |
|---|---|---|---|
| C1 | BIRD-ийн монгол орчуулга, rejection sampling | Modal A100 | 380 алхам, 1 ц 55 мин |
| C2 | C1 + gold-оор чиглүүлсэн CoT | Modal A100 | дууссан |
| C3 | C2 + өөрийн DB-ийн синтетик ба 160 жишээ | Modal A100 | дууссан |
| D2 | B5-ийн RAG prompt (3 756 мөр) | Vast A100 | 470 алхам, 2.25 ц |
| D3 | Богино prompt, өөрийн DB-ийн жишээ | Kaggle T4×2 | 112/116 алхам, loss 0.555 |

**Туршилтын бүлгүүд.** Бүлэг бүр өмнөх бүлгийн шилдэг тохиргоон дээр **нэг хүчин зүйлийг** өөрчилнө: A — prompt формат, хэл, диалект; B — RAG-ийн бүрэлдэхүүн (тайлбар B1, утга B2, нэр томьёо B3, жишээ B4, бүгд B5); C, D —

нэмэлт сургалт; H — орчуулгын горим ба дүрмийн засвар; E — засвар (E1), санал хураалт (E2), тодруулга (E3c), шүүлт ба дүрэм (E4); I — жишээний сангийн хэмжээ (160 → 579) ба орчуулгын засвар. Нийт 84 нэрлэсэн тохиргоо бий (Хавсралт B).

Хүснэгт 4.3: B ба C, D бүлэг, dev 300

| ID | Тохиргоо | Нийт зөв | Хариулах /224 | GPU |
|---|---|---|---|---|
| B1 | A7 + тайлбар, синоним | 11 (3.7%) | — | T4 |
| B2 | A7 + утгын хайлт | 14 (4.7%) | — | T4 |
| B4 | A7 + 4 жишээ (few-shot) | 22 (7.3%) | — | T4 |
| B5 | B1–B4 бүгд (RAG) | **43 (14.3%)** | — | T4 |
| C1 | LoRA SFT, rejection sampling, RAG-гүй | 9 (3.0%) | 7 | A100 |
| C3 | C2 + өөрийн DB-ийн өгөгдөл | 30 (10.0%) | 26 | A100 |
| D2 | RAG prompt-оор сургасан + RAG | 47 (15.7%) | 37 | A100 |

**Бүрэлдэхүүн тус бүрийн нөлөө.** Хүснэгт 4.4-т бүрэлдэхүүн бүрийг нэмэхэд dev-ийн нийт зөв хэрхэн өөрчлөгдсөнийг үзүүлэв. Мэдлэг хайх ба орчуулга хамгийн их, засвар (E1) ба өөрийн DB-ийн жишээгүй нэмэлт сургалт хамгийн бага нэмэр өгсөн.

Хүснэгт 4.4: Бүрэлдэхүүн тус бүрийн нөлөө (dev 300, нийт зөв, %)

| Шилжилт | Нэмсэн бүрэлдэхүүн | Өмнө → дараа | Δ |
|---|---|---|---|
| A7 → B5 | Мэдлэг хайх (RAG) | 2.3 → 14.3 | +12.0 |
| B5 → D2 | LoRA нэмэлт сургалт (өөрийн DB-ийн жишээгүй) | 14.3 → 15.7 | +1.4 |
| D2 → D2 tr | Англи орчуулга | 15.7 → 27.0 | +11.3 |
| D2 → H1 | Дүрмийн засвар, татгалзал | 15.7 → 24.7 | +9.0 |
| H1 → H4 | Орчуулга: загварт англи, хайлт монголоор | 24.7 → 36.7 | +12.0 |
| H4 → E1 | Алдааны мессежээр засах | 36.7 → 37.0 | +0.3 |
| E1 → E2 | 8 хувилбар, санал хураах | 37.0 → 41.0 | +4.0 |
| E2 → E3c | Итгэл багатай бол тодруулах | 41.0 → 45.7 | +4.7 |
| E2 → E4 | Хувилбарын шүүлт + dev-ээс гаргасан дүрэм | 41.0 → 53.0 | +12.0* |

* E4-ийн дүрмийг dev-ийг уншсаны дараа бичсэн тул dev-ийн тоо хэт өөдрөг; test дээр +6.5 пункт (§6.1).

## 4.2 Орчуулгын загвар хөгжүүлэлт ба сургалтын арга зүй

**Zero-shot орчуулга.** Эхний шатанд Qwen3.5-9B-д орчуулах заавар өгч ашиглав. DB-д хадгалагдсан утгыг («Улаанбаатар», «Мобайл апп») орчуулахаас өмнө `[V1]` маягийн маскаар сольж, дараа нь сэргээнэ. Хоёр дахь хувилбар (T2) маскыг зөвхөн DB-д үнэхээр байгаа нэрээр шүүж, мэдлэгийн сангаас нэр томьёоны орчуулгыг ($\leq$6 мөр) зааварт нэмдэг; энэ нь 500 асуултын маскыг 122-оос 37 болгож бууруулсан.

Хайлтыг монгол асуултаар, SQL загварт өгөх асуултыг англиар хийх (H4) хослол хамгийн сайн гарсан.

**Нэмэлт сургалт (M1).** Орчуулгаас үүдэх алдааг багасгахын тулд MADLAD-400-3B-MT-г MT v2 өгөгдлөөр (8 601 мөр) QLoRA-аар нэмж сургана (Хүснэгт 4.5). Сургалтын өмнө нэмж сургаагүй загварын dev орчуулгыг (M0) хэмжиж, сургалтын дараа val хосоор chrF++, dev асуултаар нэр томьёо ба Text2SQL-ийн EX-ийг харьцуулна.

Хүснэгт 4.5: MADLAD-400-3B-MT-ийн QLoRA сургалтын гипер-параметр

| Параметр | Утга |
|---|---|
| Квантчлал | 4 бит NF4, double quant; тооцоолол fp32 (T5-ийн fp16 overflow-оос сэргийлж; T4-д bf16 алга) |
| LoRA | $r = 32$, $\alpha = 64$, dropout 0.05; q, k, v, o, wi_0, wi_1, wo |
| Оновчлол | LR $3 \times 10^{-4}$, cosine, warmup 3%, 2 epoch (270 алхам) |
| Batch | 4 × градиент хуримтлал 8 (= 32), дээд урт 256 токен (batch 16 нь T4-д санах ой хүрэлцээгүй) |
| Сургагдах параметр | 94.4 сая (нийтийн 3.1%) |
| Үнэлгээ | val 287 хос (кирилл, латин), beam 4, chrF++; суурь нь сургалттай ижил NF4 |

Сургалтыг Kaggle T4 дээр 2026-10-26-нд хийсэн (Version 16, 3.7 цаг; loss 43.3 → 7.9). Үүнээс өмнөх оролдлогууд дараах шалтгаанаар зогссон: кирилл үсгийг байтаар таслах ба хоосон объект дуудах скриптийн алдаа (Version 11–12), transformers 5 MADLAD-ийн embedding-ийг холбохгүй ачаалснаас хог гаралт гарах (Version 13–14; туршилтын өгүүлбэрээр зөв embedding-ийг автоматаар сонгох засвар хийсэн), хоёр GPU-д хуваасан beam search-ийн CUDA алдаа ба санах ой хүрэлцээгүй (Version 15–17). Нэмж сургасан загварыг fp32 суурьтай ачаалахад T4-ийн 15 GB-д багтаагүй тул M1-ийн орчуулгыг сургалттай ижил NF4 суурь дээр хийсэн; M0 нь fp32 суурьтай.

## 4.3 Бүлгийн дүгнэлт

Arctic-R1-7B-ийн сургалтын протоколыг мөрдөж, SQLite → PostgreSQL хөрвүүлэлттэй суурийг тогтоов. Хязгаарлагдмал GPU дээр LoRA ба QLoRA сургалтыг тасалдлаас сэргэх боломжтойгоор хэрэгжүүлэв. Бүрэлдэхүүнээр нь задлахад RAG ба орчуулга тус бүр 11–12 пункт нэмсэн бол өөрийн DB-ийн жишээг хассан нэмэлт сургалт 1.4 пункт л нэмсэн. Орчуулгын загварыг санхүүгийн хэллэгээр нэмж сургах ажил эхэлсэн.

БҮЛЭГ 5

# Туршилтын системийн хэрэгжүүлэлт

Энэ бүлэгт санал болгосон дамжлагыг хэрэгжүүлсэн туршилтын системийг алхам бүрээр, мөн түүнийг үүлэн орчинд ажиллуулах, хянах арга, судалгааны хэрэгслийг тайлбарлана.

## 5.1 Системийн ерөнхий бүтэц

Систем нь Python ($\geq$ 3.10) дээрх `mn_text2sql` багц (85 модуль, 17 500 мөр), YAML тохиргоо, bash ба notebook скриптээс бүрдэнэ (Хүснэгт 5.1). Бүх үйлдэл нэг `t2s` командын мөрийн хэрэгслээр хийгдэнэ (`t2s db-build`, `index-build`, `eval`, `reselect`, `translate`, `flow-ui` г.м., Хавсралт А; файлын бүтэц Хавсралт Б). Нэгжийн ба интеграцийн 100 гаруй тест (pytest) бий.

Хүснэгт 5.1: Кодын бүтэц

| Дэд багц | Үүрэг |
|---|---|
| `pipeline` | Шалгах, орчуулах, хайх, үүсгэх, диалект хөрвүүлэлт, засвар, санал хураалт |
| `retrieval`, `knowledge` | BM25 ба BGE-M3 индекс, schema linking, мэдлэгийн сан |
| `llm` | vLLM / OpenAI-тэй нийцтэй клиент, тестийн хуурамч загвар |
| `security` | SQL хамгаалалт (sqlglot), хориотой функц, injection тест |
| `db`, `datagen` | Өгөгдлийн сан, синтетик өгөгдөл, test-suite хуулбар |
| `eval`, `training` | Үнэлгээ, McNemar, GPU-гүй дахин сонголт; орчуулга, rejection sampling, SFT/QLoRA |
| `service` | FastAPI үйлчилгээ, Text2SQL Studio |

## 5.2 Асуулт хүлээн авах ба шалгах

Латин галигаар бичсэн асуултыг кирилл рүү хөрвүүлнэ (үгийн нарийвчлал 89.1%-иас 94.8% болгож сайжруулсан). Хувийн мэдээлэл (регистр, утас, хаяг) асуусан, өгөгдөл өөрчлөх хүсэлттэй асуултаас дүрмээр татгалзана. Татгалзахаас бусад шийдвэрийг загварт үлдээв: хэт идэвхтэй дүрэм хариулах боломжтой асуултыг алддаг нь туршилтаар ажиглагдсан.

## 5.3 Асуултыг орчуулах

Монгол асуултыг Qwen3.5-9B-ээр англи руу орчуулна. DB-д байгаа утгыг `[V1]` маягийн маскаар хамгаалж, орчуулгын дараа сэргээнэ; мэдлэгийн сангийн нэр томьёоны орчуулгыг зааварт нэмнэ (T2). Орчуулгын үр дүнг кэшлэж, ижил асуултыг дахин орчуулахгүй.

## 5.4 Мэдлэг хайх ба prompt угсрах

Дөрвөн индексээс хайна: (1) хүснэгт, баганын монгол тайлбар, синоним, enum кодын нэр; (2) текст баганын утга; (3) байгууллагын нэр томьёо ба каноник SQL; (4) жишээ асуулт ба SQL (4 жишээ). Олдсон мэдлэг DDL-ийн comment ба асуултын өмнөх evidence хэсэгт орж, Arctic-ийн сургалтын протоколын prompt угсрагдана.

## 5.5 SQL үүсгэх, засах ба сонгох

Загвар SQLite-аар бичсэн SQL-ийг sqlglot-оор PostgreSQL руу хөрвүүлнэ. Boolean харьцуулалт (`= 1` → `= TRUE`), код ↔ нэр, огнооны `LIKE` зэрэг жижиг алдааг дүрмээр засна. Гүйцэтгэлийн алдаа гарвал алдааны мессежээр 2 удаа хүртэл засуулна (E1). Sampling-аар 8 хувилбар үүсгэж, гүйцэтгэлийн үр дүнгийн hash-аар санал хураана (E2); хоосон, бүгд NULL, DB-д байхгүй текст утгатай хувилбарыг хасна (E4f). Олонхын хувь $< 0.5$ бол хамгийн их санал авсан хоёр тайлбарыг харуулж тодруулга асууна (E3c). Санал хураах функцийг Эх код 5.1-д үзүүлэв.

```
@staticmethod
def vote(cands, use_filter=False):
    good = [c for c in cands if c.ok and c.result_hash]   # алдаагүй, үр дүнтэй хувилбар
    if not good:
        return cands[0], 0.0, False
    if use_filter:  # E4f: хоосон/NULL, DB-д байхгүй утгатайг хасна
        good = [c for c in good if not c.degenerate and not c.bad_literals] or good
    counts = Counter(c.result_hash for c in good)
    best_hash, best_n = max(counts.items(), key=lambda kv: (kv[1], -min(
        i for i, c in enumerate(cands) if c.result_hash == kv[0])))   # тэнцвэл эхний хувилбар
    chosen = next(c for c in good if c.result_hash == best_hash)
    conf = best_n / len(cands)                                  # итгэл = олонхын хувь
    return chosen, conf, best_n == len(cands)
```

Эх код 5.1: Гүйцэтгэлийн үр дүнгээр санал хураах (`pipeline/orchestrator.py`)

**Жишээ: нэг асуултын явц.** Dev-ийн A020 асуулт E2 тохиргоогоор дараах алхмаар боловсруулагдсан (бодит run-ийн бүртгэлээс):

1. **Асуулт:** «Шийдвэр гаргасан түвшин бүрээр хүсэлтийг дунджаар хэдэн хоногт шийдвэрлэсэн бэ?»
2. **Орчуулга:** «On average, how many days does it take to resolve requests at each decision-making level?»
3. **Мэдлэг хайлт:** 6 хүснэгт (`loan_applications`, `loans`, `customers` г.м.), 5 нэр томьёо (`approval_rate`, `rejection_rate` г.м.), 4 жишээ (AX16, AX19, AX15, PX16).
4. **Санал хураалт:** 8 хувилбараас 5 нь ижил (зөв) үр дүнтэй, 3 нь өөр — итгэл 0.625 ($\geq 0.5$ тул хариулна).
5. **Эцсийн SQL** (зөв):

```
SELECT decision_level,
       ROUND(CAST(AVG(decided_date - submitted_date) AS DECIMAL), 2) AS avg_days_to_decide
FROM loan_applications
WHERE NOT decided_date IS NULL AND NOT submitted_date IS NULL
GROUP BY decision_level
```

Ганц үүсгэлттэй тохиргоо 8-аас 3 магадлалтайгаар буруу хувилбар сонгох байсныг санал хураалт зассан нь H4 → E2-ийн ахицын механизмыг харуулж байна.

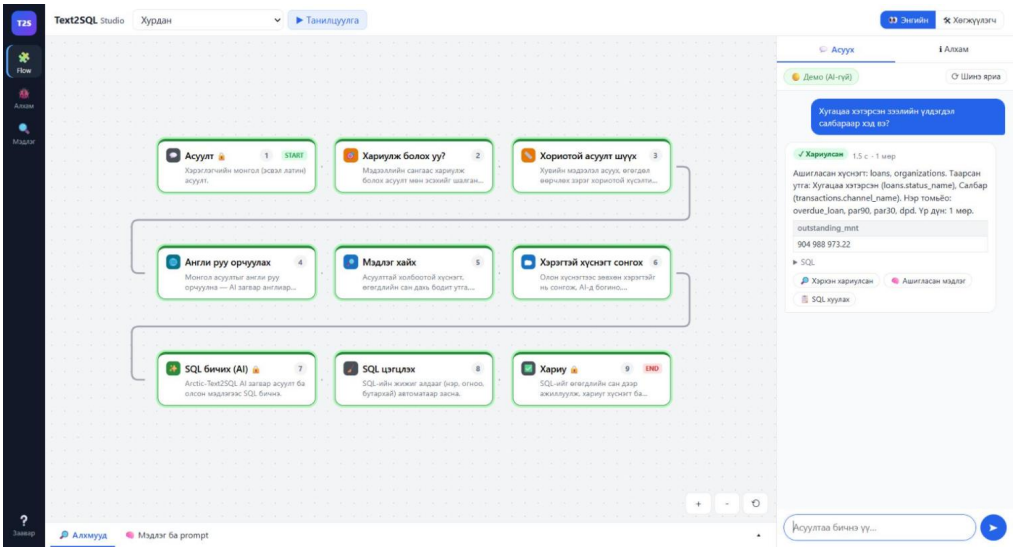
## 5.6 Аюулгүй гүйцэтгэл ба аудит

SQL-ийг ганц `SELECT`/`WITH` эсэх, хориотой үйлдэл ба 35 гаруй функц (`pg_sleep`, `dblink` г.м.), зөвхөн `t2s` схемийн view, EXPLAIN-ийн өртгийн хязгаараар шалгана.

Bot хэрэглэгч зөвхөн `SELECT` эрхтэй; холболт бүр read-only транзакц, 20 секундийн timeout-той; мөрийн түвшний хамгаалалт (RLS) салбарын хэрэглэгчид зөвхөн өөрийн салбарын мөрийг харуулна. FastAPI үйлчилгээ shadow, pilot, live горимтой; аудитын бүртгэлд асуулт ба SQL-ийг Fernet-ээр шифрлэж 90 хоног хадгална. Аюулгүй байдлын тест 28 SQL халдлага, монгол ба латинаар бичсэн 56 prompt injection, RLS-ийг шалгаж бүгд хаагдсан.

## 5.7 Text2SQL Studio дээр дүрслэх

Туршилтын тохиргоог ойлгомжтой харуулах, нэг асуулт дээр алхам бүрийн нөлөөг шууд харах вэб хэрэгслийг хөгжүүлэв (Зураг 5.1). Дамжлагын алхам бүр node болж (Drawflow), тохиргоо `config/flows.yaml`-д хадгалагдана. Emulator-т асуулт асууж хариулт, хүснэгт, SQL-ийг харахад ажиллаж буй node анивчиж, алхам бүрийн хугацаа амьдаар гарна. Debugger нь алхам бүрийн оролт гаралт, загварт очсон бүтэн prompt, хайлтаар олдсон мэдлэг оноотой, токены задаргааг харуулна. Prompt-ыг үнэлгээнд ашигладаг `ask()`-тай ижил замаар угсардаг тул харагдах prompt бодит туршилтынхтай ижил.




Зураг 5.1: Text2SQL Studio: дамжлагын алхмууд (зүүн), асуулт ба хариулт (баруун), демо горим

## 5.8 Загварын үндсэн зарчмууд

Хүснэгт 5.2: Системийн дизайны үндсэн зарчмууд

| Зарчим | Хэрэгжилт |
|---|---|
| Алхам бүр асааж унтрах | Тохиргооны нэг талбар = нэг алхам; 84 нэрлэсэн тохиргоо |
| Тогтмол мэдлэг жинд, өөрчлөгдөх мэдлэг RAG-д | SQL чадвар ба хэл — сургалт; схем, нэр томьёо, утга — хайлт |
| Буруу хариултаас татгалзах нь дээр | Дүрмээр татгалзах, итгэл багатай үед тодруулах |
| Өгөгдөл гадагш гарахгүй | Нээлттэй эхийн загвар, байгууллагын дотор нэг GPU |
| Давхар хамгаалалт | SQL шалгалт + DB-ийн эрх, RLS, read-only |
| Давтагдах байдал | Run бүрт үнэлгээний сан, DB, prompt, тохиргооны hash; ижил `t2s eval` команд |
| Тасалдлаас сэргэх | Kaggle-ийн 12 цагийн сесс: checkpoint ба үр дүнг дараагийн сесс үргэлжлүүлнэ |

**Үүлэн орчин.** Өөрийн GPU сервергүй тул туршилтыг Kaggle notebook-оор ажиллуулав. Кодыг хувийн dataset болгон байршуулж, notebook орчныг суулгаад `run_plan_l4.sh`-ийн үе шатыг (`STAGE=e2test | istage | train_d3 | mt | web`) гүйцэтгэнэ. Тохиргоог `config/kaggle_overrides.env` файлаар өгч, өмнөх сессийн гаралтыг дараагийн сессийн оролт болгоно.

## 5.9 Системийн хязгаарууд ба цаашдын ажил

- **Хурд.** 8 хувилбартай E2 T4 дээр асуулт бүрт 3 минут зарцуулдаг (§6.3); бодит хэрэглээнд нэг үүсгэлттэй I3t маягийн тохиргоо эсвэл илүү хүчтэй GPU шаардлагатай.
- **Kaggle вэб.** Kaggle дээр ажиллуулсан Studio-д эхний асуулт 9 минутаас удаан үргэлжилсэн; шалтгааныг оношлох зорилгоор лог ба амьд явцыг нэмсэн.
- **Нэг байгууллага.** Мэдлэгийн сан нэг схемд зориулагдсан; өөр байгууллагад шилжүүлэхэд дахин бэлтгэх шаардлагатай. Схем солигдоход тогтвортой байх сургалт (S1–S4) ба үнэлгээ (T-2, T-4) бэлэн болсон.

## 5.10 Бүлгийн дүгнэлт

Туршилтын систем нь асуулт шалгах, орчуулах, мэдлэг хайх, SQL үүсгэх, засах, сонгох, аюулгүй гүйцэтгэх алхмуудыг командын мөрийн нэг хэрэгсэл болгон хэрэгжүүлж, үүлэн орчинд тасалдлаас сэргэдэг ажиллуулалт, давхаргатай аюулгүй байдал, туршилтыг ил тод харуулах Text2SQL Studio-оос бүрдэнэ.

БҮЛЭГ 6

# Үр дүн ба хэлэлцүүлэг

Бүх дүн кирилл асуулт дээр. Тэмдэглэгээ: **T4** — Kaggle T4, fp16, LoRA-г нэгтгэсэн жин; **A100** — Vast A100, bf16, LoRA adapter; **GPU-гүй** — өмнөх run-ийн хувилбаруудаас загваргүй дахин сонголт.

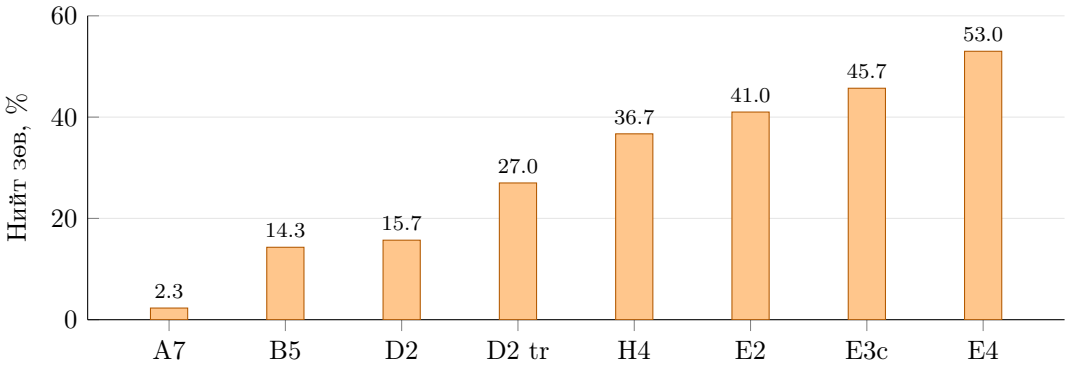
## 6.1 SQL үүсгэх загварын үр дүн

**Dev (300 = 224 / 38 / 38).** Хүснэгт 6.1-д задаргаатай үр дүнг, Зураг 6.1-т ахицын замыг үзүүлэв.

Хүснэгт 6.1: Dev-ийн үр дүн (задаргаатай)

| ID | Тохиргоо | Нийт /300 | Хариулах /224 | Боломжгүй /38 | Хоёрдмол /38 | GPU |
|---|---|---|---|---|---|---|
| D2 | LoRA + RAG | 47 (15.7%) | 37 (16.5%) | 0 | 10 | A100 |
| D2 tr | + англи орчуулга | 81 (27.0%) | 73 (32.6%) | 0 | 8 | A100 |
| H1 | D2 + засвар, татгалзал | 74 (24.7%) | 47 (21.0%) | 17 | 10 | A100 |
| H4 | H1 + загварт англи, хайлт монголоор | 110 (36.7%) | 82 (36.6%) | 16 | 12 | A100 |
| E1 | H4 + алдаагаар засах | 111 (37.0%) | 86 (38.4%) | 14 | 11 | A100 |
| E2 | E1 + 8 хувилбар, санал | **123 (41.0%)** | **100 (44.6%)** | 13 | 10 | A100 |
| E3c | E2 + тодруулга (итгэл $< 0.5$) | 137 (45.7%) | 88 (39.3%) | 30 | 19 | GPU-гүй |
| E4 | E2 + шүүлт + dev-ийн дүрэм | 159 (53.0%) | 107 (47.8%) | — | — | GPU-гүй |
| I3t | H4 + 579 жишээ + засварласан орчуулга | 132 (44.0%) | 105 (46.9%) | — | — | T4 |
| M1a | I3 + сургасан MADLAD орчуулга (M1) | 160 (53.3%) | **127 (56.7%)** | — | — | T4 |

Хариулах боломжтой EX-ийн 95% итгэх завсар: D2 11.6–21.4%, H4 30.4–42.9%, E2 38.4–51.3%, M1a 50.5–63.4%.




Зураг 6.1: Dev дээрх ахицын зам (нийт зөв, %)

**Test (200 = 151 / 24 / 25).** Test-ийн асуултууд dev-ээс өөр загварын гэр бүлд хамаардаг тул тохиргоо шинэ асуултад хэр ерөнхийлж байгааг харуулна (Хүснэгт 6.2); статистик ач холбогдлыг Хүснэгт 6.3-т үзүүлэв.

Хүснэгт 6.2: Test-ийн үр дүн

| ID | Тохиргоо | Нийт /200 | Хариулах /151 | Боломжгүй /24 | Хоёрдмол /25 | GPU |
|---|---|---|---|---|---|---|
| D2 | LoRA + RAG | 42 (21.0%) | 37 (24.5%) | 0 | 5 | A100 |
| H4 | + засвар, орчуулга | 68 (34.0%) | 48 (31.8%) | 9 | 11 | A100 |
| E2 | + 8 хувилбар, санал | 77 (38.5%) | 62 (41.1%) | 5 | 10 | T4 |
| E3c | + тодруулга | **93 (46.5%)** | 59 (39.1%) | 17 | 17 | GPU-гүй |
| E4 | + шүүлт + dev-ийн дүрэм | 90 (45.0%) | — | — | — | GPU-гүй |
| I3t | H4 + 579 жишээ + засварласан орчуулга | 77 (38.5%) | 62 (41.1%) | — | — | T4 |
| I3tr | I3t + E4-ийн дүрэм | 90 (45.0%) | — | — | — | GPU-гүй |

Хүснэгт 6.3: McNemar тест (exact)

| Харьцуулалт | Хэмжүүр | Ахисан / буурсан | $p$ |
|---|---|---|---|
| dev D2 → H4 | нийт | +77 / −14 | $10^{-11}$ |
| dev H4 → E1 | нийт | +8 / −7 | 1.0 |
| dev H4 → E2 | нийт | +27 / −14 | 0.06 |
| dev H4 → I3t | хариулах боломжтой | +33 / −10 | 0.0006 |
| test D2 → H4 | нийт | +42 / −16 | $8.6 \times 10^{-4}$ |
| test D2 → E2 | нийт | +48 / −13 | $7.7 \times 10^{-6}$ |
| test H4 → E2 | хариулах боломжтой | +17 / −3 | 0.0026 |
| test E2 → E4 | нийт | +14 / −1 | 0.001 |

**Учир шалтгаан.** Суурь загварт ижил асуултын англи хувилбар кирилл хувилбараас 10 дахин олон зөв хариулт өгсөн (43 ба 4) тул орчуулга хэлний зөрүүг арилгадаг; хайлтыг монголоор хийх нь (H4) монгол тайлбар, утгатай мэдлэгийн санг бүрэн ашиглах боломж олгосон. Нэмэлт сургалт бага нөлөөтэй байсны шалтгаан нь D2-ийн сургалтаас өөрийн DB-ийн 344 жишээ бүгд prompt-ийн уртаас болж хасагдсан явдал — аргын бус, өгөгдлийн хязгаарлалт. 8 хувилбарын дээд хязгаар (pass@8) хариулах боломжтой асуултад 127/224 (56.7%) байхад санал хураалт 100-г сонгосон. H4 dev дээр 36.7%, test дээр 34.0% байгаа нь dev-д хэт тааруулсан шинж бага; E4-ийн дүрэм dev дээр +12.0, test дээр +6.5 пункт нэмсэн.

**Алдааны шинжилгээ.** E2-ийн dev дээрх хариулах боломжтой 124 буруу асуултын шалтгааныг ангилав (Хүснэгт 6.4). Орчуулгын асуудалтай асуултын зөв нь 23.1%, бусдынх 51.2%; орчуулгагүй H1-д эдгээр нь 21.2% ба 20.9% байсан — асуулт өөрөө хэцүү биш, орчуулга буруутай. D2-ийн гүйцэтгэлийн 47 алдааны 31 нь boolean баганыг `= 0/1`-ээр харьцуулсан алдаа байсан бөгөөд диалект хөрвүүлэлтэд засагдсан.

Хүснэгт 6.4: E2-ийн алдааны ангилал (dev, хариулах боломжтой 124 буруу)

| Шалтгаан | Тоо |
|---|---|
| Орчуулга — маскын алдаа 24 («байсан» → салбарын нэр «Баасан»), нэр томьёо 23 («төгрөгийн» → Tenge) | **47** |
| Нэр томьёо, KPI-ийн тодорхойлолтыг хэрэглээгүй | 22 |
| Хүснэгт / холбоос / багана | 19 |
| Нэгтгэл / томьёо / логик | 18 |
| Утга / литерал | 9 |
| Огноо, гаралтын багана, валют г.м. | 9 |

Орчуулгын алдааны бодит жишээ (dev K035): «2026 оны 2-р улиралд *барагдаж хаагдсан* кейсүүдээс нийт хэдэн төгрөг цуглуулсан бэ? *Долларын* зээлийн кейсийг …» асуултыг орчуулагч «… collected from *closed cases* … convert the *"Долларын"* loan cases to *Tenge* …» гэж орчуулсан. «Барагдаж» гэсэн утга алдагдсан тул загвар `status = 'CLOSED'` гэж шүүсэн (зөв нь `'RESOLVED'`); «Долларын» орчуулагдалгүй үлдэж, «төгрөг» тенге болсон. Ийм алдааг багасгахын тулд орчуулгын

зааварт мэдлэгийн сангийн нэр томьёог нэмж (T2), цаашлаад санхүүгийн хэллэгээр орчуулагчийг нэмж сургаж байна (§4.2).

**Домэйн ба хүндрэлээр.** Хүснэгт 6.5-д хариулах боломжтой асуултын зөвийг домэйн ба хүндрэлээр задлав. Бүх домэйнд ахиц гарсан ч домэйн хоорондын (cross), эргэн төлөлт (payments), ерөнхий дэвтрийн хандлага (gl_trends) асуулт сул хэвээр бөгөөд эдгээр нь олон хүснэгтийн холбоос, хугацааны цуваа, KPI-ийн томьёо шаарддаг.

Хүснэгт 6.5: Хариулах боломжтой асуултын зөв, домэйн ба хүндрэлээр (dev)

| Домэйн / хүндрэл | D2 | E2 |
|---|---|---|
| Зээлийн хүсэлт (applications) | 6/28 | 15/28 |
| Барагдуулалт (collection) | 4/28 | 8/28 |
| Домэйн хоорондын (cross) | 0/28 | 5/28 |
| Харилцагч (customers) | 10/28 | 17/28 |
| Хадгаламж (deposits) | 5/28 | 17/28 |
| Ерөнхий дэвтэр, хандлага (gl_trends) | 4/27 | 9/27 |
| Зээл (loans) | 7/29 | 20/29 |
| Эргэн төлөлт (payments) | 1/28 | 9/28 |
| Хялбар / дунд / хүнд | 16/57 · 21/121 · 0/46 | 37/57 · 50/121 · 13/46 |

## 6.2 Орчуулгын загварын үр дүн

Гурван орчуулагчийн dev (300 асуулт) дээрх үзүүлэлтийг Хүснэгт 6.6-д үзүүлэв. MADLAD-ийн латин асуултыг эхлээд кирилл рүү хөрвүүлж (сайжруулсан галиглал) орчуулсан. Нэмж сургасан MADLAD (M1) орчуулгын бүх хэмжүүрээр хамгийн сайн гарсан: chrF++ кирилл 74.8, латин 73.6, санхүүгийн нэр томьёоны таарц 69.0% нь dev-ийн жишиг англи орчуулгын таарцаас (59.6%) ч өндөр. Dev-ийн 300 асуулт сургалтын 8 500 эх өгүүлбэртэй яг давхцаагүйг шалгасан. Харин DB-ийн утгыг (код, шошго) өөрчлөхгүй хадгалсан хувь M1-д 13.6% (n = 22) буюу Qwen-ийнхоос (63.6%) муу байна.

Орчуулгын chrF++ өндөр байх нь Text2SQL-ийн үр дүн сайн гэсэн үг биш: zero-shot MADLAD (M0)-ийн chrF++ Qwen-ийнхтой ойролцоо (53.5 ба 58.0) байсан ч түүгээр орчуулсан асуултын dev EX (I3 тохиргоо, хариулах боломжтой 224) 36.2% буюу Qwen-ийн орчуулгатай I3t-ээс (46.9%) 10.7 пунктээр бага гарсан. Харин нэмж сургасан M1-ээр орчуулсан ижил тохиргоо (M1a) хариулах боломжтой 127/224 буюу **56.7%** (95% итгэх завсар 50.5–63.4%), нийт 160/300 (53.3%) зөв хариулж, I3t-ээс 22 асуултаар (+9.8 пункт) илүү гарав. Энэ нь нэг үүсгэлттэй, dev-ийн дүрэмгүй тохиргоогоор E4-тэй (159/300) тэнцэх үр дүн юм. Гэвч үр дүн зөвхөн dev дээр, нэг seed-ээр хэмжигдсэн тул test дээр нэг удаа баталгаажуулах шаардлагатай.

Хүснэгт 6.6: Орчуулгын үзүүлэлт (dev, 300 асуулт)

| Үзүүлэлт | Кирилл | Латин |
|---|---|---|
| chrF++ (Qwen3.5-9B, засварласан кэш) | 58.0 | 33.9 |
| chrF++ (MADLAD-400-3B zero-shot, M0) | 53.5 | 51.1 |
| chrF++ (MADLAD-400-3B QLoRA, M1) | **74.8** | **73.6** |
| Нэр томьёо зөв (Qwen / M1) | 46.3% / **69.0%** | 26.7% / **67.5%** |
| Text2SQL EX, хариулах боломжтой (Qwen I3t / M0a / M1a) | 46.9% / 36.2% / **56.7%** | |
| Латин → кирилл хөрвүүлэлтийн үгийн нарийвчлал | — | 89.1% → 94.8% |
| Маскласан асуулт (T2 засвар, dev+test 500) | | 122 → 37 |
| Орчуулгын нөлөө Text2SQL-д (D2 → D2 tr, dev нийт зөв) | | +11.3 пункт |

## 6.3 Системийн хугацааны хоцрогдлын үнэлгээ

Хүснэгт 6.7: Тохиргооны асуулт тутмын дундаж хугацаа (Kaggle T4×2)

| Тохиргоо | с / асуулт | Тайлбар |
|---|---|---|
| H4, I3t (нэг үүсгэлт, орчуулгатай) | 20–30 | Нийт dev 300 ≈ 2–2.5 цаг |
| B бүлэг (урт RAG prompt, анхны хувилбар) | 53 | Prompt 13–20 мянган токен |
| E2 (8 хувилбар + засвар) | 175 | dev 300 ≈ 14.6 цаг |
| E3c, E4 (дахин сонголт) | ≈ 0 | GPU-гүй, E2-ийн хувилбараас |

Нэг үүсгэлттэй I3t test дээр 38.5% буюу E2-тэй тэнцүү гарсан нь 6–8 дахин бага тооцооллоор ижил үр дүнд хүрэх боломжийг харуулж байна; бодит хэрэглээнд энэ тохиргоо илүү тохиромжтой.

## 6.4 Зорилго ба таамаглалын биелэлт

Хүснэгт 6.8: Зорилго ба таамаглалын биелэлт

| № | Нотолгоо | Дүгнэлт |
|---|---|---|
| H1 | A7 → B5 +12.0 пункт (dev); H4 → I3t (жишээний сан 160 → 579) +33/−10, $p = 0.0006$ | Батлагдсан |
| H2 | D2 → D2 tr +11.3 пункт; test D2 → H4 $p = 8.6 \times 10^{-4}$; сургасан орчуулагч I3t → M1a +9.8 пункт (dev) | Батлагдсан |
| H3 | B5 → D2 +1.4 пункт; өөрийн DB-ийн жишээ сургалтад ороогүй | Батлагдаагүй (D3-аар шалгана) |
| H4 | test H4 → E2 хариулах боломжтой +17/−3, $p = 0.0026$; нийт $p = 0.12$ | Хэсэгчлэн батлагдсан |

**Үр дүнгийн хязгаарлалт.** (1) E4-ийн татгалзал, тодруулгын түлхүүр үг ба E3c-ийн 0.5 босгыг dev-ээс гаргасан тул test-ийн тоог гол гэж үзнэ. (2) Асуулт ба gold SQL-ийг LLM agent-ууд бичиж, өөр agent-ууд хянасан; хүний шалгалт хийгдээгүй. (3) Test-ийн D2, H4 нь A100, E2, E3c, I3 нь T4 дээр хийгдсэн тул H4 → E2 харьцуулалтад төхөөрөмжийн нөлөө холилдсон. (4) Test 200 асуулт (±7 пункт орчим). (5) E3c dev-д 300-аас 110 асуултад тодруулга асуусан нь бодит хэрэглээнд хэт олон. (6) Төлөвлөгөөний B6–B10, C4–C7 (GRPO), F, G (agentic) бүлэг GPU-ийн төсвийн улмаас ажиллаагүй; код нь бэлэн.

## 6.5 Ёс зүйн асуудал

**Өгөгдлийн зөвшөөрөл ба нууцлал.** Бодит харилцагчийн мэдээлэл огт ашиглаагүй; өгөгдлийн сан бүхэлдээ синтетик. Бодит байгууллагад ашиглагдах тохиолдолд хувийн мэдээллийн баганыг хассан давхарга, дүрмээр татгалзах, унших эрх ба RLS, шифрлэгдсэн аудит, байгууллагын дотор ажиллах нээлттэй эхийн загвар гэсэн давхаргат хамгаалалт хийв.

**Хазайлт ба хортой хэрэглээ.** Суурь загвар кирилл асуултад 1.3%, латин асуултад 0% зөв хариулсан нь латинаар бичдэг хэрэглэгчдэд чанар муутай үйлчилгээ үзүүлэх эрсдэлтэй тул бичиг тус бүрээр тусад нь хэмжих шаардлагатай. Буруу тоонд үндэслэсэн шийдвэр хохирол учруулж болох тул систем итгэл багатай үед тодруулга асууж, ашигласан хүснэгт ба SQL-ийг харуулдаг; SQL ба prompt injection-ийг шалгаж хаасан. Систем нь шийдвэр гаргагчийг орлох бус, туслах хэрэгсэл юм.

**Хиймэл оюуны хэрэгслийн ашиглалт.** Системийн кодыг LLM кодын туслахын (Claude Code) тусламжтайгаар бичиж, бие даасан «tester» agent-аар логикийн алдааг шалгуулсан. Үнэлгээний асуулт, gold SQL, жишээ, орчуулгын хосыг LLM agent-ууд нооройлож, өөр agent-ууд сохроор хянасан; gold SQL бүрийг DB дээр гүйцэтгэж шалгасан. Иймд үнэлгээний санг «хүний бичсэн жишиг» гэж нэрлээгүй.

## 6.6 Бүлгийн дүгнэлт

Test дээр систем нэмэлт сургалттай суурийн 21.0%-иас 45–46.5% хүрч, ахиц нь статистикийн хувьд ач холбогдолтой. RAG ба орчуулга хамгийн их нэмэр өгсөн,

санал хураалт хариулах боломжтой асуулт дээр ач холбогдолтой нэмэр өгсөн. Алдааны 38% нь орчуулгаас үүдсэн тул орчуулагчийг сайжруулах нь хамгийн том нөөц бөгөөд латин асуултын орчуулга хамгийн сул хэвээр.

# Дүгнэлт

Энэхүү ажлаар нэг GPU-д ажиллах нээлттэй эхийн Arctic-Text2SQL-R1-7B загварт суурилсан, банк бус санхүүгийн байгууллагын өгөгдлийн сан дээр монгол хэлээр асуусан асуултыг SQL болгож хариулдаг системийг бүтээж, бүрэлдэхүүн бүрийн нөлөөг хяналттай туршилтаар хэмжив.

Шинэ асуултаас бүрдсэн test дээр нэмэлт сургалттай суурь (D2) 21.0% байсан бол орчуулга ба засвартай H4 34.0% ($p = 8.6 \times 10^{-4}$), 8 хувилбарын санал хураалттай E2 38.5%, тодруулгатай E3c 46.5% хүрэв. Мэдлэг хайлт (+12.0 пункт) ба орчуулга (+11.3) хамгийн их, өөрийн DB-ийн жишээгүй нэмэлт сургалт (+1.4) ба алдааны мессежээр засах (+0.3) хамгийн бага нэмэр өгсөн. Алдааны 38% нь орчуулгаас үүдсэн тул санхүүгийн хэллэгийн орчуулгын өгөгдөл бэлтгэж, орчуулагчийг нэмж сургав: санхүүгийн 8 500 мөрөөр QLoRA сургасан MADLAD-400-3B-ийн chrF++ 58.0 $\rightarrow$ 74.8 болж, түүгээр орчуулсан нэг үүсгэлттэй тохиргоо (M1a) dev-ийн хариулах боломжтой асуултад 56.7% буюу Qwen орчуулгатай I3t-ээс 9.8 пункт өндөр гарсан (test дээр баталгаажуулах шаардлагатай). Сэдэв батлах даалгаврын зорилтуудын биелэлтийг Хүснэгт 6.9-д нэгтгэв.

Хүснэгт 6.9: Зорилгын биелэлтийн нэгтгэл

| № | Зорилт | Биелэлт |
|---|---|---|
| 1 | Мэдлэгийн сан (RAG) бүрдүүлэх | 28 view, 425 багана, 45 нэр томьёо, 20 KPI, 635 жишээ (§3.1) |
| 2 | Prompt ба pipeline боловсруулах | 7 алхамтай дамжлага, 84 нэрлэсэн тохиргоо (Бүлэг 2, 5) |
| 3 | Монгол хэл ба өөрийн DB-д тохируулан сургах | C1–C3, D2 (A100), D3 (T4); орчуулагчийн M1 сургалт (chrF++ 58.0 $\rightarrow$ 74.8); H3 батлагдаагүй |
| 4 | Олон хувилбараас сонгох, засах, татгалзах | E1, E2, E3c, E4; test хариулах боломжтой EX +17/−3 ($p = 0.0026$) |
| 5 | Тестийн багцаар хэмжиж тайлагнах | dev 300 + test 200; test 21.0% $\rightarrow$ 46.5% (§6.1) |

**Оруулсан хувь нэмэр.** (1) Монгол хэлний Text2SQL-ийн 500 асуулттай үнэлгээний сан; (2) бага нөөцтэй хэл ба 7B загварт мэдлэг хайлт ба орчуулга хамгийн их нөлөөтэйг McNemar тестээр харуулсан эмпирик нотолгоо; (3) алдааны эх үүсвэрийн хэмжилт ба орчуулгын өгөгдөл; (4) үнэгүй үүлэн квот дээр давтагдахуйц систем ба Text2SQL Studio хэрэгсэл.

**Цаашдын чиглэл.**

1. Сургасан орчуулагчтай M1a тохиргоог test дээр нэг удаа хэмжиж, SQL бичигчийн (D3, схемд тогтвортой INV1) сургалтын үр дүнг dev дээр шийдэх; M1-ийн DB утга хадгалах сул талыг (13.6%) засах;

2. Үнэлгээний санг хоёр домэйн шинжээчээр шалгаж, бүх харьцуулалтыг нэг төхөөрөмж дээр давтах;

3. Латин асуулт дээр тусад нь хэмжиж, бодит өгөгдлийн хамгаалалттай хуулбар дээр shadow горимоор туршиж хэрэглэгчийн санал авах.

**Нийгмийн нөлөө.** Монгол хэлээр өгөгдлийн сангаас тоо мэдээ авах боломж нь SQL мэдэхгүй ажилтнуудын шинжээчээс хамаарах хамаарлыг бууруулж, шийдвэр гаргалтыг хурдасгана. Нээлттэй эхийн загвар ба нэг GPU-д суурилсан тул жижиг, дунд байгууллага ч өгөгдлөө гадагш гаргахгүйгээр ашиглах боломжтой.

ХАВСРАЛТ А

# Ажиллуулах тушаалууд

**Орчин бэлтгэх ба өгөгдлийн сан.**

```
pip install -e .
export T2S_ADMIN_DSN=postgresql://postgres@localhost:55432/postgres
t2s db-build            # схем + синтетик өгөгдөл (648 205 мөр), t2s view
t2s testsuite-build     # 8 test-suite хуулбар
t2s knowledge-check     # мэдлэгийн сан <-> DB-ийн нийцэл
t2s index-build         # BM25 + BGE-M3 индекс
t2s check-gold --split all
```

**Үнэлгээ.**

```
t2s eval --run A7,B5 --split dev          # туршилтын ID-аар
t2s eval --run E2 --split test            # шилдэг тохиргоог test дээр нэг удаа
t2s eval --run B5 --oracle                # дамжлагыг gold SQL-ээр шалгах
t2s reselect --from E2 --to E4 --split dev   # GPU-гүй дахин сонголт (E4)
t2s derive-abstain --from E2 --to E3c --threshold 0.5 --action clarify
t2s compare --a <H4.jsonl> --b <E2.jsonl>     # McNemar
t2s report && t2s report-latex
```

**Орчуулга, аюулгүй байдал, үйлчилгээ.**

```
t2s translate --split dev --t2            # орчуулгын кэш (T2)
t2s security-test                         # 28 SQL халдлага, 56 prompt injection
    , RLS
t2s serve                                 # FastAPI (shadow / pilot / live)
t2s flow-ui --demo --port 8090            # Text2SQL Studio, загваргүй демо
```

**Kaggle үе шат** (`config/kaggle_overrides.env`-ээр сонгоно):

```
STAGE=e2test    bash scripts/server/run_plan_l4.sh   # E2 test
STAGE=istage    bash scripts/server/run_plan_l4.sh   # I3, I3t dev/test
STAGE=train_d3  bash scripts/server/run_plan_l4.sh   # D3 QLoRA (checkpoint-ooc
    юргэлжилнэ)
STAGE=mt        bash scripts/server/run_plan_l4.sh   # MT M0 bake-off + MADLAD
    QLoRA
STAGE=t2s_inv   bash scripts/server/run_plan_l4.sh   # S1-S4 өгөгдөл, сургалт, T
    -2/T-4
STAGE=web       bash scripts/server/run_plan_l4.sh   # Studio + загвар + tunnel
```

ХАВСРАЛТ Б

# Төслийн файлын бүтэц

```
text2sql-new/
  src/mn_text2sql/       Python багц (85 модуль)
    pipeline/            orchestrator, translate, dialect, postproc, selection, intent_check
    retrieval/ knowledge/ BM25, BGE-M3, schema linking
    llm/ security/ db/ datagen/ eval/ training/ text/
    service/             FastAPI, Text2SQL Studio (static/builder.html), flow.py
  config/                experiments.yaml (84 тохиргоо), models.yaml, flows.yaml
  knowledge/             semantic_model, glossary, metrics, examples*.jsonl
  evalset/               dev.jsonl (300), test.jsonl (200), AUTHORING.md
  evalset_shift/         T-2 (нэр сольсон схем), T-4 (тодорхойлолт)
  data/mt/v2/            MT v2: 2 828 хос, SFT мөр, human_review.html
  data/t2s_inv/          S1-S4 сургалтын prompt
  db/                    DB-ийн хуулбар ба CHANGES.md
  scripts/server/        run_plan_l4.sh (STAGE=...)
  scripts/notebook/      bootstrap.sh, pack_code.py, merge_lora.py, make_web_kaggle.py
  scripts/mt/ scripts/t2s_inv/  MT ба тогтвортой сургалтын скрипт
  notebooks/             Kaggle / Colab notebook
  results/runs/<split>/<ID>/   асуулт бүрийн үр дүн, summary, meta
  tests/                 pytest
  docs/                  WORKLOG, MT_INVARIANT_PLAN, AGENT, CLOUD ...
  report_diplom/         энэ тайлан
```

ХАВСРАЛТ В

# Туршилтын тохиргооны жагсаалт

Хүснэгт В.1: Ажиллуулсан болон бэлэн тохиргоонууд (`config/experiments.yaml`)

| ID | Тайлбар |
|---|---|
| A1 | Суурь загвар, кирилл асуулт, тайлбаргүй схем, RAG-гүй |
| A2 / A3 | A1-ийн англи / латин галиг хувилбар |
| A4 | Асуултыг англи руу машин орчуулах (Kaggle-д кэшгүй тул ажиллаагүй) |
| A6 | Prompt-д PostgreSQL dialect заах |
| A7 | SQLite-аар үүсгээд sqlglot-оор PostgreSQL руу хөрвүүлэх |
| B1–B4 | A7 + тайлбар, синоним (B1); утгын хайлт (B2); нэр томьёо (B3); 4 жишээ (B4) |
| B5 | B1–B4 бүгд (RAG); «B5 tr» = + англи орчуулга |
| C1 | LoRA SFT (rank 32), rejection sampling, RAG-гүй үнэлгээ |
| C2 | C1 + gold-оор чиглүүлсэн CoT |
| C3 | C2 + өөрийн DB-ийн синтетик өгөгдөл ба 160 жишээ |
| D2 | B5-ийн RAG prompt-оор сургасан adapter + RAG; «D2 tr» = + орчуулга |
| D3 | Богино (schema linking) prompt, QLoRA (112/116 алхам, үнэлгээ хүлээгдэж байна) |
| H1 | D2 + postproc (код ↔ нэр, огноо, ROUND), хувийн мэдээлэл/бичих хүсэлтээс татгалзах, алдаатай SQL-ээс татгалзах |
| H2 | H1 + монгол асуулт ба англи орчуулга хамт |
| H3 | H1 + асуултыг англи орчуулгаар солих |
| H4 | H1 + загварт англи, хайлт ба жишээ сонголт монголоор |
| E1 | H4 + гүйцэтгэлийн алдааны мессежээр засах ($\leq$2) |
| E2 | E1 + 8 хувилбар (sampling), гүйцэтгэлийн үр дүнгээр санал хураах |
| E3c | E2 + санал нийлэлт $<$ 0.5 бол тодруулга |
| E4f | E2 + хоосон, бүгд NULL, DB-д байхгүй утгатай хувилбарыг хасах; улирлын формат засвар |
| E4 | E4f + түлхүүр үгээр татгалзах (цалин, инфляц, таамаг г.м.), бүдэг хугацаанд тодруулга (dev-ээс гаргасан) |
| I1 / I2 | H4 + dev-ийн асуулт жишээ болгон (өөрийн гэр бүлийг хасаж) / H4 + шинэ 195 жишээ |
| I3 | H4 + 160 + 224 + 195 = 579 жишээ |
| I3t / I3t2 | I3 + засварласан орчуулга / T2 орчуулга (маскын шүүлт, нэр томьёоны RAG) |
| I3r, I3tr | Тухайн тохиргоо + E4-ийн дүрэм (загваргүй) |
| J1 | I3t + нэр томьёог англиар |
| K1–K3 | I3t2 + agentic давталт (tool, critic, planner) — код бэлэн |
| WEB | Вэбийн тохиргоо: schema linking, богино prompt |

| ID | Тайлбар |
|---|---|
| F1–F10, G1–G6 | Төлөвлөгөөний шинэлэг санаа ба agentic горим — код бэлэн, ажиллаагүй |

ХАВСРАЛТ Г

# Ажлын түүх

Төсөл git-д бүртгэгдээгүй тул ажлын түүхийг `docs/WORKLOG.md`-ээс нэгтгэв (2026 он, Улаанбаатарын цаг).

Хүснэгт Г.1: Ажлын гол үе шат

| Огноо | Хийсэн ажил |
|---|---|
| 10-15 | Заавар ба туршилтын төлөвлөгөөг код болгосон: CLI, дамжлага, RAG, үнэлгээ, сургалт, аюулгүй байдал; dev 300, test 200, 160 жишээ |
| 10-16 | Agentic горим, LaTeX тайлангийн анхны хувилбар; Kaggle ба Modal-д бэлтгэсэн |
| 10-17 | A, B бүлэг (Kaggle T4); C1–C3 сургалт (Modal); D2 сургалт ба H бүлэг (Vast A100) |
| 10-18 | E2 dev 41.0%; test D2 21.0%, H4 34.0%, E2 38.5%, E3c 46.5%; 195 шинэ жишээ; E4 |
| 10-19 | I3, I3t dev ба test; E4 test 45.0%; D3 QLoRA 112/116 алхам; 280 жишээ |
| 10-20 | T2 орчуулга (маск 122 → 37); agentic K1–K3 тохиргоо |
| 10-23 | Орчуулгын fine-tune ба тогтвортой сургалтын төлөвлөгөө; MT v0 өгөгдөл |
| 10-25 | MT v2 (2 828 хос), S1–S4, T-2/T-4; Kaggle STAGE=mt эхэлсэн; Text2SQL Studio; локал PostgreSQL демо |
| 10-26 | Танилцуулга ба энэ тайлан; Kaggle дээр MADLAD-400-3B-ийн QLoRA сургалт (Version 13) |

# Ном зүй


[1] Liang Shi et al. “A Survey on Employing Large Language Models for Text-to-SQL Tasks”. In: *ACM Computing Surveys* 58.2 (2025), pp. 1–37. DOI: 10.1145/3737873. arXiv: 2407.15186 [cs.CL].

[2] Jinyang Li et al. “Can LLM Already Serve as A Database Interface? A BIg Bench for Large-Scale Database Grounded Text-to-SQLs”. In: *Advances in Neural Information Processing Systems 36 (NeurIPS 2023), Datasets and Benchmarks Track*. 2023. arXiv: 2305.03111 [cs.CL]. URL: https://arxiv.org/abs/2305.03111.

[3] Zhewei Yao et al. *Arctic-Text2SQL-R1: Simple Rewards, Strong Reasoning in Text-to-SQL*. 2025. arXiv: 2505.20315 [cs.CL]. URL: https://arxiv.org/abs/2505.20315.

[4] Longxu Dou et al. “MultiSpider: Towards Benchmarking Multilingual Text-to-SQL Semantic Parsing”. In: *Proceedings of the AAAI Conference on Artificial Intelligence* 37.11 (2023), pp. 12745–12753. DOI: 10.1609/aaai.v37i11.26499. arXiv: 2212.13492 [cs.CL].

[5] Khanh Trinh Pham et al. “Multilingual Text-to-SQL: Benchmarking the Limits of Language Models with Collaborative Language Agents”. In: *Databases Theory and Applications (ADC 2025)*. Lecture Notes in Computer Science. Springer Nature Singapore, 2026, pp. 108–123. DOI: 10.1007/978-981-95-6196-4_8. arXiv: 2509.24405 [cs.CL].

[6] Mengyuan Zhang et al. *MM-Eval: A Hierarchical Benchmark for Modern Mongolian Evaluation in LLMs*. 2024. arXiv: 2411.09492 [cs.CL]. URL: https://arxiv.org/abs/2411.09492.

[7] Gyubok Lee et al. *TrustSQL: Benchmarking Text-to-SQL Reliability with Penalty-Based Scoring*. 2024. arXiv: 2403.15879. URL: https://arxiv.org/abs/2403.15879.

[8] Tao Yu et al. “Spider: A Large-Scale Human-Labeled Dataset for Complex and Cross-Domain Semantic Parsing and Text-to-SQL Task”. In: *Proceedings of the 2018 Conference on Empirical Methods in Natural Language Processing (EMNLP)*. Brussels, Belgium: Association for Computational Linguistics, 2018, pp. 3911–3921. DOI: 10.18653/v1/D18-1425. arXiv: 1809.08887 [cs.CL].

[9] Ruiqi Zhong, Tao Yu, and Dan Klein. “Semantic Evaluation for Text-to-SQL with Distilled Test Suites”. In: *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP)*. Association for Computational Linguistics, 2020, pp. 396–411. DOI: 10.18653/v1/2020.emnlp-main.29. arXiv: 2010.02840 [cs.CL].

[10] Irina Saparina and Mirella Lapata. "AMBROSIA: A Benchmark for Parsing Ambiguous Questions into Database Queries". In: *Advances in Neural Information Processing Systems 37 (NeurIPS 2024), Datasets and Benchmarks Track*. 2024. arXiv: 2406.19073 [cs.CL]. URL: https://arxiv.org/abs/2406.19073.

[11] Adithya Bhaskar et al. "Benchmarking and Improving Text-to-SQL Generation under Ambiguity". In: *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing (EMNLP)*. Association for Computational Linguistics, 2023, pp. 7053–7074. DOI: 10.18653/v1/2023.emnlp-main.436.

[12] Haoyang Li et al. "OmniSQL: Synthesizing High-quality Text-to-SQL Data at Scale". In: *Proceedings of the VLDB Endowment* 18.11 (2025), pp. 4695–4709. DOI: 10.14778/3749646.3749723. arXiv: 2503.02240 [cs.CL]. URL: https://arxiv.org/abs/2503.02240.

[13] Binyuan Hui et al. *Qwen2.5-Coder Technical Report*. 2024. arXiv: 2409.12186 [cs.CL]. URL: https://arxiv.org/abs/2409.12186.

[14] Zhihong Shao et al. *DeepSeekMath: Pushing the Limits of Mathematical Reasoning in Open Language Models*. 2024. arXiv: 2402.03300 [cs.CL]. URL: https://arxiv.org/abs/2402.03300.

[15] Patrick Lewis et al. "Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks". In: *Advances in Neural Information Processing Systems 33 (NeurIPS 2020)*. 2020. arXiv: 2005.11401 [cs.CL]. URL: https://arxiv.org/abs/2005.11401.

[16] Shayan Talaei et al. *CHESS: Contextual Harnessing for Efficient SQL Synthesis*. 2024. arXiv: 2405.16755 [cs.LG]. URL: https://arxiv.org/abs/2405.16755.

[17] Haoyang Li et al. "CodeS: Towards Building Open-source Language Models for Text-to-SQL". In: *Proceedings of the ACM on Management of Data* 2.3 (2024), pp. 1–28. DOI: 10.1145/3654930. arXiv: 2402.16347. URL: https://arxiv.org/abs/2402.16347.

[18] Dawei Gao et al. "Text-to-SQL Empowered by Large Language Models: A Benchmark Evaluation". In: *Proceedings of the VLDB Endowment* 17.5 (2024), pp. 1132–1145. DOI: 10.14778/3641204.3641221. arXiv: 2308.15363 [cs.DB].

[19] Karime Maamari et al. *The Death of Schema Linking? Text-to-SQL in the Age of Well-Reasoned Language Models*. 2024. arXiv: 2408.07702 [cs.CL]. URL: https://arxiv.org/abs/2408.07702.

[20] Xuezhi Wang et al. "Self-Consistency Improves Chain of Thought Reasoning in Language Models". In: *International Conference on Learning Representations (ICLR)*. 2023. arXiv: 2203.11171. URL: https://arxiv.org/abs/2203.11171.

[21] Mohammadreza Pourreza et al. "CHASE-SQL: Multi-Path Reasoning and Preference Optimized Candidate Selection in Text-to-SQL". In: *The Thirteenth International Conference on Learning Representations (ICLR 2025)*. 2025. arXiv: 2410.01943 [cs.LG]. URL: https://arxiv.org/abs/2410.01943.

[22] Jie Huang et al. "Large Language Models Cannot Self-Correct Reasoning Yet". In: *The Twelfth International Conference on Learning Representations (ICLR 2024)*. 2024. arXiv: 2310.01798 [cs.CL]. URL: https://arxiv.org/abs/2310.01798.

[23] Aviral Dawar et al. *IndicDB – Benchmarking Multilingual Text-to-SQL Capabilities in Indian Languages*. 2026. arXiv: 2604.13686 [cs.CL]. URL: https://arxiv.org/abs/2604.13686.

[24] Ali Buğra Kanburoğlu and F. Boray Tek. "TUR2SQL: A Cross-Domain Turkish Dataset For Text-to-SQL". In: *2023 8th International Conference on Computer Science and Engineering (UBMK)*. IEEE, 2023, pp. 206–211. DOI: 10.1109/UBMK59864.2023.10286686.

[25] Burak Aktaş et al. "BIRDTurk: Adaptation of the BIRD Text-to-SQL Dataset to Turkish". In: *Proceedings of the Second Workshop on Natural Language Processing for Turkic Languages (SIGTURK 2026)*. Association for Computational Linguistics, 2026, pp. 155–171. DOI: 10.18653/v1/2026.sigturk-1.13.

[26] Salmane Chafik, Saad Ezzini, and Ismail Berrada. *Dialect2SQL: A Novel Text-to-SQL Dataset for Arabic Dialects with a Focus on Moroccan Darija*. Also in Proceedings of the WACL 2025 workshop. 2025. arXiv: 2501.11498 [cs.SE]. URL: https://arxiv.org/abs/2501.11498.

[27] Julen Etxaniz et al. "Do Multilingual Language Models Think Better in English?" In: *Proceedings of the 2024 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (Volume 2: Short Papers)*. Association for Computational Linguistics, 2024, pp. 550–564. DOI: 10.18653/v1/2024.naacl-short.46. arXiv: 2308.01223 [cs.CL].

[28] Haoyang Huang et al. "Not All Languages Are Created Equal in LLMs: Improving Multilingual Capability by Cross-Lingual-Thought Prompting". In: *Findings of the Association for Computational Linguistics: EMNLP 2023*. Association for Computational Linguistics, 2023, pp. 12365–12394. DOI: 10.18653/v1/2023.findings-emnlp.826. arXiv: 2305.07004 [cs.CL].

[29] Quulgan Minggad, Xiao Zinan, and Yuan Sun. "MonCulture-Eval: A Hierarchical Benchmark for Evaluating Mongolian Cultural Capabilities of Large Language Models across Scripts and Regions". In: *Findings of the Association for Computational Linguistics: ACL 2026*. Association for Computational Linguistics, 2026, pp. 28997–29014. DOI: 10.18653/v1/2026.findings-acl.1449.

[30] Б. Очир. *Монгол болон англи хэлний асуултыг олон диалектын SQL болгон хөрвүүлэх нээлттэй эх агент системийн туршилт судалгаа*. Өмнөх ажил, text2sql-thesis репозитор. 2026.

[31] Jeffrey Johnson et al. *QueryGPT – Natural Language to SQL Using Generative AI*. Uber Engineering Blog. Sept. 2024. URL: https://www.uber.com/us/en/blog/query-gpt/ (visited on 09/21/2026).

[32] Albert Chen et al. *Practical Text-to-SQL for Data Analytics*. LinkedIn Engineering Blog. Dec. 2024. URL: https://www.linkedin.com/blog/engineering/ai/practical-text-to-sql-for-data-analytics (visited on 09/21/2026).

[33] Snowflake Inc. *Cortex Analyst*. Snowflake Documentation. 2026. URL: https://docs.snowflake.com/user-guide/snowflake-cortex/cortex-analyst (visited on 10/26/2026).

[34] Databricks. *What is an AI/BI Genie space*. Databricks Documentation. 2026. URL: https://docs.databricks.com/genie/index.html (visited on 10/26/2026).

[35] Microsoft. *Introduction to Q&A tooling to train Power BI Q&A*. Microsoft Learn. 2026. URL: https://learn.microsoft.com/en-us/power-bi/natural-language/q-and-a-tooling-intro (visited on 10/26/2026).

[36] Amazon Web Services. *Getting started with Amazon QuickSight Q*. Amazon QuickSight User Guide. 2026. URL: https://docs.aws.amazon.com/quicksight/latest/user/quicksight-q-get-started.html (visited on 10/26/2026).

[37] Vanna.AI. *Vanna: open-source Python RAG framework for SQL generation*. GitHub. 2026. URL: https://github.com/vanna-ai/vanna (visited on 10/26/2026).

[38] Canner. *Wren AI: open-source GenBI agent with a semantic layer*. GitHub. 2026. URL: https://github.com/Canner/WrenAI (visited on 10/26/2026).

[39] Quinn McNemar. "Note on the Sampling Error of the Difference Between Correlated Proportions or Percentages". In: *Psychometrika* 12.2 (1947), pp. 153–157.

[40] Snowflake. *Arctic-Text2SQL-R1-7B: model card*. 2025. URL: https://huggingface.co/Snowflake/Arctic-Text2SQL-R1-7B (visited on 10/16/2026).

[41] Toby Mao et al. *sqlglot: A no-dependency SQL parser, transpiler, optimizer, and engine*. Version 30.18.0. MIT License. 2026. URL: https://github.com/tobymao/sqlglot (visited on 09/21/2026).

[42] Woosuk Kwon et al. "Efficient Memory Management for Large Language Model Serving with PagedAttention". In: *Proceedings of the 29th Symposium on Operating Systems Principles (SOSP 2023)*. ACM, 2023, pp. 611–626. DOI: 10.1145/3600006.3613165. arXiv: 2309.06180 [cs.LG].

[43] Edward J. Hu et al. "LoRA: Low-Rank Adaptation of Large Language Models". In: *The Tenth International Conference on Learning Representations (ICLR 2022)*. 2022. arXiv: 2106.09685 [cs.CL]. URL: https://openreview.net/forum?id=nZeVKeeFYf9.

[44] Tim Dettmers et al. "QLoRA: Efficient Finetuning of Quantized LLMs". In: *Advances in Neural Information Processing Systems 36 (NeurIPS 2023)*. 2023. arXiv: 2305.14314 [cs.LG]. URL: https://proceedings.neurips.cc/paper_files/paper/2023/hash/1feb87871436031bdc0f2beaa62a049b-Abstract-Conference.html.

[45] Sneha Kudugunta et al. "MADLAD-400: A Multilingual And Document-Level Large Audited Dataset". In: *Advances in Neural Information Processing Systems 36 (Datasets and Benchmarks Track)*. 2023.

[46] Maja Popović. "chrF++: words helping character n-grams". In: *Proceedings of the Second Conference on Machine Translation*. 2017, pp. 612–618.

[47] Stephen Robertson and Hugo Zaragoza. "The Probabilistic Relevance Framework: BM25 and Beyond". In: *Foundations and Trends in Information Retrieval* 3.4 (2009), pp. 333–389.

[48] Jianlyu Chen et al. "M3-Embedding: Multi-Linguality, Multi-Functionality, Multi-Granularity Text Embeddings Through Self-Knowledge Distillation". In: *Findings of the Association for Computational Linguistics: ACL 2024*. Association for Computational Linguistics, 2024, pp. 2318–2335. DOI: 10.18653/v1/2024.findings-acl.137. arXiv: 2402.03216. URL: https://aclanthology.org/2024.findings-acl.137/.